Universidade de São Paulo Escola Superior de Agricultura "Luiz de Queiroz"

Detecção e modelagem de padrão espacial em dados binários e de contagem

Denise Nunes Viola

Tese apresentada, para obtenção do título de Doutor em Agronomia. Area de concentração: Estatística e Experimentação Agronomica

Piracicaba 2007

Denise Nunes Viola Estatístico

Detecção e modelagem de padrão espacial em dados binários e de contagem

\sim				1		
()	rı	On	1ta	М	or	
•	'11	CI.	ıta	u	w	

Profa. Dra. CLARICE GARCIA BORGES DEMÉTRIO

Tese apresentada, para obtenção do título de Doutor em Agronomia. Area de concentração: Estatística e Experimentação Agronomica

Piracicaba 2007

Dados Internacionais de Catalogação na Publicação (CIP) DIVISÃO DE BIBLIOTECA E DOCUMENTAÇÃO - ESALQ/USP

Viola, Denise Nunes

Detecção e modelagem de padrão espacial em dados binários e de contagem / Denise Nunes Viola. - - Piracicaba, 2007. 118 p.

Tese (Doutorado) - - Escola Superior de Agricultura Luiz de Queiroz, 2007. Bibliografia.

- Cebola 2. Distribuição espacial 3. Distribuição de Poisson
 Geoestatística 5. Simulação (Estatística) 6. Tripes I. Título
- CDD 515.5

"Permitida a cópia total ou parcial deste documento, desde que citada a fonte – O autor"

DEDICATÓRIA

Aos meus pais e minha irmã

pelo amor, dedicação, paciência,

incentivo, carinho e compreeensão.

AGRADECIMENTOS

À Prof.^a Dr.^a Clarice, a orientação, a ajuda, os ensinamentos, as sugestões, as discussões, a paciência e a amizade.

Ao Prof. Dr. Bryan e Prof. Dr. Paulo, as sugestões, as discussões, os ensinamentos e a ajuda.

Ao Prof. Dr. Odair, por ceder os dados, as discussões e as sugestões.

Aos meus pais e minha irmã, o carinho, o amor, o apoio e o incentivo constante.

Ao Marcelo por estar sempre ao meu lado nas horas difíceis, me escutar, aconselhar, apoiar e me confortar sempre com uma palavra de carinho.

Ao tio Tércio o apoio, a amizade e por estar sempre presente.

Aos amigos Ana Alice, Ana Cristina, Elias, Ramiro e Renato, as sugestões, a troca de conhecimentos e as dicas no R e no Latex.

À Ângela, a tradução, o carinho e a amizade.

Aos amigos Cesar, Lucio, Luziane, Nelson, Renato e Vanderly, a ajuda, as dicas e as sugestões.

Aos amigos Adriano, Afrânio, Ana Paula, Andréia, Carol, Clarissa, Dianna, Edila, Elide, Giovana, Gisele, Hélio, Lia, Luizinho, Moita, Patrícia, Rosângela, Sandra, Tati e Vivian, o carinho, os conselhos, o incentivo e o apoio.

Aos amigos Ana Maria, Beth, David, Fogo, Geneville e Pedro, a força, a troca de conhecimentos e a amizade.

Aos professores do Departamento de Ciências Exatas da ESALQ/USP, os ensinamentos, as conversas, os conselhos e a amizade.

Á Luciana, Solange e demais funcionários do Departamento de Ciências Exatas da ESALQ/USP, o apoio e a atenção.

Aos amigos e alunos de pós-graduação em Estatística e Experimentação Agronômica do Departamento de Ciências Exatas da ESALQ/USP, o apoio, o carinho, os conselhos e a amizade.

Aos colegas e amigos do Departamento de Estatística da UFBa, o apoio, o incentivo e a confiança depositada.

Á CAPES, o suporte financeiro.

À Glória, a correção e a revisão das normas.

Aos professores e funcionários das Faculdades COC, o incentivo e a colaboração.

À Edileuza e Maria José, o carinho e a ajuda.

A todos, que de forma direta ou indireta colaboram para a realização desse trabalho.

SUMÁRIO

Resumo	6
ABSTRACT	7
1 INTRODUÇÃO	8
Referências	11
2 DETECÇÃO DE PADRÕES ESPACIAIS NA OCORRÊNCIA DO TRIPES DO	
PRATEAMENTO NA CULTURA DA CEBOLA	15
Resumo	15
Abstract	15
2.1 Introdução	15
2.2 Desenvolvimento	17
2.2.1 Material	17
2.2.2 Métodos	20
2.2.3 Resultados e discussão	25
2.3 Conclusões	31
Referências	32
3 UMA AVALIAÇÃO DO ESTIMADOR DE PSEUDO-VEROSSIMILHANÇA PARA	
MODELOS AUTOLOGÍSTICOS ESPACIAIS	35
Resumo	35
Abstract	35
3.1 Introdução	35
3.2 Desenvolvimento	37
3.2.1 Modelo autologístico	37
3.2.2 Estimação	40
3.2.3 Um estudo de simulação	43
3.2.4 Resultados e discussão do estudo de simulação	45
3.2.5 Aplicação	46
3.3 Conclusões	51
Referências	52
APÊNDICE	56
ANEXO	93

RESUMO

Detecção e modelagem de padrão espacial em dados binários e de contagem

A distribuição espacial de insetos e doenças em campos comerciais é importante, por exemplo, para aplicação racional de pesticidas. Entretanto, não tem sido considerada nas recomendações de manejo da cultura, planejamento de experimentos e estudos amostrais, sendo escassa literatura a esse respeito. Os artigos apresentados nessa tese foram motivados por duas situações diferentes, uma envolvendo dados de contagem e a outra, dados binários. Os dois modelos diferem em relação às estratégias da descrição da estrutura de dependência espacial. No primeiro artigo, a variável resposta é contagem. Para caracterizar o padrão espacial da dispersão do tripes do prateamento da cebola foi feito um levantamento anotando-se o número de insetos por fase de desenvolvimento em folhas de plantas de cebola, em diferentes datas e pontos amostrais dentro de quatro propriedades com fazendas vizinhas apresentando diferentes níveis de infestação e métodos de plantio. O teste de aleatorização de Mantel foi utilizado para testar a presença de padrão espacial, que quando detectado foi descrito por um modelo de Poisson misto espacial com componente aleatório geoestatístico. Tal modelo possibilitou a caracterização do padrão espacial bem como a obtenção de mapas de predição dos níveis de susceptibilidade à infestação na área. No segundo artigo a variável resposta é binária e foi feito um estudo de simulação para verificar o comportamento dos estimadores de pseudo-verossimilhança dos parâmetros do modelo autologístico, considerando diferentes estruturas de covariáveis e de vizinhança, três intensidades de infestação de uma praga e cinco valores para o parâmetro de correlação entre os vizinhos. Uma aplicação dos modelos considerados no estudo de simulação é feita a um conjunto de dados provenientes de um experimento com pimentão. Mostra-se que o método de estimação por pseudo-verossimilhança pode ser usado, com certa cautela, quando o interesse está na contribuição das covariáveis, mas não deve ser usado quando o interesse está na estimação da correlação espacial. Um estudo com diferentes porcentagens de dados faltantes foi feito para verificar a influência na estimação do parâmetro.

Palavras-chave: Testes de aleatorização; Tripes do prateamento; Cebola; Geoestatística; Distribuição de Poisson; Dados biários; Pseudo-verossimilhança; Modelo autologístico.

ABSTRACT

Detection and modelling of space pattern in binary and counting data

The spatial distribution of insects and diseases in commercial fields is important for the efficient application of pesticides. However, in the past this has not been considered in crop management recommendations, experiment planning and sampling plans. The papers presented in this thesis were motivated by two different situation, one envolving count data and the other binary data. The two models used differ in relation to the strategies of the description of the spatial dependence structure. In the the first paper the response variable is a count. In order to characterize the spatial distribution pattern of the onion thrips a survey was carried out to record the number of insects in each development phase on onion plant leaves, on different dates and sample locations, in four rural properties with neighboring farms with different infestation levels and planting methods. The Mantel randomization test was used to test for spatial correlation, and when detected this was modelled by a mixed spatial Poisson model with a geostatistic random component. This model has allowed a spatial pattern characterization as well as the production of prediction maps of susceptibility to levels of infestation in the area. In the second paper the response variable is binary. In this paper a simulation study on pseudo-likelihood estimators of autologistic parameters to verify the effect of different covariate and neighbouring structures is described, with three pest infestation levels and five different spatial correlation coefficient values. An application of the methodology is presented using a bell pepper data set. It is shown that the pseudo-likelihood method can be used when a researcher is interested in the effect of covariates, but should not be used for the estimation of the spatial correlation. A study with different percentages of missing data is made to verify the influency on parameter estimation.

Keywords: Randomization test; Thrips tabacci; Onion; Geostatistics; Poisson distribution; Binary data; Pseudo-likelihood; Autologistic model.

1 INTRODUÇÃO

A agricultura vem apresentando grande desenvolvimento no Brasil e um fator que preocupa bastante os produtores rurais é a infestação de insetos. Em muitos casos, a produção é bastante afetada e com isso, sua colheita torna-se prejudicada. A distribuição de insetos muitas vezes sugere a estrutura de dependência espacial, porém, geralmente, o produtor não sabe como agir nessas situações, comprometendo sua produção. Existem ainda, algumas infestações que prejudicam toda a colheita quando não são tomados os devidos cuidados, apresentando evidência de dependência espacial e/ou temporal.

A distribuição espacial de insetos em campos comerciais é importante, por exemplo, para aplicação racional de pesticidas e nos estudos ambientais e de comportamento das espécies (RUIZ, 2002). Entretanto, não tem sido considerada nas recomendações de manejo da cultura, planejamento de experimentos e estudos amostrais, sendo escassa literatura a esse respeito. A fim de que os padrões espaciais sejam detectados e modelados, técnicas especiais de análise estatística são necessárias.

Os métodos convencionais de análise estatística, geralmente, são baseados em amostras independentes e identicamente distribuídas, o que não acontece em dados que apresentem estrutura de dependência espacial e/ou temporal, uma vez que as amostras são correlacionadas. Quando os dados apresentam evidência de distribuição espacial, espera-se que as observações vizinhas sejam mais parecidas do que as distantes. Dados com padrões específicos de distribuição espacial podem ser encontrados em áreas tais como agronômica, florestal, biológica, saúde, educação, dentre outras.

Numa caracterização inicial, o padrão espacial de dispersão de insetos pode ser classificado como aleatório, agregado ou regular (Figura 1). O aleatório ocorre quando, em condições naturais, há oportunidades iguais de infestação para todas as plantas, enquanto que o padrão agregado está associado à pequena mobilidade do inseto. O padrão regular raramente ocorre de forma natural, mas pode ser induzido pelo plantio alternado de plantas resistentes e susceptíveis. Para estudar se o padrão de dispersão de leucemia infantil era aleatório, Mantel (1967) propôs um teste de aleatorização, baseado nas matrizes de distância entre as observações. Entretanto, não foram encontradas aplicações no estudo de dispersão de insetos e, em particular, do tripes do prateamento.

Por outro lado, é muito comum, no estudo da dispersão de insetos, encontrar o uso de índices baseados na relação entre variância e média, tais como o índice de David & More, a lei de poder de Taylor, os índices de agregação de Lloyd e Iwao, dentre outros (RUIZ et al., 2003). Entretanto, esses índices ignoram a localização espacial das amostras, tendo capacidade limitada de descrição de padrões espaciais, além de dependerem fortemente do tamanho das unidades amostrais (UPTON; FINGLETON, 1985).

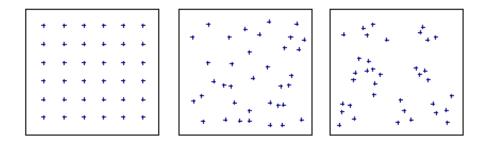


Figura 1.1 – Padrão espacial uniforme, casual e agregado

Métodos geoestatísticos (ISAAKS; SRISVARTAVA, 1989; GOOVAERTS, 1997) têm sido usados para descrever os padrões espaciais de insetos como por exemplo em Greco, Vieira e Lourenção, 2006. Tais métodos foram originalmente desenvolvidos para variáveis aleatórias contínuas com diversas implementações computacionais disponíveis. A variável contagem de insetos é discreta e tipicamente distribuída em aglomerados e com excesso de valores iguais a zero. Logo, os dados de contagens podem não ter a estrutura de covariância assumida pelos métodos tradicionais da análise geoestatística que tem uma estrutura de covariância espacial estacionária na área (RUIZ, 2002). Portanto, é recomendável adotar modelos que incorporem explicitamente o mecanismo gerador dos dados, tais como, neste caso, modelos com distribuição de Poisson para dados de contagem combinados com estruturas que descrevam o padrão espacial. Modelos desse tipo propostos na literatura estatística (e.g. DIGGLE; TAWN; MOYEED, 1998) ainda encontram poucas aplicações na análise de dados.

Existem diversas situações para as quais foram utilizadas técnicas geoestatísticas para analisar os dados com dependência espacial. Dentre elas, podem ser citados estudos da distribuição da precipitação pluviométrica medida em 143 postos meteorológicos do Estado do Paraná (RIBEIRO JR, 2004, ZAMBOTI, 2001); densidade e umidade do solo, medidas em 250 pontos (RIBEIRO JR, 1995); teor de argila de 85 amostras de solos da Fazenda Canchim, localizada em São Carlos, SP (CAMARGO); para obter os métodos de estimação dos parâmetros em modelos geoestatísticos, avaliando características morfológicas, físicas e químicas dos solos em diferentes camadas (OLIVEIRA, 2003); para modelar a profundidade *secchi* e a concentração de clorofila A em nove pontos de coleta no Rio Anil, localizado em São Luís - MA, que pode estar associada a covariáveis, tais como salinidade, pH e temperatura (ALCÂNTARA et al., 2004). Como exemplo de variáveis respostas de contagem podem ser citados estudos na Ilha de Rongelap, localizada no Oceano Pacífico, sobre a localização de níveis de alta concentração de césio radioativo (DIGGLE; TAWN; MOYEED, 1998, DIGGLE; RIBEIRO JR; CHRISTENSEN, 2003); distribuição espacial das espécies de cigarrinhas vetoras da *Xylella fastidiosa*, agente que causa a *Clorose Variegada* dos Citros em um pomar de laranjas "Pera" (FARIAS et al., 2004). Como exemplo de variáveis respostas

binárias podem ser citados estudos da existência de padrão espacial da incidência de malária em crianças de Gambia, África, (DIGGLE; RIBEIRO JR., 2007); levantamento da infestação da broca do café na Colômbia (RUIZ, 2002); para modelar a distribuição espacial da epidemiologia de *ascaríase* em dezenove setores censitários na região do município de Duque de Caxias, RJ (FORTES et al., 2004).

Variáveis respostas binárias, isto é, do tipo sucesso/fracasso são muito comuns. Assim, por exemplo, em Fitopatologia, o pesquisador pode estar interessado no estudo da presença ou ausência de uma determinada doença e sua distribuição espacial. Nesse tipo de estudo, espera-se, em geral, que as observações sejam correlacionadas no espaço e/ou no tempo. Com a finalidade de incorporar a informação da vizinhança como covariável foram propostos os modelos autologísticos (BESAG, 1972, AUGUSTIN; MUGGLESTONE; BUCKLAND, 1996, GUMPERTZ; GRAHAM; RISTANO, 1997). As áreas de aplicação são diversas e incluem estudos sobre fauna aquática de macro invertebrados em 76 lagoas inglesas (SANDERSON; EYRE; RUSHTON, 2005), comportamento de clientes em relação a políticas de seguro (MOON; RUSSEL 2005), mapeamento de pobreza em países em desenvolvimento (PETRUCCI; SALVATI; SEGHIERI 2004), distribuição espacial de renas na Suécia (TETERUKOVSKIY; EDEMIRS, 2003), distribuição de vegetação em florestas, considerando covariáveis climáticas (HE; ZHOU; ZHU 2003), distribuição da epidemia do Phytophthora em pimentão considerando efeitos de variáveis do solo (GUMPERTZ; GRA-HAM; RISTAINO, 1997), distribuição de espécies de plantas considerando covariáveis climáticas (WU; HUFFER, 1997), distribuição espacial de alces em uma região da Escócia (AUGUSTIN; MUGGLESTONE; BUCKLAND, 1996), análise genética de características familiares (ABEL; GLOLMARD; MALLET, 1993), dentre outros.

Os artigos apresentados a seguir foram motivados por duas situações distintas, uma para variáveis com resposta de contagem e outra para variáveis com resposta binária. Os dois modelos utilizados diferem quanto a estratégias da descrição da estrutura de dependência espacial.

No primeiro artigo, a variável resposta contagem é modelada por uma especificação hierárquica do processo através de um modelo geoestatístico, indicado para espaço contínuo. É motivado por um conjunto de dados provenientes de um estudo por amostragem do tripes do prateamento em cultura de cebola, em quatro propriedades, localizadas no Município de São José do Rio Pardo, interior do Estado de São Paulo, no período de junho a setembro de 1996. O objetivo é estudar a distribuição espacial do tripes. As quatro propriedades escolhidas usaram o híbrido Granex 33 de cebola e o método de plantio por mudas. As áreas experimentais foram escolhidas com vizinhos que adotavam diferentes tipos de plantio e tinham diferentes níveis de infestação. O teste de aleatorização de Mantel (MANLY, 2006) foi utilizado para testar a presença de padrão espacial, que quando detectado foi descrito por um modelo de Poisson misto espacial com componente aleatório geoestatístico. Tal modelo possibilitou a caracterização do padrão espacial bem como a obtenção

de mapas de predição dos níveis de susceptibilidade à infestação na área.

No segundo artigo, a variável resposta binária é modelada por uma especificação condicional do processo através de um modelo autologístico, indicado para espaço discreto facilmente estendido para o tempo, além de ser indicado para experimentos complexos ou com certa quantidade de dados perdidos. Inicia-se a análise com ferramentas para detectar a presença de dependência espacial.

No segundo artigo é feito um estudo de simulação para verificar o comportamento das estimativas dos parâmetros do modelo autologístico, considerando diferentes estruturas de covariáveis e de vizinhança, três intensidades de infestação de uma praga e cinco valores para o parâmetro de correlação entre os vizinhos. Uma comparação dos modelos considerados no estudo de simulação é feita, considerando-se um conjunto de dados proveniente de um experimento com pimentão, utilizado por Gumpertz, Graham e Ristino (1997). A fim de se estudar o efeito de observações faltantes sobre as estimativas dos parâmetros para os diversos modelos, diferentes proporções de observações são retiradas do conjunto analisado de dados e os novos conjuntos de observações são reanalisados.

Com o grande desenvolvimento dos recursos computacionais o uso de simulações tem sido muito comum para o estudo de propriedades estatísticas de interesse. Esses estudos são baseados em informações reais e utilizados como repetições de um experimento, sendo indicado para respostas contínuas e discretas.

Referências

ABEL, L; GOLMARD, J. L.; MALLET, A. An autologistic model for the Genetic Analysis of familial Binary data. **American Journal of Human Genetics**, Boston, v. 53, p. 894-907, 1993.

ALCÂNTARA E. H.; MOCHEL, F. R.; AMORIM, A. J. E; THEVAND, A. Modelagem da profundidade secchi e da concentração de clorofila A no estuário do Rio Anil. São Luís-MA. **Caminhos de geografia**, Uberlândia, v.2, p.19-40, 2004.

AUGUSTIN, N. H.; MUGGLESTONE, M. A.; BUCKLAND, S. T. An autologistic model for the spatial distribution of wildlife. **Journal of Applied Ecology**, London, v. 33, p. 339-347, 1996.

BESSAG, J. Nearest-neighbour systems and the auto-logistic model for binary data (with discussion). **Journal of the Royal Statistical Society**, London, v. 34, p. 75-83, 1972.

CAMARGO, E. C. G. **geoestatística: fundamentos e aplicações**. Disponível em: < http://www.dpi.inpe.brgilbertotutoriaisgis_ambiente5geoest.pdf >. Acesso em: 20 dez.

2006.

DIGGLE, P. J.; RIBEIRO JR., P. J. Model-Based geostatistics. New York: Springer, 2007. 228p.

DIGGLE, P. J.; RIBEIRO JR, P. J.; CHRISTENSEN, O. F. An introduction to Model-Based Geostatistics. In: $M\phi$ LLER, J. (Ed.). **Spatial statistics and computational methods**. New York: Springer-Verlag, 2003. chap. 1, p.1-45.

DIGGLE, P. J.; TAWN, J. A.; MOYEED, R. A. Model-Based geostatistics. **Applied Statistics**, London, v.47, p.299-350, 1998.

FARIAS, P. R.S.; ROBERTO, S. R.; LOPES, J. R. S.; PERECIN, D., Geostatistical Characterization of the Spatial Distribution of Xylellafastidiosa Sharpshooter Vectors on Citrus. **Neotropical Entomology**, Vacaria, v.33, p.13-30, 2004.

FORTES, B. P. M. D.; VALENCIA L. I. O.; RIBEIRO, S. V.; MEDRONHO, R. A. Modelagem geoestatística por *Ascaris lumbricóides*. **Caderno da saúde pública**, Rio de Janeiro, v. 2 p.727-734, 2004.

GOOVAERTS, P. Geostatistics for natural resources evaluation, New York: Oxford University Press, 1997. 483p.

GRECO, C. R.; VIEIRA, S. R.; LOURENÇÃO, A. L. Spatial distribution of *Pseudaletia sequax* franclemlont in triticale under no-till management, **Scientia Agricola**, Piracicaba, v.63, p. 321-327, 2006.

GUMPERTZ M. L.; GRAHAM, J. M; RISTANO, J. B. Autologistic model of spatial pattern of Phytophthora epidemic in bell pepper: effects of soil variables on disease presence. **Journal of Agricultural, Biological and Environmental Statistics**, Alexandria, v.2, p.131-156, 1997.

HE, F.; ZHOU, J.; ZHU, H. Autologistic regression model for the distribution of vegetation. **Journal of Agricultural, Biological and Environmental Statistics**, Alexandria, v.8, p.205-222, 2003.

ISAAKS, E.H., SRIVASTAVA, R.H. **Applied Geostatisctics**. New York: Oxford University Press, 1989. 561p.

MANLY, B. F. J. **Randomization, Bootstrap and Monte Carlo Mrthods in Biology**, Flórida: Chapman & Hall, 2006. 460p.

MANTEL, B. F. J. The detection of disease clustering and a generalised regression approach. **Cancer Research**, Philadelphia, v. 27, p. 209-220. 1967.

MOON, S; RUSSEL, G. J. Predicting product purchase from inferred customer similarity: an autologistic model approach. Disponível em:

 $<\!http:www.biz.uiowa.edumarketingpdfrussell_moon_sept05.pdf>$. Acesso em 12 nov. 2006.

OLIVEIRA, M. C. N. Métodos de estimação de parâmetros em modelos geoestatísticos com diferentes estruturas de covariâncias: uma aplicação ao teor de cálcio no solo, 2003, 140p. Tese (Doutorado em estatística e experimentação agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 2003.

PETRUCCI, A.; SALVATI, N.; SEGHIERI, C. Autologistic regression model for poverty mapping and analysis. **Metodološki Zveszki**, Ljubljana, v. 1, p. 225-234, 2004.

RIBEIRO JR., P. J. Abordagem geoestatística em um estudo de variabilidade espacial. 1995. 99p. Dissertação (Mestrado em Estatística e Experimentação Agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 1995.

RIBEIRO JR, P. J. **model based geostatistics**. Disponível em: http://leg.ufpr.br/ paulojus/MBG/slides/mbg.slides.pdf. Acesso em: 22 out. 2004.

RUIZ, R. C.; DEMÉTRIO, C. G. B.; ASSUNÇÃO, R. M.; LEANDRO, R. A. Modelos hierárquicos Bayesianos para estudar a distribuição espacial da infestação da broca do café em nível local. **Revista Colombiana de Estadística**, Bogotá, v.26, n.1 p.1-24, 2003.

RUIZ, R. Modelagem da Distribuição Espaço-Temporal da Broca do Café (*Hypothenemus hampei Ferrari*) em uma Cultura de Região Central Colombiana. 2002. 119p. Dissertação (Mestrado em Estatística e Experimentação Agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 2002.

SANDERSON, R. A.; EYRE, M. D.; RUSHTON, S. P.; Distribution of selected macroinvertebrates in a mosaic of temporary and permanent freshwater ponds as explained by autologistic models **Ecography**, Lund, v. 28, p. 355-362, 2005.

TETERUKOVSKIY, A.; EDEMIRS, L. Effective field sampling for predicting the spatial distribution of reindeer (Rangifer tarandus) with help of the gibbs sampler **A Journal of the Human Environment**, Stockholm, v.32, p.568-572, 2003.

UPTON, G.; FINGLETON, B. **Spatial Data Analysis by Example**, New York: Wiley, 1985. 422p.

WU, H; HUFFER, F. W. Modelling distribution of plant species using the autolologistic regression model. **Environmental and Ecological Statistics**, London, v.4, p.49-64, 1997.

ZAMBOTI, J. L. **Mapas pluviométricos médios mensais no verão para o Estado do Paraná, utilizando métodos geoestatísticos**. 2001. 134p. Dissertação (Mestrado em Agronomia / Energia na Agricultura) - Faculdade de Ciências Agronômicas, Universidade Estadual Paulista, Botucatu, 2001.

2 DETECÇÃO DE PADRÕES ESPACIAIS NA OCORRÊNCIA DO TRIPES DO PRATEAMENTO NA CULTURA DA CEBOLA

Resumo

A cebola é uma das hortaliças mais cultivadas e consumidas no Brasil e sua importância social se deve à grande demanda por mão-de-obra. Uma das principais pragas que afeta essa cultura é o tripes do prateamento (*Thrips tabaci*) e sua distribuição espacial, embora importante, não tem sido considerada nas recomendações de manejo da cultura, planejamento de experimentos ou estudos amostrais. Para caracterizar o padrão espacial da dispersão do tripes do prateamento da cebola foi feito um levantamento anotando-se o número de insetos por fase de desenvolvimento em folhas de plantas de cebola, em diferents datas e pontos amostrais dentro de quatro propriedades com fazendas vizinhas apresentando diferentes níveis de infestação e métodos de plantio. O teste de aleatorização de Mantel foi utilizado para testar a presença de padrão espacial, que quando detectado foi descrito por um modelo de Poisson misto espacial com componente aleatório geoestatístico. Tal modelo possibilitou a caracterização do padrão espacial bem como a obtenção de mapas de predição dos níveis de susceptibilidade à infestação na área.

Palavras-chave: Tripes do prateamento; Cebola; Testes de aleatorização; Geoestatística; Distribuição de Poisson.

Abstract

Onion is one of the most cultivated and consumed vegetables in Brazil and its importance is due to the large workforce involved. One of the main pests that affect this crop is the onion thrips (Thrips tabaci), but the spatial distribution, although important, has not been considered in crop management recommendations, experiment planning or sampling plans. In order to characterize the spatial distribution pattern of the onion thrips a survey was carried out to record the number of insects in each development phase on onion plant leaves, on different dates and sample locations, in four rural properties with neighboring farms with different infestation levels and planting methods. The Mantel randomization test was used to test for spatial correlation, and when detected this was modelled by a mixed spatial Poisson model with a geostatistic random component. This model has allowed a spatial pattern characterization as well as the production of prediction maps of susceptibility to levels of infestation in the area.

Keywords: Onion Thrips; Onion; Randomization tests; Geostatistics; Poisson distribution.

2.1 Introdução

A cebola é uma das hortaliças mais cultivadas e consumidas no Brasil e sua importância social se deve à grande demanda por mão-de-obra. Estima-se que 70% da produção seja proveniente da agricultura familiar, pois é típica de pequenas e médias propriedades. É uma planta anual para

a produção de bulbos e bianual para a produção de sementes. Seu plantio pode ser feito por semeadura direta, por bulbinhos ou por mudas cultivadas em canteiros e transplantadas para o campo.

Uma das principais pragas da cebola é o tripes do prateamento (*Thrips tabaci*) que em altos níveis de infestação prejudica a colheita (WORKMAN; MARTIN, 2002) que pode ser reduzida em até 80% nas épocas quentes e secas (COSTA; MEDEIROS, 1950 e SATO, 1989).

Esse inseto é encontrado na base das folhas e se alimenta da seiva e do parênquima foliar provocando manchas cinzentas que depois se tornam prateadas como resultado da destruição dos tecidos externos das folhas. Ataques severos da parte aérea da planta causam perda na produção dos bulbos, que têm tamanho diminuído e pior qualidade, o que prejudica a comercialização e dificulta sua exportação (COSTA; MEDEIROS, 1950). Quando o ataque é muito intenso, as folhas ficam amareladas, secas e com a extremidade retorcida causando a murcha e a morte da planta (SATO, 1989) e facilitando a entrada de água até o bulbo, que apodrece. O inseto é considerado ainda vetor de agente fitopatogênico por ter a capacidade de transmitir virose para a planta.

O desenvolvimento desse inseto ocorre em quatro fases: ovo, ninfa, pupa e adulto, sendo que a ninfa e o adulto são os que de fato causam prejuízos à produção, pois a fase de pupa desenvolve-se no solo. A ninfa apresenta baixa mobilidade, enquanto o adulto, embora alado, tem movimentação restrita. Tipicamente, o ciclo total de vida varia de 14 a 30 dias passando para 10 a 11 dias quando a temperatura é superior a 30°C.

A distribuição espacial de tripes em campos comerciais é importante, por exemplo, para aplicação racional de inseticidas. Entretanto, não tem sido considerada nas recomendações de manejo da cultura, planejamento de experimentos e estudos amostrais, sendo escassa literatura a esse respeito. Acredita-se que o principal fator de dispersão do tripes, e potencialmente determinante na ocorrência de padrões espaciais, é o vento, pois as ninfas são ápteras e os adultos, embora alados, possuem asas rudimentares.

Numa caracterização inicial, o padrão espacial de dispersão de insetos pode ser classificado como aleatório, agregado ou regular. O aleatório ocorre quando, em condições naturais, há oportunidades iguais de infestação para todas as plantas, enquanto que o padrão agregado está associado à pequena mobilidade do inseto. O padrão regular raramente ocorre de forma natural, mas pode ser induzido pelo plantio alternado de plantas resistentes e susceptíveis. Para estudar se o padrão de dispersão de leucemia infantil era aleatório, Mantel (1967) propôs um teste de aleatorização, baseado nas matrizes de distância entre as observações. Entretanto, não foram encontradas aplicações no estudo de dispersão de insetos e, em particular, do tripes do prateamento.

Por outro lado, é muito comum, no estudo da dispersão de insetos, encontrar o uso de índices baseados na relação entre variância e média, tais como o índice de David & More, a lei de poder de Taylor, os índices de agregação de Lloyd e Iwao, dentre outros (RUIZ et al., 2003). Entretanto, esses índices ignoram a localização espacial das amostras, tendo capacidade limitada de descrição de

padrões espaciais, além de dependerem fortemente do tamanho das unidades amostrais (UPTON; FINGLETON, 1985).

Métodos geoestatísticos (ISAAKS; SRISVARTAVA, 1989; GOOVAERTS;1997) têm sido usados para descrever os padrões espaciais de insetos como por exemplo em Greco, Vieira e Lourenção, 2006. Tais métodos foram originalmente desenvolvidos para variáveis aleatórias contínuas com diversas implementações computacionais disponíveis. A variável contagem de insetos é discreta e tipicamente distribuída em aglomerados e com excesso de valores iguais a zero. Logo, os dados de contagens podem não ter a estrutura de covariância assumida pelos métodos tradicionais da análise geoestatística que tem uma estrutura de covariância espacial estacionária na área (RUIZ, 2002). Portanto, é recomendável adotar modelos que incorporem explicitamente o mecanismo gerador dos dados, tais como, neste caso, modelos com distribuição de Poisson para dados de contagem combinados com estruturas que descrevam o padrão espacial. Modelos desse tipo propostos na literatura estatística (e.g. DIGGLE; TAWN; MOYEED, 1998) ainda encontram poucas aplicações na análise de dados.

Neste artigo, faz-se um estudo da distribuição espacial do tripes do prateamento da cebola a partir de dados provenientes de um levantamento realizado em quatro propriedades, considerando-se diferentes níveis de infestação e métodos de plantio nas fazendas vizinhas. O teste de aleatorização de Mantel (MANLY, 2006) foi utilizado para testar a presença de padrão espacial, que quando detectado foi descrito por um modelo de Poisson misto espacial com componente aleatório geoestatístico. Tal modelo possibilitou a caracterização do padrão espacial bem como a obtenção de mapas de predição dos níveis de susceptibilidade à infestação na área.

O restante deste artigo está organizado como se segue. A Seção 2.2.1 descreve os dados a serem utilizados, enquanto que a Seção 2.2.2 traz uma revisão do teste de aleatorização de Mantel para a detecção do padrão espacial e apresenta um modelo de Poisson misto espacial com componente aleatório geoestatístico. Resultados obtidos são apresentados e discutidos na Seção 2.2.3. Finalmente, são feitas algumas considerações finais na Seção 2.3.

2.2 Desenvolvimento

2.2.1 Material

Este trabalho é motivado por um conjunto de dados provenientes de um estudo por amostragem do tripes do prateamento em cultura de cebola, em quatro propriedades, localizadas no Município de São José do Rio Pardo, interior do Estado de São Paulo, no período de junho a setembro de 1996. O objetivo é estudar a distribuição espacial do tripes. As quatro propriedades escolhidas usaram o híbrido Granex 33 de cebola e o método de plantio por mudas. As áreas

experimentais foram escolhidas com vizinhos que adotavam diferentes tipos de plantio e tinham diferentes níveis de infestação.

Detalhes referentes a tipo de plantio vizinho e data das coletas e número de amostras por coletas nas diferentes propriedades são mostrados na Tabela 2.1. A Fazenda São Paulo está localizada em um ponto alto da região e o plantio de cebola mais próximo se encontrava a uma distância de pelo menos um quilômetro. Nas áreas vizinhas à Estância Bela Vista já havia culturas atacadas pela praga do tripes do prateamento.

Tabela 2.1 – Detalhes sobre a origem dos dados, tipos de plantios vizinhos, datas de coletas e números de amostras

Propriedade Plantios vizinhos		Datas das Coletas	Nº de Amostras	
Fazenda	isolada de	10/7, 24/7, 31/7, 7/8,	100, 100, 100, 98	
São Paulo	outros plantios	14/8, 21/8, 28/8, 04/9	100, 100, 100, 100	
Estância	bulbinhos	11/7, 1/8, 8/8,	100, 100, 84	
Bela Vista		14/8, 9/9	99, 99	
Sítio	mudas	21/6, 29/6, 7/7, 14/7, 21/7,	50, 50, 48, 50, 50,	
Rosário		28/7, 4/8, 11/8, 18/8, 25/8, 3/9	50, 50, 50, 50, 50, 50	
Sítio	mudas	4/6, 19/6, 27/6, 28/6,	100, 100, 100, 100	
Novo II		4/7, 11/7, 24/7, 31/7, 7/8	100, 100,100 ,100 ,100	

A unidade amostral foi um círculo de 1m de raio com uma estaca no centro sendo sorteada uma planta em cada data de amostragem. A Figura 2.1 mostra a posição das estacas nas quatro propriedades estudadas, em geral, com um espaçamento de referência nas linhas e colunas de 10 em 10 metros, com algumas variações na Fazenda São Paulo. As variáveis medidas foram a localização das estacas no eixo das coordenadas, o número de ninfas, o número de insetos adultos e o número de folhas por planta. A listagem completa do número de insetos dado pela soma de ninfas e adultos por folha, encontra-se no Apêndice A.

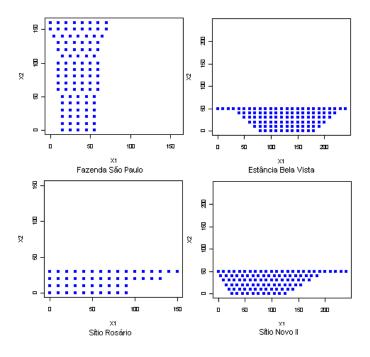


Figura 2.1 – Localização das estacas centrais dos círculos de 1m de raio, em quatro propriedades

Pode-se ver pela Tabela 2.1 que as coletas dos insetos foram feitas em números e épocas distintas nas quatro propriedades e que as variáveis respostas são discretas dadas pelas contagens de ninfas e adultos. Na coleta dos dados, em alguns casos, as contagens de insetos foram registradas apenas como múltiplos de 5 ou 10 e as contagens acima de 100 foram registrados iguais a 100 havendo ainda casos de dados faltantes.

A Figura 2.2 mostra diagramas *box-plot* para o número médio de insetos por folha, nas quatro propriedades, para as diversas coletas, enquanto que estatísticas descritivas estão nas Tabelas 3.5 a 3.8 do Anexo A. Vê-se, em todos os casos, que há uma variabilidade grande e aparentemente não existe um padrão ao longo do tempo, com exceção da Fazenda São Paulo, em que o número médio de insetos e a variabilidade aumentam com o tempo enquanto que nos outros casos, a média aumenta e depois diminui. Em todos os casos nota-se que as observações estão mais dispersas acima da mediana, apresentando assimetria positiva e ainda valores discrepantes na maioria dos casos.

Na Fazenda São Paulo, observa-se que o dia 31/07 apresentou média menor de insetos por folha e também menor variância, tendo um inseto por folha como valor máximo, enquanto que o dia 04/09 apresentou uma maior média de insetos por folha e também a maior variabilidade. Verifica-se ainda, que essa propriedade apresenta menor proporção de plantas infestadas, variando de 35% a 89%, com exceção do dia 04/09 em que todas as plantas estavam infestadas. Para a Estância Bela Vista, observa-se que as menores médias de insetos por folha ocorreram nos dias 11/07 e 14/08, e essa propriedade foi a que mostrou maior proporção de plantas infestadas, variando de 89% a

100%, sendo que em três datas de coleta, todas as plantas estavam infestadas. O Sítio Rosário foi o que apresentou menor variabilidade, apresentando também a maior média de insetos por folha nos dias 11 e 18 de agosto. Ressalta-se porém que nessa propriedade foram observados apenas 50 pontos. No Sítio Novo II foram observadas as menores médias para o número de insetos por folha e menores variabilidades nas médias.

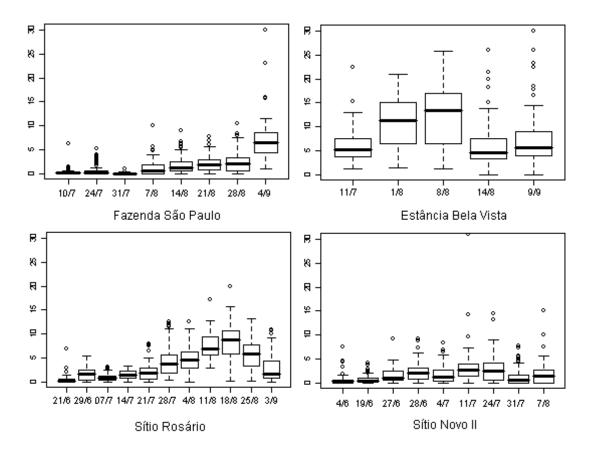


Figura 2.2 – Box-Plot do número médio de tripes por folha de cebola

2.2.2 Métodos

Teste de Mantel para detecção de padrão espacial

A não existência de padrão espacial na dispersão dos insetos pode ser considerada como hipótese de aleatoriedade, pois pode testar a existência de um padrão espacial através da aleatorização da ordem dos dados observados (MANLY, 2006).

Os testes de aleatorização têm como base o fato que, se a hipótese de nulidade é verdadeira, todas as possíveis ordens para os dados têm a mesma chance de ocorrer. Assim, para um conjunto de observações calcula-se o valor e_o de uma estatística E e a seguir, faz-se um número grande de aleatorizações que no contexto de dados espaciais são dadas por reordenações aleatórias dos dados,

obtendo-se valores e_a que irão gerar uma aproximação por simulação da distribuição amostral de E. Assim, como em testes estatísticos clássicos, a decisão é guiada por um valor - p que no caso de testes aleatorizados é dado pela proporção dos valores e_a que são maiores do que ou iguais a e_o . Por exemplo, se p < 0,05, conclui-se que existe uma forte evidência de que a hipótese de nulidade não seja verdadeira ao nível de 5% de probabilidade (MANLY, 2006).

Testes aleatorizados possuem algumas características particulares em comparação a testes estatísticos clássicos. Como vantagens dos testes de aleatorização, em geral, são relativamente fáceis de serem calculados, são baseados em estatísticas não padronizadas e não necessitam de informações prévias a respeito da população da qual a amostra foi retirada. Além disso, podem ser aplicados em amostras não aleatórias que podem consistir simplesmente de itens que precisam ser analisados (MANLY, 2006). Entretanto, os testes de aleatorização são mais facilmente justificados quando as amostras analisadas são aleatórias ou o próprio delineamento experimental sugere um teste de aleatorização. À primeira vista podem parecem ser pouco rigorosos, pois nem sempre é possível generalizar as conclusões obtidas, sendo a sua construção específica para cada conjunto de dados e tipo de problema.

No contexto de dados espaciais, em geral, deseja-se testar a hipótese nula de padrão espacial aleatório versus a alternativa de padrão espacial não aleatório. Um teste para tal hipótese foi proposto por Mantel (1967) que permite estudar, a partir da configuração dos pontos observados, se a dispersão dos insetos segue um padrão aleatório. O teste é implementado como se segue. Seja uma variável observada em n localizações. Obtêm-se duas matrizes A e B, de dimensões $n \times n$, simétricas, cujos elementos representam distâncias, em alguma métrica, entre as observações.

$$A = \begin{pmatrix} 0 & a_{21} & \dots & a_{n1} \\ a_{21} & 0 & \dots & a_{n2} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & 0 \end{pmatrix} \quad e \quad B = \begin{pmatrix} 0 & b_{21} & \dots & b_{n1} \\ b_{21} & 0 & \dots & b_{n2} \\ \dots & \dots & \dots & \dots \\ b_{n1} & b_{n2} & \dots & 0 \end{pmatrix}$$

sendo que aqui A é a matriz das distâncias Euclidianas entre os pontos com localizações dadas por (x_{1i},x_{2i}) e (x_{1j},x_{2j}) , isto é, com elementos $a_{ij}=\sqrt{(x_{1i}-x_{1j})^2+(x_{2i}-x_{2j})^2}$ e B é a matriz com elementos $b_{ij}=\sqrt{(z_i-z_j)}^2$, em que Z é número médio de insetos por folha. A estatística teste é dada pelo coeficiente de correlação de Pearson entre os elementos correspondentes de A e B, isto é,

$$r = \frac{m \sum_{i < j} a_{ij} b_{ij} - \sum_{i < j} a_{ij} \sum_{i < j} b_{ij}}{\sqrt{[m \sum_{i < j} a_{ij}^2 - (\sum_{i < j} a_{ij})^2][m \sum_{i < j} b_{ij}^2 - (\sum_{i < j} b_{ij})^2]}},$$
(2.1)

que produz o valor r_o quando calculada para os valores observados. A seguir permutam-se linhas e colunas de uma das matrizes, um número N suficientemente grande, e obtêm-se os valores r_{ak} , para $k=1,2,\ldots N$. A proporção p de valores $r_{ak} \geq r_o$, é comparada com um valor de nível de significância pré-fixado α (por exemplo, 0,05) e rejeita-se a hipótese nula se $p < \alpha$ (MANLY, 2006).

Sendo as matrizes A e B simétricas, a correlação entre todos os elementos fora da diagonal principal é a mesma que a correlação de m=n(n-1)/2 elementos na parte triangular superior ou inferior da matriz. Note-se ainda que o único termo de (2.1) que é alterado pela mudança da ordem dos elementos em uma das matrizes A ou B é a soma de produtos $Z=\sum a_{ij}b_{ij}$.

Outras possíveis métricas utilizadas para o cálculo das distâncias são *Euclidiana com dados* padronizados, *Euclidiana quadrática*, *Euclidiana quadrática com dados padronizados*, *distância* proporcional e diferença amostral para procedimentos de permutação de respostas múltiplas. Esse teste assume que a correlação na métrica adotada é linear e alternativas incluem as propostas de Besag-Diggle, de Edgington, Monte Carlo, dentre outros (MANLY, 2006). Uma outra proposta é dada por Snäll, Ribeiro Jr. e Rydin (2003) que constroem um teste aleatorizado usando formas flexíveis para relação entre as medidas de distâncias dadas pela estrutura de modelos generalizados aditivos.

Quando o teste de Mantel rejeita a hipótese de nulidade, pode haver interesse em se detectar qual o tipo de associação existente entre as variáveis e isso pode ser mostrado pelo gráfico de b_{ij} versus a_{ij} . Um dos possíveis modelos de associação é a regressão linear simples, em que os elementos da matriz A entram como variável explanatória e os elementos da matriz B como variável resposta, isto é,

$$b_{ij} = \beta_0 + \beta_1 a_{ij} + \epsilon_{ij}$$

em que β_0 e β_1 são parâmetros a serem estimados e ϵ_{ij} é o erro associado à resposta. Entretanto, formas mais complexas de dependência espacial podem ocorrer.

Neste trabalho, o teste de aleatorização para padrões espaciais foi calculado considerandose as observações em cada data de coleta. O teste pode, a princípio ser estendido para detecção de padrões temporais, porém isto levanta a questão de como combinar informações da diversas unidades de observação. Embora tal alternativa tenha sido verificada para os dados de occorrência de tripes optou-se por não incluir os resultados aqui dado o pequeno número de observações no tempo e o não haver interesse específico em testar padrões temporais.

Modelagem do padrão espacial

Uma vez detectado o padrão espacial, o passo seguinte é tentar descrever tal padrão por algum modelo, usualmente assumindo como estocástico. Tal modelagem permite não apenas caracterizar

o padrão de dependência mas também utilizá-lo para obter predição de quantidades de interesse no problema em questão, tais como mapas do comportamento da variável na área, proporção na área com infestação acima de um determinado limiar, maiores valores de infecção e sua localização, entre outros.

Uma possível forma de modelar a distribuição espacial é dada pelas técnicas geoestatísticas, que associam o grau de dependência espacial a medidas de distância e direção entre os pontos amostrados. A descrição da dependência espacial, usualmente, assume que os pontos amostrados mais próximos são mais parecidos do que pontos mais distantes (MONTAGNA, 2001). Diggle, Ribeiro Jr e Christensen (2003) afirmam que o termo geoestatística é utilizado para identificar uma parte dos métodos de estatística espacial na qual o modelo utilizado descreve uma variação contínua das observações no espaço.

O formato básico de dados geoestatísticos univariados é dado por (x_i, y_i) , i = 1, 2, ..., n, em que $x_i = (x_{1i}, x_{2i})$ identifica a localização espacial, em geral, no espaço bidimensional e y_i é a medida escalar na posição x_i da i-ésima observação. Tem-se ainda que y pode ser medido a princípio em qualquer lugar da região estudada (DIGGLE; RIBEIRO JR., 2007).

O modelo geoestatístico é especificado por: [S,Y] = [S][Y|S], em que: $Y(x): x \in A$ é o processo de medida e y_i são os dados observados; $S = \{S(x) : x \in \mathbb{R}^2\}$ é um processo gaussiano com média μ , variância σ^2 e função de correlação $\phi(u)$ sendo u a distância entre pares de observações. S(x) é chamado de *sinal* e seus valores usualmente não são diretamente observados, x é a posição da observação no espaço; A é um subconjunto fixo de pontos no \mathbb{R}^d em que d é a dimensão do espaço que aqui será tomada como d=2 (DIGGLE; MOYEED; TAWN, 1998; DIGGLE; RIBEIRO JR., 2007). As observações Y_i podem ser vistas como uma versão com ruído de $S(x_i)$ para um conjunto de localizações x_i . Geralmente, assume-se que o delineamento de amostragem para as posições x_i é fixo ou estocasticamente independente do processo que gera as medidas de y_i . No caso de Y com distribuição gaussiana, o modelo, pode ser escrito como $Y_i = S(x_i) + Z_i$, em que Z_i são mutuamente independentes e seguem distribuição normal, com média 0 e variância τ^2 (DIGGLE; RIBEIRO JR., 2007) e para um conjunto finito de pontos o vetor aleatório Y segue uma distribuição gaussiana multivariada. Entretanto, de forma mais geral Y pode seguir outras distribuições. Diggle Tawn e Moyeed (1998) especificam tal modelo dentro da classe de modelos lineares generalizados (McCULLAGH e NELDER, 1989) em que o processo S define efeitos aleatórios com estrutura de dependência espacial chamado por Diggle e Ribeiro (2007) de modelo linear generalizado geoestatístico. Tal modelo permite então especificar explicitamente uma distribuição de Poisson para as observações o que é compatível com a estrutura de dados de contagem de insetos considerada neste trabalho.

O modelo linear generalizado geoestatístico é um caso particular de modelo linear generalizado misto em que os Y_i , $i=1,2,\ldots,n$ condicionais a S(x) são mutuamente independentes com

esperança $E[Y_i|S(x)] = \lambda_i$ e preditor linear $h(\lambda_i) = S(x_i)$, i = 1, 2, ..., n para uma função de ligação $h(\cdot)$ conhecida, sendo que o sinal do processo é $\{h^{-1}(S(x)) : x \in A\}$ e, no caso de presença de covariáveis estende-se com $S(x_i) = S(x) + d(x)^T \beta$, em que β é o vetor dos parâmetros de regressão (DIGGLE; MOYEED; TAWN, 1998, DIGGLE; RIBEIRO JR.; CHRISTENSEN, 2003).

Supondo-se que o número total de insetos $Y(x_i)|S(x_i)$ tem distribuição de Poisson com média $t_i \exp(S(x_i)), i=1,2,\ldots,n$, em que t_i representa os números de folhas, tem-se que

$$P[Y(x)|S(x) = y(x_i)] = \frac{e^{-t_i e^{S(x_i)}} \left(t_i e^{S(x_i)}\right)^{y(x_i)}}{y(x_i)!}.$$

Neste modelo função de verossimilhança, não é expressa de forma fechada, sendo descrita pela integral

$$L = \int \prod_{i=1}^{n} \frac{e^{-t_{i}e^{S(x_{i})}} \left(t_{i}e^{S(x_{i})}\right)^{y(x_{i})}}{y(x_{i})!} \cdot \frac{1}{\sqrt{2\pi\sigma^{2}}|R|} e^{\frac{-1}{2\sigma^{2}}(S(x_{i})-\mu_{i})'R(S(x_{i})-\mu_{i})} ds, \tag{2.2}$$

que tem dimensionalidade igual ao número de observações, e não tendo solução explícita. Uma possível solução é utilizar Cadeias de Markov via Monte Carlo (MCMC). Uma implementação computacional é disponibilizada pelo pacote geoRglm (CHRISTENSEN; RIBEIRO JR., 2002) do ambiente estatístico R (http://www.R-project.org).

No caso de variáveis aleatórias discretas, o variograma é um resumo menos natural dos dados, mas pode ser útil como ferramenta para diagnóstico, após o ajuste do modelo linear generalizado misto (DIGGLE; RIBEIRO JR, 2007). Nesse caso, compara-se o variograma ajustado com o variograma experimental, obtido através dos resíduos. Os variogramas experimental e ajustado são dados, respectivamente por:

$$\gamma_Y(h) = \frac{1}{2} Var\{Y(x)\} + \frac{1}{2} Var\{Y(x+h)\} - Cov\{Y(x), Y(x+h)\}.$$

e

$$\gamma_Y(h) = \exp(\beta + \frac{\sigma^2}{2}) + \exp(2\beta + \sigma^2)[\exp(\sigma^2) - \exp\{\sigma^2\rho(u)\}].$$

Porém, deve-se avaliar com parcimônia tal diagnóstico pois o variograma é neste caso ainda mais errático do que o usualmente obtido para dados com distribuição contínua e simétrica, uma vez que é gerado por dados assimétricos, sendo portanto, aconselhado para orientar as análises e não como ferramenta para obtenção de estimativas dos parâmetros.

Após a escolha de um determinado modelo, em geral, há interesse na construção de um mapa de predição que descreva o comportamento da variável na região, ou qualquer outra quantidade de interesse que possa ser obtida a partir de tais mapas. Assumindo, inicialmente, que se conhecem os parâmetros e que o interesse está na intensidade de insetos dada por $\lambda(x_0) = \exp(\beta + S(x_0))$, para o local $x_0 = (x_{10}, x_{20})$, com a distribuição marginal de S e a distribuição condicional de Y|S podese simular a distribuição condicional de [S|y], através do método MCMC. A superfície predita é dada por (DIGGLE; MOYEED; TAWN, 1998):

$$\hat{\beta} + \hat{S}(x) + \frac{Var(x)}{2},$$

sendo que, $\hat{\beta}$ é a média do processo, nesse caso, pois não existem covariáveis explanatórias nem tendência; $\hat{S}(x)$ é o preditor linear de krigagem e Var(x) é a variância da predição.

2.2.3 Resultados e discussão

Detecção de padrão espacial através do teste de aleatorização de Mantel

Para a Fazenda São Paulo os valores de *p* do teste de Mantel obtidos para cada uma das datas de coletas foram **0,0228**, **0,0022**, **0,0235**, 0,0588, 0,1005, 0,0749, 0,1297 e 0,5540 e, portanto, detectando padrão espacial para o número de insetos por folha apenas nos dias 10, 24 e 31 de julho. Tal padrão pode ser observado no gráfico de pontos (Figura 2.3) em que diferente símbolos indicam os quartis de distribuição dos dados. De forma geral, para todas as propriedades e datas a distribuição do número médio de insetos por folha é assimétrica e aparentemente não apresenta tendência com as coordenadas da região. Adicionalmente, a regressão linear entre distâncias do número de insetos por folhas e as distâncias da localização das estacas, mostra que, para essas datas, existe evidência de associação positiva, conforme Tabela 2.2 que mostra ainda os resultados análogos para datas em que foi detectado padrão espacial nas demais propriedades consideradas neste estudo.

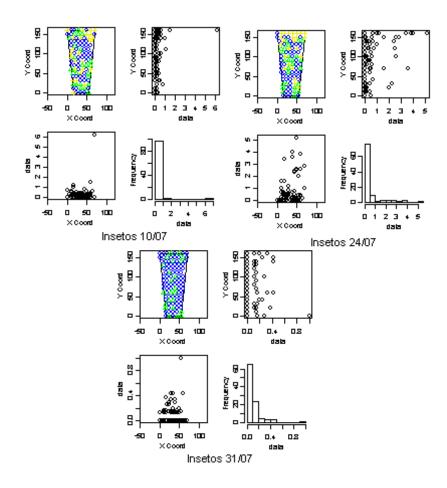


Figura 2.3 – Gráficos de dispersão e histogramas para o número médio de insetos na Fazenda São Paulo

Tabela 2.2 – Modelos de regressão ajustados às matrizes de distâncias do teste de aleatorização

Prorpiedade	Data	Modelo	p
Fazenda SãoPaulo	10/07	Insetos/folha=0,2102+0,002325loc	0,0205
	24/07	Insetos/folha=0,6024+0,004216loc	0,0022
	31/07	Insetos/folha=0,0932+0,000417loc	0,0264
Estância Bela Vista	08/08	Insetos/folha=6,2180+0,009037loc	0,0334
Sítio Novo II	04/06	Insetos/folha=0,3035+0,007206loc	0,0012
	27/06	Insetos/folha=1,1810+0,004034loc	0,0258
	04/07	Insetos/folha=1,5240+0,0033711oc	0,0455

Para a Estância Bela Vista os valores de p obtidos para o teste de Mantel feito para cada uma das coletas foram 0,8986, 0,0902, **0,0338**, 0,7880 e 0,6224 e, portanto, detectando padrão espacial apenas para o dia 08 de agosto. Diagramas resumo dos dados para essa data são mostrados na Figura 2.4. No caso de Sítio Rosário, os valores de p obtidos para o teste de Mantel foram 0,5309,

0,5961, 0,9236, 0,9512, 0,9412, 0,7297, 0,3223, 0,1897, 0,2771, 0,1771 e 0,7020, portanto, sem evidência de padrão espacial em todas as datas. Finalmente, para Sítio Novo II os valores de p obtidos para o teste de Mantel foram **0,0006**, 0,6127, **0,0251**, 0,7326, **0,0478**, 0,4781, 0,0651, 0,6084 e 0,4264 com padrão espacial detectado em 04 e 27 de junho e 04 de julho cujos dados estão representados na Figura 2.5.

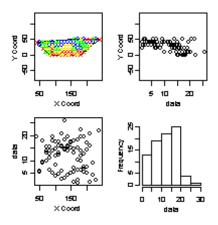


Figura 2.4 – Gráficos de dispersão e histogramas para o número médio de insetos - Estância Bela Vista

Para as propriedades e datas em que há evidência de padrão espacial nos dados foi feita a modelagem espacial através do modelo linear generalizado geoestatístico com distribuição de Poisson e função de ligação logarítmica. Foram obtidos intervalos de confiança para os parâmetros com estimativas de máxima verossimilhança obtidas pelo algoritmo de MCMC. Obteve-se uma cadeia de 50.000 iterações, com ciclo de pré-convergência (burn in) de 10.000 e sendo armazenada uma amostra a cada vinte amostras geradas, perfazendo um total de 2.500 amostras. Esse processo foi repetido 1.000 vezes e, através das 1.000 estimativas obtidas, foram calculados os intervalos de confiança para os quantis 2,5% e 97,5%. Os resultados obtidos são resumidos na Tabela 2.3. As cadeias obtidas para cada parâmetro foram analisadas para verificar a convergência do algoritimo de MCMC. Os intervalos de confiança para o parâmetro ϕ , que reflete a extensão da dependência espacial apresenta grande amplitude, refletindo a dificuldade em estimar esse parâmetro com precisão a partir de dados esparsos. No caso do modelo de função de correlação exponencial, o alcance prático de correlação corresponde a três vezes o valor desse parâmetro. A interpretação do valor desse parâmetro depende dos valores de distâncias entre pontos que variaram de 10 a 170 metros na Fazenda São Paulo, 10 a 200 metros na Estância Bela Vista, 10 a 204 metros em Sítio Novo II. Observa-se ainda que existem três casos em que a estimativa é menor do que a distância mínima.

Observa-se, também, que a amplitude dos intervalos para β e σ^2 são pequenas. Tem-se ainda que β é o parâmetro associado à função de ligação e σ^2 , ϕ e τ^2 são parâmetros associados à superfície S(x). Valores negativos para o parâmetro β na Fazenda São Paulo refletem o fato de que

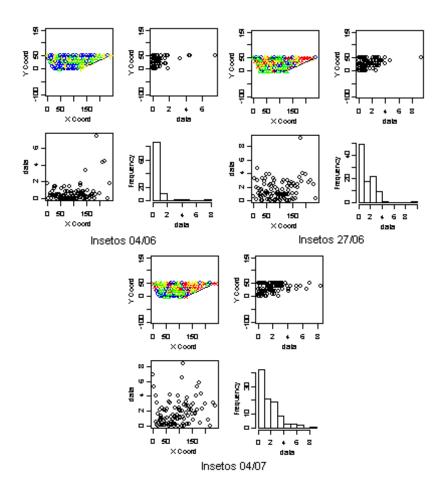


Figura 2.5 – Gráficos de dispersão e histogramas para o número médio de insetos - Sítio Novo II

essa Fazenda estava isolada de outros plantios de cebola, resultando em baixas médias de infestação. Valores altos das estimativas foram observados na Estância Bela Vista, que estava rodeada por plantio de cebola infestados pelo tripes. Em Sítio Novo II, as estimativas foram próximas a zero como reflexo das baixas médias para número de insetos por folha.

Tabela 2.3 – Estimativas pontuais e intervalos de confiança para os parâmetros do modelo geoestatístico

Prorpiedade	Data	β	σ^2	ϕ	$ au^2$	LogMV
Fazenda São Paulo	10/07	-0,6302	0,2763	3,7852	0,0000	231,2
		(-0,57; -0,46)	(0,03; 0,34)	(0,57; 36,86)	(0,00; 7,04)	
	24/07	-0,5123	0,3773	13,1430	0,5781	186,5
		(-0,81; -0,62)	(0,16; 1,01)	(5,67; 82,86)	(0,00; 5,40)	
	31/07	-0,9424	0,2550	1,0000	0,0000	320,6
		(-0,97; -0,88)	(0,04; 0,30)	(0,56; 16,04)	(0,00; 5,31)	
Estância Bela Vista	08/08	2,3522	0,1994	14,2512	0,9220	127,5
		(2,34; 2,38)	(0,18; 0,28)	(10,72; 21,19)	(0,39; 1,28)	
Sítio Novo II	04/06	-0,4212	0,5535	1,0002	0,0000	160,7
		(-0,45; -0,15)	(0,07; 0,58)	(0,57; 110,18)	(0,00; 5,94)	
	27/06	0,2341	0,2233	23,6466	2,0880	55,53
		(0,14;0,25)	(0,14; 0,73)	(5,60; 40,50)	(0,00; 4,28)	
	04/07	0,2697	0,2660	23,5905	2,3366	51,63
		(0,20; 0,30)	(0,22; 0,46)	(13,68; 37,71)	(0,90; 3,08)	

O resumo e o gráfico de convergência dos parâmetros estão no Anexo. Pode-se observar que houve uma boa convergência dos parâmetros, apesar desses apresentarem alta variabilidade em alguns casos.

A partir dos modelos ajustados foram construídos os mapas de predição para as áreas estudadas. Comparando o mapa de predição mostrado nas figuras Figura 2.6, Figura 2.7 e Figura 2.8, em que tonalidades mais claras indicam baixa infestação enquanto que as tonalidades mais escuras indicam maior infestação, com o gráfico de pontos das figuras Figura 2.3, Figura 2.4 e Figura 2.5, observa-se que o primeiro detalha o comportamento mostrado no segundo, uma vez que as áreas de alta e baixa infestação são as mesmas.

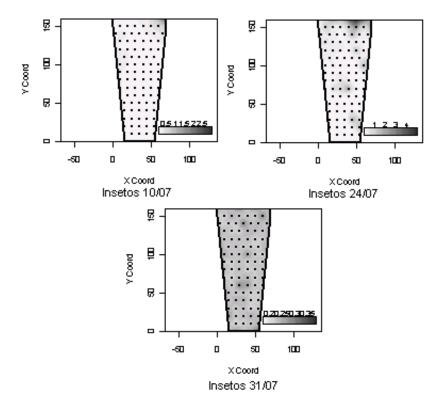


Figura 2.6 – Mapa de predição - Fazenda são Paulo

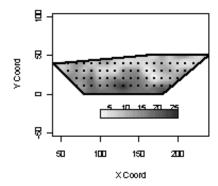


Figura 2.7 – Mapa de predição para Estância Bela Vista

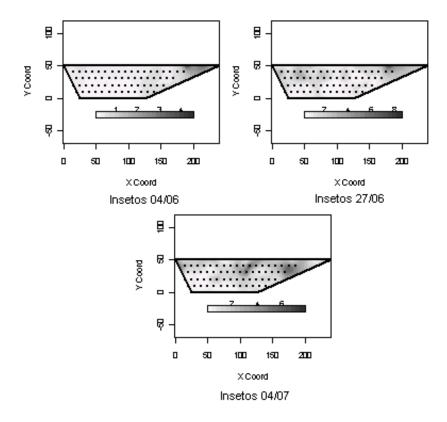


Figura 2.8 – Mapa de predição para Sítio Novo II

2.3 Conclusões

As metodologias apresentadas e utilizadas aqui permitiram testar a presença de padrões espaciais na distribuição do tripes do prateamento, bem como sugerir mecanismos que podem ser usados como possíveis descrições de tais processos. No primeiro caso, o teste de aleatorização de Mantel mostrou-se bastante satisfatório para a verificação do padrão espacial aleatório enquanto que o modelo linear generalizado geoestatístico fornece um possível modelo para os dados e uma forma natural para acomodar em sua estrutura relações com covariáveis que possam afetar a distribuição do inseto. A combinação e o emprego de tais métodos é nova no contexto da aplicação considerada e os resultados aqui obtidos sugerem que este ferramental de análise deve ser considerado para detecção e descrição dos padrões espaciais de pragas em condições de campo.

O padrão espacial, embora detectado em algumas datas de coleta, não foi consistentemente indicado pelo teste aleatorizado. As análises exploratórias dos dados indicaram que a hipótese de presença de padrão espacial é razoável para o fenômeno. Entretanto, a sua não detecção em certos casos pode ser atribuída à grande variabilidade das observações com possível efeito da forma imprecisa como os dados de valores mais elevados foram anotados. Além disso, efeitos de covariáveis não medidas podem ter gerado condições heterogêneas de coleta que terminaram por mascarar o padrão espacial.

Aparentemente, existe influência do tipo de plantio na vizinhança sobre o número de insetos por folha na planta, pois a Estância Bela Vista, que tinha na vizinhança área plantada no sistema bulbinho, já infestada de tripes, foi a que apresentou maiores médias para o número de insetos por folha e maiores proporções de plantas infestadas. A Fazenda São Paulo, isolada de outros plantios de cebola, foi a que apresentou a menor proporção de plantas infestadas, sendo que, essa proporção, no geral, foi aumentando no decorrer do tempo, indicando que possa realmente haver influência da infestação das plantas vizinhas. Tal conjectura não pode ser testada estatisticamente com os dados disponíveis mas deve ser considerada para investigação em estudos futuros.

Recomenda-se ainda que a amostragem seja realizada incluindo algums pares de observações com espaçamentos menores, possibilitando assim uma melhor capacidade de descrição dos padrões espaciais o que é especialmente relevante considerando-se a limitada mobilidade deste inseto.

Referências

CHRISTENSEN, O. F.; RIBEIRO JR., P.J. **geoRglm**: A package for generalised linear spatial models. **R-NEWS**, Vienna, v.2, p.26-28, 2002.

COSTA, A. A.; MEDEIROS, Z. P. O piolho da cebola (Thrips Tabaci Lindeman). **Agronomia**, Rio de Janeiro, v.9, p.77-86, 1950.

DIGGLE, P. J.; RIBEIRO JR, P. J.; CHRISTENSEN, O. F. An introduction to Model-Based Geostatistics. In: $M\phi$ LLER, J. (Ed.). **Spatial statistics and computational methods**. New York: Springer-Verlag, 2003. chap. 1, p.1-45.

DIGGLE, P. J.; TAWN, J. A.; MOYEED, R. A. Model-Based geostatistics. **Applied Statistics**, London, v.47, p.299-350, 1998.

DIGGLE, P. J.; RIBEIRO JR., P. J. Model-Based geostatistics. New York: Springer, 2007. 228p.

GOOVAERTS, P. Geostatistics for natural resources evaluation, New York: Oxford University Press, 1997. 483p.

GRECO, C. R.; VIEIRA, S. R.; LOURENÇÃO, A. L. Spatial distribution of *Pseudaletia sequax* franclemlont in triticale under no-till management, **Scientia Agricola**, Piracicaba, v.63, p. 321-327, 2006.

ISAAKS, E.H.; SRIVASTAVA, R.H. **Applied Geostatisctics**. New York: Oxford University Press, 1989. 561p.

MANLY, B. F. J. Randomization, Bootstrap and Monte Carlo Mrthods in Biology, Flórida: Chapman & Hall, 2006. 460p.

MANTEL, B. F. J. The detection of disease clustering and a generalised regression approach. **Cancer Research**, Philadelphia, v. 27, p. 209-220. 1967.

McCULLAGH, P.; NELDER, J. A. **Generalized Linear Models**, London: Chapman & Hall, 1989. 511p.

MONTAGNA, M. A. **Distribuição espacial e amostragem seqüencial da mosca-branca** *Bemisia Tabaci Raça B* (**Homoptera: Aleyrodidae**) **no agroecossistema do melão**. 2001, 112 p. Dissertação (Mestrado em Entomologia) - USP/RP Universidade de São Paulo, Ribeirão Preto, 2001.

RIBEIRO JR., P. J. Abordagem geoestatística em um estudo de variabilidade espacial. 1995. 99p. Dissertação (Mestrado em Estatística e Experimentação Agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 1995.

RIBEIRO JR, P. J. **model based geostatistics**. Disponível em: http://leg.ufpr.br/paulojus/MBG/slides/mbg.slides.pdf. Acesso em: 22 out. 2004.

RUIZ, R. C.; DEMÉTRIO, C. G. B.; ASSUNÇÃO, R. M.; LEANDRO, R. A. Modelos hierárquicos Bayesianos para estudar a distribuição espacial da infestação da broca do café em nível local. **Revista Colombiana de Estadística**, Bogotá, v.26, n.1 p.1-24, 2003.

RUIZ, R. Modelagem da Distribuição Espaço-Temporal da Broca do Café (*Hypothenemus hampei Ferrari*) em uma Cultura de Região Central Colombiana. 2002. 119p. Dissertação (Mestrado em Estatística e Experimentação Agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 2002.

SATO, M. E. **Avaliação do Dano e Controle do** *Thrips tabaci* **Lindeman, 1988, na Cultura da Cebola** (*Allium cepaL*.). 1989. 93p. Dissertação (Mestrado em Estatística e Experimentação

Agronômica) - Escola Superior de Agricultura "Luiz de Queiroz", Universidade de São Paulo, Piracicaba, 1989.

SNÄLL, T.; RIBEIRO JUNIOR, P. J.; RYDIN, H. Spatial occurrence and colonisations in patch-tracking metapopulations: local conditions versus dispersal. **Oikos**, Barcelona, v.103, n.3, p.566-578, 2003.

UPTON, G.; FINGLETON, B. **Spatial Data Analysis by Example**, New York: Wiley, 1985. 422p.

WORKMAN, P. J.; MARTIN, N. A. Towards Integrated Pest Management of *Thrips Tabaci* in onions **Plant Protection**, New Zeland, v.55, p.188 - 192, 2002.

3 UMA AVALIAÇÃO DO ESTIMADOR DE PSEUDO-VEROSSIMILHANÇA PARA MODELOS AUTOLOGÍSTICOS ESPACIAIS

Resumo

Neste artigo é feito um estudo de simulação para verificar o comportamento dos estimadores de pseudo-verossimilhança dos parâmetros do modelo autologístico, considerando diferentes estruturas de covariáveis e de vizinhança, três intensidades de infestação de uma praga e cinco valores para o parâmetro de correlação entre os vizinhos. Uma aplicação dos modelos considerados no estudo de simulação é feita a um conjunto de dados provenientes de um experimento com pimentão, utilizado por Gumpertz, Graham e Ristino (1997). Mostra-se que o método de estimação por pseudo-verossimilhança pode ser usado, com certa cautela, quando o interesse está na contribuição das covariáveis, mas não deve ser usado quando o interesse está na estimação da correlação espacial.

Palavras-chaves: Modelo autologístico; Correlação espacial; Dados binários; Distribuição Bernoulli; Pseudo-verossimilhança.

Abstract

In this paper a simulation study on pseudo-likelihood estimators of autologistic parameters to verify the effect of different covariate and neighbouring structures is described, with three pest infestation levels and five different spatial correlation coefficient values. An application of the methodology is presented using bell pepper data from Gumpertz, Graham and Ristino (1997). It is shown that the pseudo-likelihood method can be used when a researcher is interested in the effect of covariates, but should not be used for the estimation of the spatial correlation.

Keywords: Autologistic model; Spatial correlation; Binary data; Bernoulli distribution; pseudo-likelihood.

3.1 Introdução

Variáveis respostas binárias, isto é, do tipo sucesso/fracasso são muito comuns na experimentação agronômica. Por exemplo, em estudos de fitopatologia, o pesquisador pode estar interessado na presença ou ausência de uma determinada doença visando associar a probabilidade de occorência com covariáveis de interesse e/ou estudar padrões espaciais da distribuição da doença. Nesse tipo de estudo, espera-se, em geral, que as observações sejam correlacionadas no espaço e/ou no

tempo. O modelo usualmente adotado para a análise de respostas binárias é o modelo de regressão logística que tem como uma de suas pressuposições a independência das observações. Assim sendo, extensões ou modelos alternativos são necessários para acomodar a estrutura de correlação induzida pela dependência espacial e/ou temporal e têm sido propostos na literatura.

Uma das propostas apresentadas na literatura são os modelos autologísticos (BESAG, 1972, AUGUSTIN; MUGGLESTONE; BUCKLAND, 1996, GUMPERTZ; GRAHAM; RISTANO, 1997) em que se contróem covariáveis com a finalidade de incorporar a informação do "status" da doença na vizinhança de cada observação. As áreas de aplicação são diversas e incluem estudos sobre fauna aquática de macro invertebrados em 76 lagoas inglesas (SANDERSON; EYRE; RUSHTON, 2005), comportamento de clientes em relação a políticas de seguro (MOON; RUSSEL 2005), mapeamento de pobreza em países em desenvolvimento (PETRUCCI; SALVATI; SEGHIERI 2004), distribuição espacial de renas na Suécia (TETERUKOVSKIY; EDEMIRS, 2003), distribuição de vegetação em florestas, considerando covariáveis climáticas (HE; ZHOU; ZHU 2003), distribuição da epidemia do *Phytophthora* em pimenta do sino considerando efeitos de variáveis do solo (GUMPERTZ; GRAHAM; RISTAINO, 1997), distribuição de espécies de plantas considerando covariáveis climáticas (WU; HUFFER, 1997), distribuição espacial de alces em uma região da Escócia (AUGUSTIN; MUGGLESTONE; BUCKLAND, 1996), análise genética de características familiares (ABEL; GLOLMARD; MALLET, 1993), dentre outros. Uma comparação entre o modelo autologístico e um modelo logístico regressivo é apresentada em Abel, Golmard, Mallet (1993).

Entretanto, estudos mais detalhados em relação às propriedades dos estimadores e métodos de estimação propostos são necessários para essa categoria de modelos. Entre os métodos propostos está o de maximização de uma pseudo-verossimilhança. Tal método é relativamente simples quando comparado com métodos alternativos e computacionalmente intensivos, porém suas propriedades não têm sido extensivamente estudadas (PETRUCCI; SALVATI; SEGHIERI, 2004). Os parâmetros que descrevem a estrutura de dependência tornam complexo, se não proibitivo o estudo análitico das propriedades dos métodos de estimação. Entretanto, com o grande desenvolvimento dos recursos computacionais o uso de simulações consistem um uma alternativa viável para o estudo de propriedades estatísticas de interesse. Esses estudos são baseados em informações reais e utilizados como repetições de um experimento, sendo igualmente aplicáveis para variáveis respostas contínuas ou discretas.

Neste artigo procurou-se estudar o comportamento do procedimento de estimação em diferentes cenários de intensidade do padrão espacial e escolha de covariáveis espaciais. São relatados os resultados de um estudo de simulação para verificar o comportamento dos estimadores de pseudo-verossimilhança dos parâmetros do modelo autologístico, considerando (i) diferentes estruturas de covariáveis e de vizinhança, (ii) três intensidades de infestação de uma praga e (iii) cinco valores para o parâmetro de correlação entre os vizinhos. Adicionalmente, uma aplicação dos

modelos considerados no estudo de simulação é feita a um conjunto de dados provenientes de um experimento com pimentão, utilizado por Gumpertz, Graham e Ristino (1997). E, para finalizar, foi feito um estudo com diferentes porcentagens de dados faltantes para verificar a influência na estimação do parâmetro.

O restante do artigo está organizado como se segue. A Seção 3.2.1 descreve o modelo autologístico como uma extensão do modelo logístico usual e o procedimento de inferência é apresentado na Seção 3.2.2. Na Seção 3.2.3 é feita a descrição do estudo de simulação cujos resultados são apresentados e discutidos na Seção 3.2.4. A aplicação do modelo autologístico a dados reais é mostrada na Seção 3.2.5. Finalmente, algumas considerações finais aparecem na Seção 3.3.

3.2 Desenvolvimento

3.2.1 Modelo autologístico

Modelos lineares generalizados (MLG) envolvem três componentes, a saber um componente sistemático, um aleatório e uma função de ligação. O componente sistemático é definido durante o planejamento do experimento e as variáveis explicativas entram na forma de soma linear dos efeitos, isto é, com preditor linear $\eta = \mathbf{X}\boldsymbol{\beta}$, em que \mathbf{X} é a matriz do modelo, $\boldsymbol{\beta}$ é o vetor de parâmetros. O componente aleatório é estabelecido após definidas as medidas que serão realizadas, em que o conjunto de variáveis aleatórias $Y_i, i = 1, 2, \ldots, n$ são mutuamente independentes com distribuição pertencente à família exponencial na forma canônica e $E(Y_i) = \mu_i$. A função de ligação relaciona o componente aleatório ao componente sistemático, ou seja, a média da distribuição ao preditor linear. Logo, na seleção de modelos a serem ajustados a um conjunto de dados, é importante escolher a distribuição da variável resposta, a matriz do modelo e a função de ligação (DEMÉTRIO, 2001). Um caso particular dos MLG é o modelo de regressão logística que pode ser usado para a análise de variáveis aleatórias binárias independentes.

Sejam Y_i , $i=1,2,\ldots,n$, variáveis aleatórias com distribuição de Bernoulli com probabilidade de sucesso π_i , sendo que y_i assume os valores zero (fracasso) ou um (sucesso). Tem-se que $E(Y_i)=\pi_i$ e $Var(Y_i)=\pi_i(1-\pi_i)$. Então, um modelo linear generalizado permite que as probabilidades de sucesso π_i sejam modeladas em termos de p variáveis explanatórias x_{ik} , $k=1,\ldots,p$, através de

$$g(\pi_i) = \boldsymbol{\beta}^T \mathbf{x}_i$$

em que g é uma função de ligação adequada e β é o vetor de parâmetros desconhecidos. Considerando-

se a função de ligação logística, tem-se

$$logit(\pi_i) = log \frac{\pi_i}{1 - \pi_i} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{ip}$$

e, portanto,

$$\pi_i = P(Y = 1|x) = \frac{\exp\{\beta_0 + \sum_{k=1}^p \beta_j x_{ik}\}}{1 + \exp\{\beta_0 + \sum_{k=1}^p \beta_j x_{ik}\}}.$$

	y_{i^3}		
y_{i1}	y _i	y_{i_2}	
	y_{i^4}		

_				
	y _{i5}	y_{i^3}	y_{i6}	
	y_{i1}	y _i	y_{i2}	
	y_{i7}	y_{i^4}	y_{i^8}	

		y _{i13}		
	y_{i5}	y_{i^3}	y ₁₆	
y_{i9}	y_{i1}	y _i	y_{i2}	y _{i10}
	y _{i7}	y_{i^4}	y_{i^8}	
		y _{i12}		

Figura 3.1 – Representação esquemática de estrutura de vizinhança sobre um látice regular (primeira, segunda e terceira ordens).

O modelo autologístico, motivado por problemas na área de estatística espacial, foi introduzido pelos artigos de Besag (1972, 1974) e consiste em uma generalização do modelo logístico, considerando dependência espacial entre as respostas. A autocorrelação é induzida por funções das respostas dos vizinhos como covariáveis do modelo, sendo que diferentes estruturas de vizinhança podem ser consideradas, usualmente chamadas de primeira, segunda e terceira ordens com quatro, oito e doze vizinhos, respectivamente, conforme Figura 3.1. O preditor linear passa a ter a forma

$$logit(\pi_i) = log \frac{\pi_i}{1 - \pi_i} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{ip} + \gamma^T \mathbf{z}_i$$
 (3.1)

em que π_i é a probabilidade de sucesso de um evento para o i-ésimo indivíduo, $i=1,\ldots,n,$ β_k é o k-ésimo parâmetro associado à covariável $x_{ik},$ γ é o vetor de parâmetros associado ao vetor \mathbf{z}_i das covariáveis contruídas a partir das observações na vizinhança da i-ésima observação. Portanto, a probabilidade de um sucesso é dada por

$$P(Y_i = 1 | \text{vizinhos}) = \frac{\exp\{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \boldsymbol{\gamma}^T \mathbf{z}_i\}}{1 + \exp\{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \boldsymbol{\gamma}^T \mathbf{z}_i\}}.$$

A forma da covariável \mathbf{z}_i faz parte da especificação do modelo. Augustin, Mugglestone e Buckland (1996) definem como dada pelo peso médio ponderado dos k_i vizinhos do i-ésimo

indivíduo, isto é,

$$z_i = \frac{\sum_{j=1}^{k_i} w_{ij} y_j}{\sum_{j=1}^{k_i} w_{ij}}$$

sendo que $w_{ij} = \frac{1}{h_{ij}}$, em que h_{ij} é a distância euclidiana entre as observações i e j. Por exemplo, considerando-se distância unitária entre vizinhos e estrutura de vizinhança de primeira ordem, com observações nos vizinhos dadas por y_{ir} , $r=1,\ldots,4$, o valor da covariável z_i da i-ésima observação é dado por

$$z_i = \frac{1}{4}(y_{i_1} + y_{i_2} + y_{i_3} + y_{i_4}) \tag{3.2}$$

enquanto que para estrutura de vizinhança de segunda ordem

$$z_{i} = \frac{1}{4 + \frac{4}{\sqrt{2}}} \left(y_{i_{1}} + y_{i_{2}} + y_{i_{3}} + y_{i_{4}} + \frac{y_{i_{5}}}{\sqrt{2}} + \frac{y_{i_{6}}}{\sqrt{2}} + \frac{y_{i_{7}}}{\sqrt{2}} + \frac{y_{i_{8}}}{\sqrt{2}} \right). \tag{3.3}$$

Uma forma alternativa é adotada por Gumpertz, Grahan e Ristino (1997) que definem um conjunto de covariáveis \mathbf{z}_i que consideram os componentes da estrutura de vizinhança com possibilidade de especificar efeitos de linhas, colunas e diagonais separadamente, permitindo assim modelar efeitos direcionais. Logo, para estrutura de vizinhança de primeira ordem, o preditor linear pode ser escrito da forma:

$$logit(\pi_i) = \beta_0 + \beta_1 x_{i_1} + \ldots + \beta_p x_{i_p} + \gamma_1 L_i + \gamma_2 C_i,$$

em que $\gamma^T=(\gamma_1 \ \gamma_2)$, $\mathbf{z}_i^T=(L_i \ C_i)$, γ_1 e γ_2 são os parâmetros associados à informação dos vizinhos nas linhas $L_i=(y_{i_1}+y_{i_2})/2$ e colunas $C_i=(y_{i_3}+y_{i_4})/2$. No caso de estrutura de vizinhança de segunda ordem

$$logit(\pi_i) = \beta_0 + \beta_1 x_{i_1} + \ldots + \beta_p x_{i_p} + \gamma_1 L_i + \gamma_2 C_i + \gamma_3 dA_i + \gamma_4 dB_i,$$

em que $\boldsymbol{\gamma}^T=(\gamma_1\;\gamma_2\;\gamma_3\;\gamma_4),\; \mathbf{z}_i^T=(L_i\;C_i\;dA_i\;dB_i),\;\gamma_3$ e γ_4 são os parâmetros associados à informação das diagonais A e B, respectivamente, e $dA_i=\frac{y_{i_5}/\sqrt{2}+y_{i_8}/\sqrt{2}}{2/\sqrt{2}}$ e $dB_i=\frac{y_{i_6}/\sqrt{2}+y_{i_7}/\sqrt{2}}{2/\sqrt{2}}$. Essa separação de efeitos é interessante, por exemplo, no caso de observações provenientes de plan-

tios com diferentes espaçamentos entre e dentro de linhas de plantio e efeitos direcionais.

3.2.2 Estimação

No modelo de regressão logística com observações independentes, a estimação dos parâmetros é feita, geralmente, pelo método da máxima verossimilhança (ML). Entretanto, no caso da modelagem de observações espacialmente correlacionadas com o uso do modelo de regressão autologístico não é possível escrever a função de verossimilhança de forma fechada, sendo, portanto, em geral, desconhecida uma expressão analítica para a constante de normalização. Diversos métodos aproximados foram, então, propostos para estimação dos parâmetros desse modelo, tais como máxima pseudo-verossimlhança, MPL (WU; HUFFER, 1997, WARD; GLEDITSCH, 2002, HE; ZHOU; ZHU, 2003, PETRUCCI; NICOLA SALVATI; SEGHIERI, 2004, SHERMAN, APANOSOVICH, CARROLL, 2006), e "coding", COD, (BESAG, 1972), "bootstrap" (BESAG, 1977), equações de estimação (BESAG, 1986), máxima verossimilhança com simulação Monte Carlo, MCL, (GEYER, 1991, GEYER, 1992, WU; HUFFER, 1997, GRIFFITH, 2002, HE; ZHOU; ZHU, 2003, SHERMAN, APANOSOVICH, CARROLL, 2006), máxima verossimilhança com simulação Monte Carlo via cadeias de Markov, MCMC (GEYER, 1994, WU; HUFFER, 1997, HUFFER; WU, 1998, GU; KONG, 1998, GU; ZHU, 2001, WARD; GLEDITSCH, 2002), máxima pseudo-verossimlhança generalizada, MGPL, (HUANG; OGATA, 2002), dentre outros. Um método computacional estatisticamente eficiente foi desenvolvido para o cálculo da constante de normalização por Pettitt, Friel, Reeves (2003).

A estimativa da máxima pseudo-verossimilhança para um vetor de parâmetros desconhecidos $\theta = (\beta_0, \beta_1, \dots, \gamma)^T$ é definida como um vetor $\hat{\theta}$ que maximize a função de pseudo-verossimilhança (PETRUCCI; SALVATI; SEGHIERI, 2004)

$$L(\pi) = \prod_{i=1}^{n} P(Y_i = 1 | \text{vizinhos}) = \prod_{i=1}^{n} \pi_i^{y_i} (1 - \pi_i)^{(1 - y_i)}$$
(3.4)

ou, equivalentemente, o seu logaritmo

$$\ell(\boldsymbol{\pi}) = \sum_{i=1}^{n} y_i \log \pi_i + \sum_{i=1}^{n} (1 - y_i) \log(1 - \pi_i).$$

Para o modelo autologístico, essa aproximação é computacionalmente simples, pois necessita apenas de alguma rotina que construa as covariáveis espaciais a partir dos dados originais e suas localizações e alguma implementação computacional com método de otimização numérica capaz de ajustar o modelo de regressão logística. As estimativas pontuais obtidas dessa forma são consistentes. Entretanto, os erros padrões das estimativas dos parâmetros são inacurados por serem calcu-

lados, como se as observações fossem independentes (PETRUCCI; SALVATI; SEGHIERI, 2004). Uma proposta feita por Gumpertz, Grahan e Ristino (1997) é usar um método de reamostragem baseado em "bootstrap" paramétrico no qual o amostrador de Gibbs garante a obtenção de amostras com padrão espacial compatível com o observado a partir das quais podem-se obter os erros padrões para as estimativas iniciais.

O método de pseudo-verossimilhança, de acordo com Ward e Gleiditsch (2002) é fácil de implementar, mais eficiente do que COD e mostra propriedades assintóticas razoáveis. Entretanto, suspeita-se que seja ineficiente quando há forte correlação espacial. Portanto, há a necessidade de avaliações sobre a qualidade das inferências produzidas em diferentes condições.

Um método alternativo utiliza simulação Monte Carlo para aproximar a função de verossimilhança e gerar estimadores que são consistentes e assintoticamente normais. Considera-se o logaritmo da razão de verossimilhanças em relação a um ponto de referência $\psi \in \Theta$, isto é,

$$\ell(\boldsymbol{\theta}) - \ell(\boldsymbol{\psi}) = (\boldsymbol{\theta} - \boldsymbol{\psi})^T T(Y_0) - \log \frac{C(\boldsymbol{\theta})}{C(\boldsymbol{\psi})}.$$

e dado que,

$$P_{\boldsymbol{\theta}}(\mathbf{Y}) = C(\boldsymbol{\theta})^{-1} \exp{\{\boldsymbol{\theta}^T T(\mathbf{Y})\}}$$

em que $T(\mathbf{Y}) = \sum_{i \in D} y_i \widetilde{x}_i$ e $\widetilde{x}_i = (1, \mathbf{x}_i^T, \mathbf{z}_i^T)$, tem-se que,

$$\frac{C(\boldsymbol{\theta})}{C(\boldsymbol{\psi})} = \int \exp\{(\boldsymbol{\theta} - \boldsymbol{\psi})^T T(\mathbf{Y})\} P_{\boldsymbol{\psi}}(\mathbf{Y}) d\mathbf{Y}.$$
 (3.5)

Logo, usando-se simulação Monte Carlo, a integral (3.5) pode ser aproximada com base em uma amostra aleatória $\mathbf{Y}_1, \dots \mathbf{Y}_n$ de $P_{\psi}(\mathbf{Y})$, isto é,

$$\frac{C(\boldsymbol{\theta})}{C(\boldsymbol{\psi})} \approx \sum_{i=1}^{n} [(\boldsymbol{\theta} - \boldsymbol{\psi})^T T(\mathbf{Y}_i)],$$

e, portanto,

$$\ell(\boldsymbol{\theta}, \boldsymbol{\psi}) = (\boldsymbol{\theta} - \boldsymbol{\psi})^T T(\mathbf{Y}) - \log[\frac{1}{n} \sum_{i=1}^n \exp{(\boldsymbol{\theta} - \boldsymbol{\psi})^T T(\mathbf{Y}_i)}].$$

que maximizada produz a estimativa $\hat{\theta}_n$ (HE; ZHOU; ZHU, 2003). A desvantagem desse método é que a simulação não preserva a estrutura de vizinhança.

O método de Monte Carlo via Cadeias de Markov é uma modificação do anterior e para preservar a estrutura de vizinhança a simulação é baseada em cadeias de Markov, usando-se o amostrador de Gibbs ou o algoritmo de Metropolis-Hasting. No processo de simulação, é descartado um determinado número das amostras iniciais ("burning" ou "aquecimento" da cadeia) e depois são usadas amostras espaçadas de um determinado número de amostras, a fim de garantir a independência das estimativas.

Diversos estudos de simulação foram feitos comparando os métodos de estimação, Assim, por exemplo, Wu; Huffer (1997) comparando COD, MPL e MCMC concluem que MCMC dá as melhores estimativas e melhor precisão, principalmente, quando a correlação espacial é grande, mas requer um esforço computacional muito maior do que os outros dois métodos, tornando difícil sua utilização em aplicações; MPL requer menor esforço computacional e leva a erros de estimação semelhantes a COD e para correlação espacial pequena mostra-se adequado para a maioria dos casos. Os autores recomendam, então, o uso do método MPL em um primeiro estágio como uma análise exploratória e um refinamento com o método MCMC e falam sobre a necessidade de maiores estudos sobre as propriedades das estimativas obtidas. Chegam a conclusões semelhantes na análise da distribuição espacial de duas espécies vegetais na Flórida.

O método de pseudo-verossimilhança, de acordo com Ward; Gleiditsch (2002) é fácil de implementar, mais eficiente do que COD e mostra propriedades assintóticas razoáveis. Entretanto, tende a ser ineficiente quando há forte correlação espacial.

Em um outro estudo de simulação, usando o modelo autologístico de segunda ordem, He, Zhou, Zhu (2003) comparando MCMC, MPL e MCL concluem que os métodos MCMC e MCL dão resultados idênticos para as estimativas da média e do desvio-padrão e estatísticas de verificação de ajuste do modelo enquanto que MPL leva a resultantes relativamente diferentes. Entretanto, afirmam que MPL pode ser usado na maior parte dos casos em que o principal interesse nao recai em aspectos inferenciais, sendo que, no entanto, ainda é desconhecida a melhor maneira de se medir a falta de ajuste do modelo autologístico. Obtêm conclusões semelhantes na modelagem da distribuição espacial de duas espécies vegetais no Canadá. Recomendam a combinação dos métodos MCMC e MCL, isto é, obtenção das estimativas dos parâmetros por MCL com estimativas iniciais obtidas pelo primeiro passo de MCMC, em função da desvantagem computacional do último.

Ainda, comparando, por simulação os métodos MPL, MGPL e MCL, Sherman, Apanasovich e Carrol (2006) concluem que o método MCL funciona bem para processos espaciais com correlação espacial pequena e pobremente, além de requerer um monitoramento cuidadoso, quando a correlação espacial é grande; o método MPL, embora, menos eficiente para correlação espacial grande do que ML em teoria, é mais eficiente do que MCL; as estimativas obtidas por MGPL têm variabilidade pouco menor do que as de MPL. Entretanto, o método MCL produz erros padrões estimados das estimativas dos parâmetros enquanto que isso não ocorre automaticamente com os métdos MPL e MGPL, sendo necessário complementar com o uso de métodos "bootstrap", considerando o amostrador de Gibbs (GUMPERTZ; GRAHAM; RISTAINO, 1997).

3.2.3 Um estudo de simulação

A fim de verificar o efeito causado por diferentes estruturas de covariáveis e dependência espacial sobre os estimadores de pseudo-verossimilhança dos parâmetros do modelo autologístico, é proposto um estudo de simulação, considerando-se um látice de 20×20 localizações com distância de uma unidade entre pontos. Foram feitas 1.000 simulações, usando-se os pacotes geoR (RIBEIRO JR.; DIGGLE, 2001) para gerar simulações e Rcitrus (KRAINSKI; RIBEIRO JR., 2006) para o ajuste de modelo autologístico, ambos do ambiente computacional estatístico R (R Core Team, 2006). Para cada simulação foram seguidos os passos que se seguem.

Inicialmente, foram gerados valores para duas covariáveis X_1 e X_2 , para três situações: (i) independendentes espacialmente e entre si, (ii) com dependência espacial e não correlacionadas entre si e (iii) com dependência espacial e correlacionadas entre si. Nos três casos os valores para X_1 e X_2 foram gerados a partir de uma distribuição normal de média zero e variância unitária. Entretanto, no primeiro caso as observações foram geradas independentemente enquanto que no segundo e terceiro simulou-se de um modelo linear generalizado geoestatístico (DIGGLE; RIBEIRO, 2007) em que, no segundo caso possuíam valores de alcance prático de 5 e 7 unidades, respectivamente e, 6 unidades para o terceiro caso. O alcance prático em modelos geoestatísticos reflete a extensão da dependência espacial. A relação entre as covariáveis no terceiro caso é dada por $X_2 = 0,9X_1 + 0,3\epsilon$, com ϵ gerado a partir de uma distribuição normal de média zero e variância unitária, definindo a correlação em torno de 0,9 entre X_1 e X_2 .

Em uma segunda etapa, foi ajustado o modelo logístico a partir do qual foram obtidos os valores para as probabilidades p, a partir de

$$p = \frac{\exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2)}{1 + \exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2)}.$$

Para se obterem diferentes valores de níveis de incidência da doença, em torno de 10%

(baixa), 30% (média) e 50% (alta), os valores usados para os parâmetros (β_0 , β_1 , β_2) foram, respectivamente, (0, 1, 1), (-1, 0,25, 0,25) e (-3, -1, -1).

Em uma terceira etapa, após a construção da variável espacial definidas no modelo autologístico (3.1) foram calculados valores para a covariável z, usando-se a expressão (3.2) com os valores de y_{ir} , $r=1,\ldots,4$, substituídos por valores de p obtidos na segunda etapa.

Em uma quarta etapa, foram recalculados os valores de p, considerando-se

$$p = \frac{\exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \gamma z)}{1 + \exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \gamma z)}$$

em que foram avaliadas simulações com os valores 0,00, 0,25, 0,50, 0,75 e 1,00 para o parâmetro γ e a seguir, foram calculados novos valores para z e valores de π dados por

$$\pi = \frac{\exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \gamma z)}{1 + \exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \gamma z)}.$$

A partir destes, foram gerados valores para a variável resposta Y a partir de uma distribuição Bernoulli com probabilidade de sucesso π .

A cada conjunto de dados gerados nas 90 situações, foram ajustados cinco modelos, considerando

- 1. M1: $logit(\pi) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \gamma z$
- 2. M2: logit(π) = $\beta_0 + \gamma z$
- 3. M3: $logit(\pi) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$
- 4. M4: $\operatorname{logit}(\pi) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \gamma_1 L + \gamma_2 C$ ou M4: $\operatorname{logit}(\pi) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \gamma_1 L + \gamma_2 C + \gamma_3 dA + \gamma_4 dB$, para estruturas de vizinhança de primeira e segunda ordens, respectivamente.
- 5. M5: $logit(\pi) = \beta_0 + \gamma_1 L + \gamma_2 C$ ou M5: $logit(\pi) = \beta_0 + \gamma_1 L + \gamma_2 C + \gamma_3 dA + \gamma_4 dB$, para estruturas de vizinhança de primeira e segunda ordens, respectivamente.

Note que M1 é o modelo usado na geração dos dados, enquanto que M2 e M3 estão sendo usados para verificar o efeito do uso de modelos incompletos e M4 e M5 para verificar se existe efeito na direção da vizinhança, em que M4 é o modelo completo e M5 é o modelo sem o efeito das covariáveis.

Para cada combinação de incidências e modelos considerados na simulação os resultados foram avaliados e resumidos por médias, erros padrões e médias dos erros padrões das estimativas

fornecidas pelo ajuste das 1000 sumulações obtidas em cada caso. Os resultados obtidos estão apresentados no Anexo B (Tabelas 3.13 a 3.30).

3.2.4 Resultados e discussão do estudo de simulação

As médias das estimativas de cada parâmetro (Est), os erros padrões (EPC) e as médias dos erros padrões fornecidos pelo ajuste das 1000 simulações (EP) estão apresentados nas Tabelas 3.13 a 3.30.

De uma forma geral, nota-se que as médias das estimativas dos parâmetros β_1 e β_2 têm valores não muito distantes dos valores verdadeiros, mas com diferenças que dependem da intensidade da correlação espacial γ verdadeira, e também da forma como as covariáveis foram geradas. Nota-se que os erros padrões de suas estimativas são muito próximos da média dos erros padrões fornecidos pelo ajuste do modelo. Observa-se, ainda uma influência pequena nas médias das estimativas dos parâmetros β_1 e β_2 obtidas pelos diferentes modelos mostrando que as estimativas pontuais desses parâmetros são pouco afetadas pela alternativa de modelagem de dependência espacial. Entretanto, as médias das estimativas do parâmetro γ têm uma disparidade muito grande em relação ao valor γ com o qual foram gerados os dados. De forma semelhante existem disparidades entre ECP e EP. A seguir são feitos comentários mais específicos.

Observa-se que quando as covariáveis foram geradas sem correlação e sem dependência espacial (Tabela 3.13 a 3.18 do Anexo B), de uma forma geral, as médias das estimativas dos parâmetros β_1 e β_2 são muito próximas dos valores verdadeiros para todos os casos. Observa-se ainda, que a média das estimativas de γ aumentam à medida em que aumenta a correlação entre os vizinhos. Verifica-se ainda que os erros padrões das estimativas têm valores muito próximos da média das estimativas dos erros padrões dados pelo modelo, embora aumentem à medida que aumenta o valor da correlação espacial usada na geração dos dados.

Quando as covariáveis foram geradas sem correlação e com dependência espacial (Tabela 3.19 a 3.24 do Anexo B), observa-se que, de uma forma geral, as médias das estimativas dos parâmetros β_0 , β_1 , β_2 e γ aumentam à medida que aumenta o valor da correlação espacial. Nota-se ainda que, no modelo completo, as médias das estimativas de β_0 são mais próximas dos valores verdadeiros, para o caso de baixa infestação, quando a correlação entre vizinhos é maior e são mais próximas dos valores verdadeiros quando a correlação entre vizinhos é menor para média e alta infestação. Verifica-se também, que os erros padrões das estimativas têm valores muito próximos da média das estimativas dos erros padrões dados pelo modelo.

Observa-se que quando as covariáveis foram geradas com correlação e com dependência espacial (Tabela 3.25 a 3.30 do Anexo B), de uma forma geral, as médias das estimativas dos parâmetros β_1 e γ aumentam à medida em que aumenta a correlação entre vizinhos, já as médias das estimativas de β_2 são muito próximas dos valores verdadeiros. Observa-se ainda, que a média

das estimativas de β_0 não alteram muito no caso de baixa infestação e aumentam à medida em que aumenta a correlação entre os vizinhos para o caso de média e alta infestação. Verifica-se ainda que os erros padrões das estimativas têm valores próximos da média das estimativas dos erros padrões dados pelo modelo.

3.2.5 Aplicação

Uma aplicação da metodologia foi feita usando-se dados de presença/ausência do patógeno $Phytophthora\ capsici\ em\ quadrats\ de\ pimentões,\ tendo\ como\ covariáveis\ o\ conteúdo\ de\ água\ no\ solo\ e\ o\ número\ de\ discos\ de\ folhas\ colonizadas\ pelo\ patógeno,\ apresentados\ em\ Gumpertz,\ Graham\ e\ Ristiano\ (1997). É importante observar que\ a\ porcentagem\ de\ infecção\ nesse\ caso\ é\ de\ 13,5\%,\ o\ que\ pode\ ser\ considerado\ como\ baixa.\ Além\ disso,\ a\ correlação\ estimada\ entre\ <math>X_1$ e X_2 é apenas 0,27. A esse conjunto de dados, foram ajustados os cinco\ modelos\ usados\ no\ estudo\ de\ simulação,\ considerando\ X_1 como\ a\ covariável\ conteúdo\ de\ água\ no\ solo\ e\ X_2 como\ o\ número\ de\ discos\ de\ folhas\ colonizados\ pelo\ patógeno\ e\ o\ método\ de\ pseudo-verossimilhança\ para\ estimação\ dos\ parâmetros.\ No\ artigo\ original, foi\ considerada\ uma\ borda\ dupla,\ enquanto\ aqui\ usou-se\ borda\ simples.\ Os\ valores\ faltantes\ da\ covariável\ X_2 \ foram\ estimados\ usando-se\ as\ expressões\ (3.2)\ e\ (3.3)\ para\ estruturas\ de\ vizinhança\ de\ primeira\ e\ segunda\ ordens,\ respectivamente.\ A\ seleção\ de\ modelos\ foi\ feita\ usando-se\ o\ critério\ de\ informação\ de\ Akaike\ (AIC),\ dado\ por\ -2*LVM+2*p,\ em\ que\ p\ representa\ o\ número\ de\ parâmetros\ e\ LVM\ é\ o\ logaritmo\ do\ valor\ maximizado\ da\ função\ de\ verossimilhança,\ considerando-se\ como\ melhor\ modelo\ aquele\ com\ menor\ AIC.

Como estudo complementar, a fim de verificar o efeito de valores faltantes sobre a estimativas dos parâmetros e estatísticas foram retiradas observações do conjunto original de dados, nas porcentagens de 1%, 5%, 10%, 20% e 50%.

Para estimar os dados retirados foram seguidos os passos: inicialmente, os dados faltantes foram substituídos pela média geral das observações restantes, depois, foi considerada a informação da vizinhança para estruturas de primeira e segunda ordens. Finalmente, foram estimados os parâmetros para os cinco modelos definidos e obtida uma nova matriz de dimensões 20×20 , composta pela combinação linear dos parâmetros estimados e das covariáveis consideradas no modelo (constante, X_1, X_2, \mathbf{z}). A seguir, as observações faltantes na matriz original foram substituídas pelas probabilidades do modelo ajustado

$$m_{ij} = \frac{e^{\beta_0 + \beta_1 CovA + \beta_2 CovB + \gamma z}}{1 + e^{\beta_0 + \beta_1 CovA + \beta_2 CovB + \gamma z}}$$

em que γ são os parâmetros associados às informações da vizinhança.

Esse processo foi repetido até a convergência dos parâmetros. Vale ressaltar que, quanto maior a proporção de observações faltantes no modelo, maior o número de interações feitas.

Os resultados obtidos para o ajuste dos modelos ao conjunto original de dados estão nas Tabelas 3.3 e 3.4. Pelo critério de informação de Akaike, considerando-se estrutura de vizinhança de primeira ordem foi escolhido o modelo que inclui apenas a constante e o efeito de linha, enquanto que estrutura de vizinhança de segunda ordem, o melhor modelo inclui a constante, e os efeitos de linha e da diagonal B. Verifica-se, portanto, que nenhuma covariável foi significativa, como obtido por Gumpertz; Graham; Ristaino (1997). A probabilidade de um "quadrat" ter presença da doença é dada por

$$P(Y_i = 1/y_j, j \neq i) = \frac{\exp\{-2, 83 + 1,07dB + 1,29L\}}{1 + \exp\{-2, 83 + 1,07dB + 1,29L\}}.$$

Os resultados obtidos para o ajuste dos modelos aos conjuntos modificados de dados estão nas Tabelas 3.3 e 3.4. Observa-se que não existe muita variabilidade nas estimativas dos parâmetros quando até 20% das observações são retiradas e estimadas, dando resultados semelhantes aos dados originais. Entretanto, quando 50% das observações são retiradas e estimadas, as estimativas dos coeficientes das covariáveis ficam, ainda, próximas de zero (próximas dos valores obtidos para os dados originais) mas os coeficientes estimados para as variáveis de autocorrelação tornam-se muito pequenos e, portanto, a correlação espacial, é subestimada drasticamente.

Apesar de as estimativas dos parâmetros apresentarem diferentes valores para diferentes porcentagens de observações estimadas, quando o interesse está na probabilidade de ocorrência de um evento em um determinado local, essa não apresenta muita variabilidade, indicando que o valor estimado dos parâmetros não afeta muito a estimativa da probabilidade de sucesso de um determinado evento.

Tabela 3.1 – Estimativas dos parâmetros e estatísticas dos diversos modelos ajustados aos dados originais de pimentão, com estrutura de vizinhança de primeira ordem

Modelo	Parâmetro	Estimativa	Erro Padrão	Z	valor - p	AIC
M1	β_0	-3,29	1,10	-3,00	0,003	245,16
	eta_1	-0,05	0,13	-0,35	0,73	
	eta_2	0,08	0,10	0,75	0,454	
	γ	3,57	0,67	5,31	0,000	
M2	eta_0	-2,50	0,24	-10,51	0,000	241,73
	γ	3,56	0,66	5,38	0,000	
M3	eta_0	-2,66	1,07	-2,48	0,013	272,85
	eta_1	0,08	0,12	0,65	0,519	
	eta_2	0,08	0,10	0,77	0,440	
M4	eta_0	-3,07	1,11	-2,75	0,006	243,00
	eta_1	-0,04	0,14	-0,262	0,793	
	eta_2	0,06	0,10	0,54	0,591	
	γ_1	1,30	0,26	4,93	0,000	
	γ_2	0,36	0,32	1,12	0,26	
M5	eta_0	-2,49	0,24	-10,47	0,000	239,30
	γ_1	1,31	0,26	5,01	0,000	
	γ_2	0,34	0,32	1,08	0,279	
M5	eta_0	-2,41	0,22	-10,85	0,000	238,43
	γ_1	1,41	0,25	5,73	0,000	

Tabela 3.2 – Estimativas dos parâmetros e estatísticas dos diversos modelos ajustados aos dados originais de pimentão, com estrutura de vizinhança de segunda ordem

Modelo	Parâmetro	Estimativa	Erro Padrão	Z	valor - p	AIC
M1	β_0	-3,74	1,13	-3,30	0,000	233,86
	eta_1	-0,11	0,14	-0,79	0,433	
	eta_2	0,09	0,10	0,86	0,390	
	γ	5,22	0,88	5,96	0,000	
M2	eta_0	-2,82	0,27	-10,28	0,000	230,88
	γ	5,09	0,85	6,02	0,000	
M3	eta_0	-2,68	1,08	-2,49	0,013	272,82
	eta_1	0,08	0,12	0,64	0,52	
	eta_0	0,08	0,10	0,79	0,429	
M4	eta_0	-3,60	1,19	-3,04	0,002	229,31
	eta_1	-0,10	0,15	-0,70	0,485	
	eta_2	0,06	0,11	0,60	0,550	
	γ_1	1,25	0,28	4,53	0,000	
	γ_2	-0,15	0,37	-0,41	0,682	
	γ_3	0,57	0,33	1,71	0,088	
	γ_4	1,04	0,28	3,75	0,000	
M5	eta_0	-2,94	0,29	-10,16	0,000	225,94
	γ_1	1,25	0,27	4,58	0,000	
	γ_2	-0,19	0,37	-0,51	0,61	
	γ_3	0,56	0,33	1,68	0,092	
	γ_4	1,02	0,27	3,72	0,000	
M5	eta_0	-2,83	0,27	-10,48	0,000	224,74
	γ_1	1,29	0,25	5,12	0,000	
	γ_4	1,07	0,27	4,00	0,000	

Tabela 3.3 – Estimativas dos parâmetros e estatísticas dos diversos modelos ajustados aos dados originais e os modificados de pimentão, com estrutura de vizinhança de primeira ordem

					γ ν	erdade	eiro	
Modelo	Parâmetro	Original	Original2	0,01	0,05	0,10	0,20	0,50
M1	β_0	-3,30	-3,29	-3,27	-3,35	-3,28	-2,88	-1,78
	eta_1	-0,05	-0,05	-0,04	0,00	-0,08	-0,15	0,04
	eta_2	0,08	0,08	0,07	0,07	0,06	0,04	-0,01
	γ	3,55	3,57	3,53	3,76	4,02	3,80	1,18
M2	eta_0	-2,50	-2,50	-2,50	-2,57	-2,61	-2,52	-1,89
	γ	3,56	3,56	3,52	3,79	3,95	3,61	1,21
M3	eta_0	-2,69	-2,66	-2,72	-2,66	-2,53	-1,88	-1,53
	eta_1	0,08	0,08	0,09	0,11	0,06	0,00	0,06
	eta_2	0,08	0,08	0,08	0,07	0,06	0,00	-0,02
M4	eta_0	-3,07	-3,07	-3,09	-3,28	-3,22	-2,86	-1,76
	eta_1	-0,04	-0,04	-0,03	0,00	-0,08	-0,14	0,04
	eta_2	0,06	0,06	0,06	0,07	0,06	0,04	-0,01
	γ_1	1,29	1,30	1,23	1,14	1,25	1,18	0,42
	γ_2	0,35	0,36	0,43	0,69	0,69	0,66	0,15
M5	eta_0	-2,49	-2,49	-2,49	-2,55	-2,60	-2,51	-1,89
	γ_1	1,31	1,31	1,24	1,15	1,24	1,14	0,43
	γ_2	0,34	0,34	0,41	0,69	0,67	0,60	0,16

Tabela 3.4 – Estimativas dos parâmetros e estatísticas dos diversos modelos ajustados aos dados originais e os modificados de pimentão, com estrutura de vizinhança de segunda ordem

					γ v	erdade	eiro	
Modelo	Parâmetro	Original	Original2	0,01	0,05	0,10	0,20	0,50
M1	β_0	-3,74	-3,74	-3,71	-3,60	-3,61	-3,27	-2,03
	eta_1	-0,11	-0,11	-0,12	-0,05	-0,12	-0,17	0,01
	eta_2	0,09	0,09	0,08	0,07	0,08	0,06	0,00
	γ	5,19	5,22	5,50	5,30	5,29	5,14	2,19
M2	eta_0	-2,82	-2,82	-2,89	-2,85	-2,82	-2,72	-2,05
	γ	5,09	5,09	5,35	5,25	5,14	4,85	2,21
M3	eta_0	-2,69	-2,68	-2,73	-2,56	-2,53	-1,88	-1,56
	eta_1	0,08	0,08	0,08	0,12	0,05	0,00	0,04
	eta_2	0,08	0,08	0,08	0,06	0,06	0,00	-0,01
M4	eta_0	-3,61	-3,60	-3,65	-3,61	-3,64	-3,29	-2,00
	eta_1	-0,10	-0,10	-0,11	-0,06	-0,15	-0,17	0,01
	eta_2	0,07	0,06	0,06	0,07	0,08	0,05	-0,01
	γ_1	1,24	1,25	1,19	1,07	1,19	1,05	0,48
	γ_2	-0,17	-0,15	-0,09	0,29	0,33	0,37	0,09
	γ_3	0,60	0,57	0,70	0,31	0,19	0,33	0,13
	γ_4	1,03	1,04	1,09	1,05	0,99	0,82	0,42
M5	eta_0	-2,94	-2,94	-3,01	-2,92	-2,88	-2,75	-2,06
	γ_1	1,25	1,25	1,18	1,06	1,16	1,01	0,48
	γ_2	-0,19	-0,19	-0,13	0,27	0,30	0,31	0,09
	γ_3	0,56	0,56	0,69	0,31	0,18	0,32	0,13
	γ_4	1,02	1,02	1,07	1,04	0,95	0,79	0,42

3.3 Conclusões

O estudo de simulação com o objetivo de verificar o efeito causado por diferentes estruturas de covariáveis e dependência espacial sobre os estimadores de pseudo-verossimilhança dos parâmetros do modelo autologístico permitiu verificar que as médias das estimativas dos parâmetros associados às covariáveis têm valores não muito distantes dos valores verdadeiros, mas com variações dependendo da correlação espacial, e da forma como as covariáveis foram geradas, mostrando uma robustez quanto à modelagem da covariância na obtenção das estimativas. Os erros padrões de suas

estimativas são muito próximos da média dos erros padrões fornecidos pelo modelo. Entretanto, as médias das estimativas do parâmetro de correlação espacial têm uma disparidade muito grande em relação ao valor verdadeiro com o qual foram gerados os dados. De forma semelhante existem disparidades entre o erro padrão obtido a partir das estimativas dos parâmetros e a média dos erros padrões fornecidos pelo modelo.

As médias das estimativas dos parâmetros, geralmente, aumentam com o aumento da correlação espacial, evidenciando a presença de um pequeno vício, que praticamente desaparece no caso em que as covariáveis não são correlacionadas e não têm dependência espacial. O coeficiente de correlação espacial é estimado com vício muito grande, fazendo com que a correlação espacial se torne muito maior do que o valor verdadeiro.

Portanto, a conclusão geral deste estudo é a de que o método de estimação por pseudoverossimilhança pode ser usado, com certa cautela, quando o interesse está na contribuição das covariáveis, mas não deve ser usado quando o interesse está na estimação da correlação espacial. Estudos adicionais por simulação são necessários para verificar o efeito de observações faltantes nas estimativas dos parâmetros do modelo autologístico.

Referências

ABEL, L; GOLMARD, J. L.; MALLET, A. An autologistic model for the Genetic Analysis of familial Binary data. **American Journal of Human Genetics**, Boston, v.53, p.894-907, 1993.

AUGUSTIN, N. H.; MUGGLESTONE, M. A.; BUCKLAND, S. T. An autologistic model for the spatial distribution of wildlife. **Journal of Applied Ecology**, London, v.33, p.339-347, 1996.

BESSAG, J. Nearest-neighbour systems and the auto-logistic model for binary data (with discussion). **Journal of the Royal Statistical Society**, London, v.34, p.75-83, 1972.

BESAG, J., Spatial interaction and the statistical analysis of lattice systems (with discussions). **Journal of the Royal Statistical Society**, London, v.36 p.192-236, 1974.

BESAG, J. Efficience of pseudolikelihood estimators for simple Gaussian fields. **Biometrika**, London, v.64, p.616-618, 1977.

BESAG, J. On the statistical analysis of dirty pictures (with discussion). **Journal Royal Statistic Society**, London, v.48, p.259-302,1986.

DEMÉTRIO, C. G. B. Modelos lineares generalizados In: 46^O Reunião Anual da RBRAS, 2001, Piracicaba. **Minicurso** Piracicaba, 2001, 113p.

DIGGLE, P. J.; RIBEIRO JR., P. J. Model-Based geostatistics. New York: Springer, 2007, 228p.

GEYER, C. J. Markov Chain Monte Carlo maximum likelihood. **Computing Science and Statistics: Proceedings of the 23rd Symposium on the Interface**, Seattle, p.156-163, 1991.

GEYER C. J. Pratical Markov chain Monte Carlo (with discussion). **Statistical Science**, Beachwood, v. 7, p. 473-511, 1992.

GEYER, C. J. On the convergence Of Monte Carlo Maximum likelihood calculations. **Journal of the Royal Statistical Society**, London, v.56, p.261-274, 1994.

GRIFFITH, D. A. A spatial filtering specification for the autologistic model. **Environmental and Planning A**, London, v.36, p.1791-1811, 2002.

GU, M. G.; KONG, F. H. A stochastic approximation algorithm with Markov Chain Monte Carlo method for incomplete data estimation problems, **Proceedings of National Academic Science of USA**, Washington, v.95, p.7270-7274, 1998.

GU, M. G.; ZHU, H. T. Maximum likelihood estimation for spatial models by Markov Chain Monte Carlo Stocastic Approximation. **Journal of the Royal Statistical Society**, London, v.63, p.339-355, 2001.

GUMPERTZ M. L.; GRAHAM, J. M; RISTANO, J. B. Autologistic model of spatial pattern of Phytophthora epidemic in bell pepper: effects of soil variables on disease presence. **Journal of Agricultural, Biological and Environmental Statistics**, Alexandrina, v.2, p.131-156, 1997.

HE, F.; ZHOU, J.; ZHU, H. Autologistic regression model for the distribution of vegetation. **Journal of Agricultural, Biological and Environmental Statistics**, Alexandria, v.8, p.205-222, 2003.

HUANG, F.; OGATA, Y. Comparison of two methods for calculating the partition functions of various spatial statistical models **The Australian and New Zeland Journal of Statistics**, Oxford, v.43, p.47-65, 2002.

HUFFER, F. W.; WU, H. L., Markov chain Monte Carlo for autologistic regression models with application to the distribution of plant species, **Biometrics**, Arlington, v.54, p.509-524, 1998.

KRAINSKI, E. T.; RIBEIRO JR., P. J., Introdução ao Reitrus, 2006. Disponível em: <a href="http://example.com/http://example.com

MOON, S; RUSSEL, G. J. Predicting product purchase from inferred customer similarity: an autologistic model approach. Disponível em:

http://www.biz.uiowa.edumarketingpdfrussell_moon_sept05.pdf>. Acesso em: 12 nov. 2006.

PETRUCCI, A.; SALVATI, N.; SEGHIERI, C. Autologistic regression model for poverty mapping and analysis. **Metodoloŝki Zveszki**, Ljubljana, v.1, p.225-234, 2004.

PETTITT, A. N.; FRIEL, N.; REEVES, R. Efficient calculation of the normalizing constant of the autologistic and related models on the cylinder and lattice. **Journal Royal Statistical Society**, London, v.65, p.235-246, 2003.

RIBEIRO JUNIOR, P. J., DIGGLE, P. J. geoR: a package for geostatistical analysis, **R-NEWS**, v.1, p.14-18, 2001. Disponível em: < http: CRAN.R - project.orgdocRnews>. Acesso em 05 jan. 2006.

SANDERSON, R. A.; EYRE, M. D.; RUSHTON, S. P.; Distribution of selected macroinvertebrates in a mosaic of temporary and permanent freshwater ponds as explained by autologistic models **Ecography**, Lund, v.28, p.355-362, 2005.

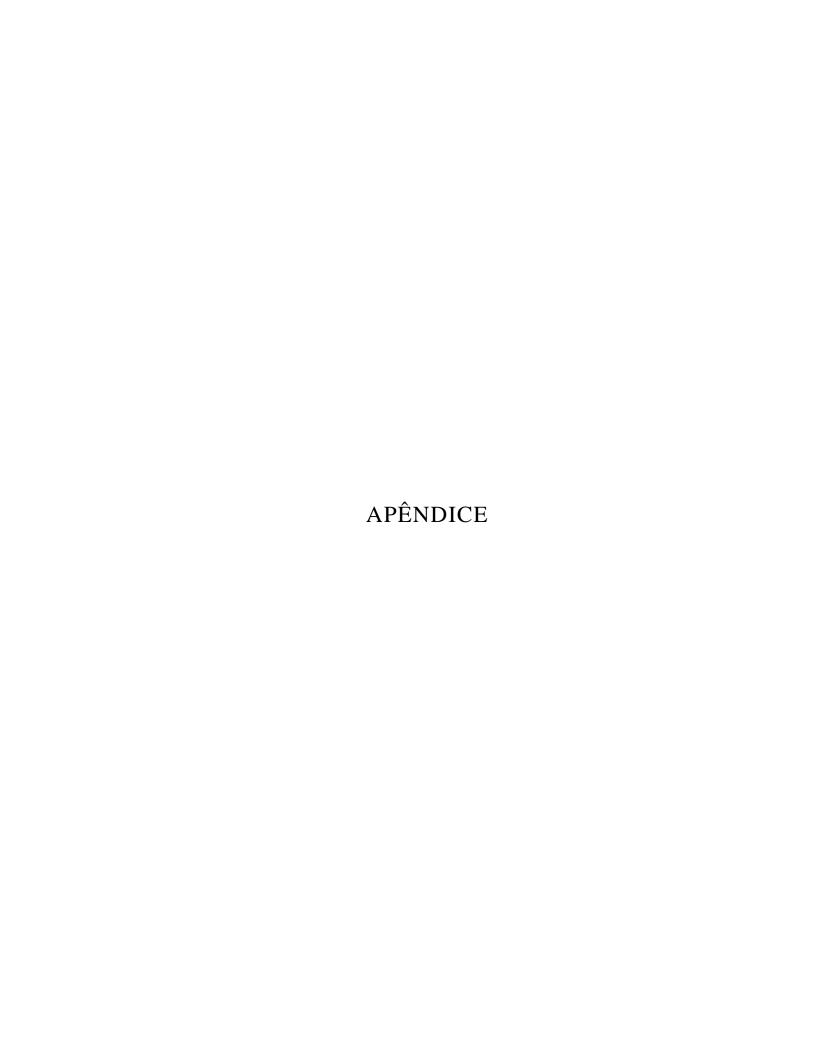
SHERMAN, M.; APANOSOVICH, T. V.; CARROLL, R. J. On estimation in binary autologistic spatial models **Journal of Statistical Computation and Simulation**, Philadelphia, v.76, p.167-179, 2006.

TETERUKOVSKIY, A.; EDEMIRS, L. Effective field sampling for predicting the spatial distribution of reindeer (Rangifer tarandus) with help of the gibbs sampler **A Journal of the**

Human Environment, Stockholm, v.32, p.568-572, 2003.

WARD, M.; GLEDITSCH, K. S. Location, location, location: An MCMC approach to modeling the spatial context of war and peace **Political Analysis**, Oxford, v.10, p.244-260, 2002.

WU, H; HUFFER, F. W. Modelling distribution of plant species using the autolologistic regression model. **Environmental and Ecological Statistics**, London, v.4, p.49-64, 1997.



APÊNDICE A

Tabela 1: Número de tripes (ninfas+adultos) por folha na Fazenda São Paulo

(Continua) X1 X2 10/07 24/07 21/07 07/08 14/08 21/08 28/08 04/09 Media 70 160 6,20 1,00 0,00 2,50 3,29 2,29 4,80 5,11 3,15 60 160 1,50 3,83 0,00 3,25 5,00 1,20 4,38 2,96 4,50 50 160 0,00 5,17 0,20 0,50 4,57 2,82 3,57 7,67 3,06 40 160 0,40 4,00 0,00 0,80 0,00 5,29 5,42 6,67 2,82 30 160 0,20 1,20 0,33 0,86 3,75 0,43 0,57 10,40 2,22 20 160 0,00 3,40 0,00 0,00 6,00 1,08 0,33 8,00 2,35 0,00 0,67 10 160 0,00 0,57 2,00 2,33 1,09 4,00 1,33 0 160 0,67 0,00 0,13 3,40 6,00 5,29 0,00 6,75 2,78 0 150 0,00 0,00 0,00 3,89 2,00 7,78 2,25 4,83 2,59 10 150 0,00 1,57 0,00 1,80 0,71 1,40 3,57 9,40 2,31 20 150 0,20 0,00 0,25 0,50 0,50 0,60 2,00 5,83 1,24 30 150 0,20 0.13 0,00 1,25 3,57 1,14 11,20 4,29 2,72 1,60 40 150 0,20 0,63 0,00 1,14 0,00 6,71 1,00 1,41 50 150 0,60 2,57 0,00 0,00 1,00 3,50 5,00 4,11 2,10 60 150 0,40 0,00 0,43 0,00 1,43 2,00 0,57 3,00 0,98 70 150 0,00 2,86 0,00 5,00 3,00 0,80 1,67 6,00 2,42 65 140 0,60 0,20 0,00 5,71 3,33 4,29 0,40 8,60 2,89 55 140 0,33 0,38 0,14 0,86 3,00 0,00 3,50 5,67 1,73 2,40 0,00 45 140 0,17 0,13 2,50 0,71 2,86 5,11 1,73 35 140 0,33 0,00 0,43 0,00 1,71 0,75 1,18 3,63 1,00 25 140 0,00 0,33 0,00 0,80 0,57 0,00 0,00 7,29 1,12 15 140 1,00 0,67 0,13 4,80 1,67 2,00 1,25 9,17 2,58 5 140 0,25 0,00 0,00 10,00 3,33 2,43 2,14 8,00 3,27 10 130 0,17 1,00 0,14 2,86 0,00 1,80 2,40 30,00 4,80 20 130 0,17 0,00 0,00 0,14 0,50 2,50 1,17 2,50 0,87

Tabela 1: Número de tripes (ninfas+adultos) por folha na Fazenda São Paulo (Continuação)

								(Contil	iuaçao)
X1	X2	10/07	24/07	21/07	07/08	14/08	21/08	28/08	04/09	Media
30	130	0,00	0,43	0,00	0,57	0,00	0,00	5,00	5,67	1,46
40	130	0,17	0,00	0,13	0,57	0,67	1,00	3,00	23,00	3,57
50	130	0,17	0,00	0,13	1,29	2,57	1,50	1,17	4,17	1,37
60	130	0,40	0,00	0,00	1,43	1,57	0,00	1,00	8,25	1,58
60	120	0,00	0,00	0,00	0,00	0,86	0,25	0,00	8,33	1,18
50	120	0,00	2,50	0,00	3,57	2,83	0,67	2,00	1,25	1,60
40	120	0,00	0,00	0,13	0,00	1,71	0,00	1,67	1,11	0,58
30	120	0,00	0,80	0,13	0,00	1,00	0,00	3,00	3,25	1,02
20	120	0,20	0,38	0,00	2,40	0,00	1,86	1,33	5,00	1,40
10	120	0,00	0,29	0,00	2,00	1,00	0,71	1,50	6,80	1,54
15	110	1,17	0,50	0,00	2,40	6,67	0,33	5,50	6,00	2,82
25	110	0,00	0,00	0,14	1,67	2,40	1,29	0,00	8,33	1,73
35	110	0,20	0,00	0,00	2,00	4,00	0,00	1,33	5,50	1,63
45	110	0,00	0,00	0,00	1,00	1,17	2,14	0,00	3,89	1,02
55	110	0,00	0,00	0,00	0,00	1,14	1,00	4,29	3,83	1,28
60	100	0,00	2,60	0,00	0,57	0,20	1,67	4,60	6,00	1,95
50	100	0,00	0,14	0,00	2,00	2,00	1,40	3,57	6,80	1,99
40	100	0,00	0,00	0,29	2,14	2,40	1,25	2,00	7,00	1,88
30	100	0,40	0,20	0,00	0,00	2,83	1,71	0,71	11,25	2,14
20	100	0,00	0,60	0,00	0,00	0,00	0,00	0,86	3,83	0,66
10	100	0,60	0,00	0,13	NA	5,00	0,29	0,00	8,20	2,03
10	90	0,50	0,00	0,00	0,33	5,50	3,33	0,57	4,86	1,89
20	90	0,20	0,25	0,00	0,40	0,60	1,00	0,57	3,44	0,81
30	90	0,17	0,40	0,14	0,00	0,00	5,71	0,43	4,38	1,40
40	90	0,00	0,25	0,00	5,00	0,00	6,11	0,44	7,33	2,39

Tabela 1: Número de tripes (ninfas+adultos) por folha na Fazenda São Paulo (Continuação)

									Comu	maagao
X1	X2	10/07	24/07	21/07	07/08	14/08	21/08			Media
50	90	0,00	0,00	0,00	1,40	0,29	1,67	3,71	6,44	1,69
60	90	0,17	0,33	0,00	2,29	0,00	3,17	2,50	7,83	2,04
60	80	0,20	0,00	0,00	0,00	1,25	1,17	1,17	3,57	0,92
50	80	0,00	0,00	0,00	0,00	0,00	2,14	7,86	3,75	1,72
40	80	0,40	0,20	0,00	0,29	0,00	2,14	3,33	10,00	2,05
30	80	0,00	0,57	0,13	1,00	6,00	3,00	2,14	6,43	2,41
20	80	0,40	0,00	0,00	0,00	0,33	5,33	0,67	6,00	1,59
10	80	0,00	0,00	0,13	0,63	0,00	0,29	2,29	2,78	0,76
10	70	0,00	0,00	0,00	1,11	6,25	3,89	1,00	7,83	2,51
20	70	0,00	1,60	0,00	0,00	0,89	4,60	3,29	4,88	1,91
30	70	0,00	0,50	0,00	0,00	0,71	1,71	3,33	5,83	1,51
40	70	0,20	3,60	0,14	0,00	5,71	0,00	0,00	6,57	2,03
50	70	0,20	0,00	0,00	0,00	1,88	2,89	1,50	2,89	1,17
60	70	0,20	0,40	0,00	2,14	1,00	2,17	0,57	8,75	1,90
60	60	0,33	0,00	0,00	NA	0,25	1,86	0,00	8,57	1,57
50	60	0,00	0,00	0,00	1,71	0,43	1,00	4,50	6,17	1,73
40	60	0,33	0,00	0,33	0,88	1,14	2,29	2,50	3,25	1,34
30	60	0,00	0,40	0,43	2,50	2,00	1,29	2,50	9,29	2,30
20	60	0,33	0,00	0,00	0,00	1,40	2,60	3,57	5,75	1,71
10	60	0,20	0,00	0,17	1,89	0,00	1,00	2,14	5,71	1,39
15	50	0,20	0,00	0,00	0,00	1,20	5,00	3,13	11,25	2,60
25	50	0,20	0,00	0,00	0,57	0,40	0,00	0,00	9,29	1,31
35	50	0,40	0,00	0,00	0,00	1,00	2,50	3,88	16,00	2,97
45	50	0,00	0,00	0,00	0,33	1,33	0,00	7,50	6,57	1,97
55	50	0,20	0,00	0,00	0,00	1,25	2,44	0,00	8,75	1,58

Tabela 1: Número de tripes (ninfas+adultos) por folha na Fazenda São Paulo (Conclusão)

45 40 0,00 0,71 0,00 2,60 0,00 1,17 5,71 3,25 1,68 35 40 0,00 0,00 0,20 0,20 2,00 1,50 0,00 10,00 1,74 25 40 0,00 0,00 0,25 0,00 2,40 5,17 1,00 11,43 2,53 15 40 0,00 0,00 0,00 0,17 2,86 1,67 0,00 2,00 0,84 15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,80										(Cor	iclusao,
45 40 0,00 0,71 0,00 2,60 0,00 1,17 5,71 3,25 1,68 35 40 0,00 0,00 0,20 0,20 2,00 1,50 0,00 10,00 1,74 25 40 0,00 0,00 0,02 0,00 2,40 5,17 1,00 11,43 2,53 15 40 0,00 0,00 0,00 0,17 2,86 1,67 0,00 2,00 0,84 15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,80	X1	X2	10/07	24/07	21/07	07/08	14/08	21/08	28/08	04/09	Media
35 40 0,00 0,00 0,20 0,20 2,00 1,50 0,00 10,00 1,74 25 40 0,00 0,00 0,25 0,00 2,40 5,17 1,00 11,43 2,53 15 40 0,00 0,00 0,00 0,17 0,00 1,43 3,14 0,00 2,00 0,84 15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,13 2,22 1,20 2,00 1,67 7,20 1,80 45 30 0,00 2,29 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 45 20 0,80 0,14 0,13	55	40	0,20	0,00	0,00	0,00	1,14	1,00	3,50	15,71	2,69
25 40 0,00 0,00 0,25 0,00 2,40 5,17 1,00 11,43 2,53 15 40 0,00 0,00 0,00 0,17 2,86 1,67 0,00 2,00 0,84 15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99	45	40	0,00	0,71	0,00	2,60	0,00	1,17	5,71	3,25	1,68
15 40 0,00 0,00 0,17 2,86 1,67 0,00 2,00 0,84 15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25	35	40	0,00	0,00	0,20	0,20	2,00	1,50	0,00	10,00	1,74
15 30 0,40 0,40 0,17 0,00 1,43 3,14 0,00 6,43 1,50 25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,13 2,22 1,20 2,00 1,67 7,20 1,80 45 30 0,00 2,29 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 <th>25</th> <th>40</th> <th>0,00</th> <th>0,00</th> <th>0,25</th> <th>0,00</th> <th>2,40</th> <th>5,17</th> <th>1,00</th> <th>11,43</th> <th>2,53</th>	25	40	0,00	0,00	0,25	0,00	2,40	5,17	1,00	11,43	2,53
25 30 0,50 0,14 0,00 0,00 0,00 2,00 5,40 4,17 1,53 35 30 0,00 0,00 0,13 2,22 1,20 2,00 1,67 7,20 1,80 45 30 0,00 2,29 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,38 0,00 1,29 4,00 2,14 6,67 1,86 </td <th>15</th> <td>40</td> <td>0,00</td> <td>0,00</td> <td>0,00</td> <td>0,17</td> <td>2,86</td> <td>1,67</td> <td>0,00</td> <td>2,00</td> <td>0,84</td>	15	40	0,00	0,00	0,00	0,17	2,86	1,67	0,00	2,00	0,84
35 30 0,00 0,00 0,13 2,22 1,20 2,00 1,67 7,20 1,80 45 30 0,00 2,29 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,57 0,67 <	15	30	0,40	0,40	0,17	0,00	1,43	3,14	0,00	6,43	1,50
45 30 0,00 2,29 0,00 0,14 1,38 3,20 2,86 7,14 2,13 55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,14 0,00 0,71 2,67 5,00	25	30	0,50	0,14	0,00	0,00	0,00	2,00	5,40	4,17	1,53
55 30 0,00 0,40 0,00 1,86 0,80 0,50 2,71 8,25 1,82 55 20 0,20 2,00 0,00 3,83 1,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,85 35 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85<	35	30	0,00	0,00	0,13	2,22	1,20	2,00	1,67	7,20	1,80
55 20 0,20 2,00 0,00 3,83 1,83 2,50 10,00 2,78 45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 <tr< td=""><th>45</th><td>30</td><td>0,00</td><td>2,29</td><td>0,00</td><td>0,14</td><td>1,38</td><td>3,20</td><td>2,86</td><td>7,14</td><td>2,13</td></tr<>	45	30	0,00	2,29	0,00	0,14	1,38	3,20	2,86	7,14	2,13
45 20 0,80 0,14 0,13 0,00 0,57 3,20 2,50 8,57 1,99 35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 10 0,00 0,20 0,14 0,67 1,50 3,75 <	55	30	0,00	0,40	0,00	1,86	0,80	0,50	2,71	8,25	1,82
35 20 0,20 0,00 0,14 0,20 1,14 2,50 8,40 10,00 2,82 25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 <t< td=""><th>55</th><td>20</td><td>0,20</td><td>2,00</td><td>0,00</td><td>3,83</td><td>1,83</td><td>1,83</td><td>2,50</td><td>10,00</td><td>2,78</td></t<>	55	20	0,20	2,00	0,00	3,83	1,83	1,83	2,50	10,00	2,78
25 20 0,20 0,00 0,00 0,33 1,67 0,90 4,00 8,57 1,96 15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14	45	20	0,80	0,14	0,13	0,00	0,57	3,20	2,50	8,57	1,99
15 20 0,20 0,20 0,38 0,00 1,29 4,00 2,14 6,67 1,86 15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,50 0,57 1,60 2,50 0	35	20	0,20	0,00	0,14	0,20	1,14	2,50	8,40	10,00	2,82
15 10 0,00 0,40 0,00 0,71 1,00 6,83 5,71 8,57 2,90 25 10 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,	25	20	0,20	0,00	0,00	0,33	1,67	0,90	4,00	8,57	1,96
25 10 0,00 0,00 0,00 0,57 0,67 2,50 10,50 8,57 2,85 35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	15	20	0,20	0,20	0,38	0,00	1,29	4,00	2,14	6,67	1,86
35 10 0,20 0,00 0,00 0,17 9,00 4,17 0,00 3,75 2,16 45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	15	10	0,00	0,40	0,00	0,71	1,00	6,83	5,71	8,57	2,90
45 10 0,20 0,14 0,00 0,71 2,67 5,00 0,00 8,33 2,13 55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	25	10	0,00	0,00	0,00	0,57	0,67	2,50	10,50	8,57	2,85
55 10 0,00 0,20 0,14 0,67 1,50 3,75 6,00 3,33 1,95 55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	35	10	0,20	0,00	0,00	0,17	9,00	4,17	0,00	3,75	2,16
55 0 0,20 0,00 1,00 1,00 6,67 1,86 3,00 9,00 2,84 45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	45	10	0,20	0,14	0,00	0,71	2,67	5,00	0,00	8,33	2,13
45 0 0,00 0,50 0,17 0,00 2,14 1,57 0,57 3,33 1,04 35 0 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	55	10	0,00	0,20	0,14	0,67	1,50	3,75	6,00	3,33	1,95
35 0 0,00 0,00 0,00 0,57 1,60 2,50 0,89 5,71 1,41 25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	55	0	0,20	0,00	1,00	1,00	6,67	1,86	3,00	9,00	2,84
25 0 0,00 0,00 0,29 0,80 0,00 0,50 3,25 4,29 1,14	45	0	0,00	0,50	0,17	0,00	2,14	1,57	0,57	3,33	1,04
	35	0	0,00	0,00	0,00	0,57	1,60	2,50	0,89	5,71	1,41
15 0 0,33 0,00 0,00 0,00 2,29 1,43 0,00 5,71 1,22	25	0	0,00	0,00	0,29	0,80	0,00	0,50	3,25	4,29	1,14
	15	0	0,33	0,00	0,00	0,00	2,29	1,43	0,00	5,71	1,22

Tabela 2: Número de tripes (ninfas+adultos) por folha na Estância Bela Vista

(Continua)

X1	X2	11/07	01/08	08/08	14/08	09/09	Media
80	0	11,67	16,43	15,50	3,67	9,00	11,25
90	0	5,33	14,71	17,83	3,33	9,00	10,04
100	0	5,00	14,71	17,33	4,60	14,44	11,22
110	0	10,80	9,57	17,43	4,17	6,67	9,73
120	0	7,40	17,50	15,29	1,67	10,00	10,37
130	0	8,00	10,00	18,17	5,83	10,00	10,40
140	0	9,00	14,71	15,71	2,29	4,00	9,14
150	0	22,50	15,43	17,33	0,00	22,50	15,55
160	0	10,33	15,00	17,67	3,00	4,60	10,12
170	0	15,40	15,00	15,00	7,86	30,00	16,65
180	0	8,80	7,00	22,20	0,20	22,43	12,13
190	10	7,40	8,57	19,33	4,38	7,00	9,34
180	10	7,20	15,57	19,50	2,56	1,43	9,25
170	10	12,33	16,14	18,17	5,43	6,00	11,61
160	10	12,00	15,71	14,71	10,71	1,71	10,97
150	10	6,60	14,86	17,00	4,50	5,71	9,73
140	10	2,20	15,29	19,43	3,33	1,71	8,39
130	10	11,17	13,33	25,83	2,86	5,00	11,64
120	10	7,80	6,17	20,50	4,17	10,00	9,73
110	10	12,17	17,83	15,86	1,67	7,14	10,93
100	10	6,00	12,86	14,71	7,14	2,50	8,64
90	10	5,20	8,80	19,50	4,00	3,33	8,17
80	10	3,60	14,50	12,50	8,33	2,40	8,27
70	10	4,00	9,67	10,00	4,43	12,50	8,12
60	20	5,00	11,50	18,00	2,00	4,00	8,10

Tabela 2: Número de tripes (ninfas+adultos) por folha na Estância Bela Vista (Continuação)

X1 X2 11/07 01/08 08/08 14/08 09/09 Media 4,00 17,83 13,88 70 20 4,50 0,33 8,11 80 20 4,00 10,83 14,00 1,00 4,00 6,77 5,00 16,86 19,29 90 20 5,11 4,29 10,11 100 20 5,60 17,17 8,40 2,11 6,25 7,91 110 20 3,20 15,86 13,25 3,50 5,71 8,30 120 20 5,00 16,29 16,00 7,50 5,00 9,96 5,60 14,71 14,38 7,00 130 20 2,50 8,84 140 20 4,33 11,67 15,57 26,00 7,14 12,94 150 20 7,75 8,50 16,86 4,00 6,00 8,62 160 20 4,60 19,17 13,00 6,88 10,00 10,73 170 20 5,75 21,00 1,17 15,00 0,50 8,68 180 20 5,00 17,17 6,33 3,43 0,00 6,39 190 20 6,80 15,00 6,83 4,40 0,00 6,61 200 20 7,20 13,17 14,25 2,00 3,00 7,92 210 30 9,00 17,33 16,00 5,40 5,00 10,55 200 30 11,25 20,50 7,50 0,00 5,00 8,85 190 30 4,60 15,00 12,63 20,00 26,00 15,65 180 30 8,00 19,00 12,00 21,43 0,00 12,09 170 30 4,60 14,83 6,40 6,67 10,00 8,50 160 30 5,60 12,25 1,60 3,14 5,71 5,66 150 30 7,00 16,50 15,00 9,17 18,57 13,25 140 30 10,00 18,17 13,75 5,83 2,14 9,98 130 30 7,20 17,67 14,71 3,43 4,29 9,46 120 30 1,75 11,00 2,60 0,75 6,67 4,55 110 30 6,00 11,50 4,67 3,14 0,80 5,22

Tabela 2: Número de tripes (ninfas+adultos) por folha na Estância Bela Vista

(Continuação)

						Contin	iuuçuo)
X1	X2	11/07	01/08	08/08	14/08	09/09	Media
100	30	5,67	13,14	3,83	1,00	6,00	5,93
90	30	4,60	8,00	14,00	13,33	8,00	9,59
80	30	2,00	15,00	6,40	13,33	0,00	7,35
70	30	5,75	10,67	13,25	2,43	6,67	7,75
60	30	3,75	18,67	9,00	2,14	3,83	7,48
50	30	12,00	15,43	6,00	8,57	6,33	9,67
40	40	3,33	13,20	19,43	3,57	3,83	8,67
50	40	13,00	12,75	5,60	NA	1,20	8,14
60	40	4,50	13,67	9,33	5,83	3,33	7,33
70	40	8,40	9,50	15,33	3,50	2,22	7,79
80	40	5,50	7,00	11,20	10,00	NA	8,43
90	40	4,00	15,25	5,00	6,17	9,43	7,97
100	40	2,67	8,33	11,75	3,67	5,71	6,43
110	40	2,00	3,00	12,40	1,33	13,33	6,41
120	40	6,00	1,33	6,00	9,17	13,33	7,17
130	40	3,00	5,67	3,33	7,86	5,71	5,11
140	40	1,67	4,00	4,25	0,60	4,29	2,96
150	40	8,00	6,33	5,00	2,00	2,86	4,84
160	40	3,33	1,67	5,40	2,60	6,67	3,93
170	40	3,00	5,75	10,14	4,17	11,67	6,95
180	40	3,50	4,50	9,83	7,50	5,00	6,07
190	40	2,25	9,75	7,33	7,50	4,29	6,22
200	40	2,67	12,40	5,25	3,86	12,00	7,23
210	40	4,00	3,50	1,40	4,50	17,78	6,24
220	40	5,33	4,60	4,50	5,20	6,67	5,26

Tabela 2: Número de tripes (ninfas+adultos) por folha na Estância Bela Vista

(Conclusão)

						(Con	ciusao)
X1	X2	11/07	01/08	08/08	14/08	09/09	Media
240	50	8,00	6,80	21,80	18,33	7,14	12,42
230	50	5,25	5,60	2,25	6,43	8,00	5,51
220	50	5,00	7,20	9,25	4,29	13,33	7,81
210	50	8,33	5,25	20,75	7,14	7,50	9,80
200	50	7,00	9,50	17,00	7,00	5,00	9,10
190	50	3,50	4,33	5,50	5,00	5,00	4,67
180	50	5,00	2,50	14,00	11,67	4,00	7,43
170	50	3,67	7,40	2,33	3,75	8,57	5,14
160	50	3,25	5,50	7,00	5,00	16,67	7,48
150	50	7,50	11,50	NA	4,00	12,50	8,88
140	50	2,50	9,20	NA	10,00	5,00	6,68
130	50	3,25	10,80	NA	3,33	7,50	6,22
120	50	5,67	6,50	NA	10,00	6,67	7,21
110	50	6,33	4,50	NA	7,14	8,57	6,64
100	50	1,25	10,00	NA	5,71	5,00	5,49
90	50	6,00	3,25	NA	8,57	7,14	6,24
80	50	3,75	6,25	NA	7,00	0,00	4,25
70	50	4,00	2,00	NA	8,33	0,00	3,58
60	50	2,67	4,00	NA	9,25	4,00	4,98
50	50	3,50	5,60	NA	11,75	23,33	11,05
40	50	3,50	4,75	NA	6,20	18,57	8,26
30	50	5,00	5,75	NA	13,75	4,00	7,13
20	50	7,60	7,00	NA	7,20	5,00	6,70
10	50	2,25	8,25	NA	8,71	3,86	5,77
0	50	3,75	3,67	NA	4,43	9,00	5,21

Tabela 3: Número de tripes (ninfas+adultos) por folha no Sítio Rosário

(Continua) X1 X2 21/06 29/06 07/07 14/07 21/07 28/07 08/04 08/11 18/08 25/08 09/03 Media 0 0 0,33 2,00 0,60 3,17 2,33 3,83 3,00 0,83 1,83 2,33 0,67 1,90 10 0 0,33 0,33 0,40 2,80 2,75 6,83 6,50 0,29 5,00 7,14 0,80 3,02 0 20 0.00 1,75 2,40 0,40 0,20 6,33 4,17 6,50 11,80 0,20 10,83 4,05 0,00 3,20 30 0 1,00 2,20 2,75 12,20 8,60 5,83 20,00 1,83 0,60 5,29 40 0 0,25 2,50 1,00 2,50 1,80 9,60 6,50 6,00 15,71 4,29 8,86 5,36 0 0,00 1,50 50 2,00 1,50 2,17 12,67 3,83 9,17 15,50 7,50 2,17 5,27 7,00 0,33 0,00 0,40 0,80 3,00 3,33 9,29 13,67 7,50 4,29 60 0 1,83 70 0 2,00 4,00 1,00 0,75 2,80 2,50 4,50 6,63 10,71 5,71 3,78 1,00 80 0 0,00 5,40 0,60 2,17 1,83 3,83 2,14 4,75 8,63 3,75 0,17 3,02 90 0,50 0,50 0,50 0,00 0,60 3,00 5,43 7,13 9,00 5,71 2,33 0 3,15 10 0,00 1,00 1,20 0,50 0,40 5,67 5,29 7,29 6,71 5,00 2,50 90 3,23 80 10 0,00 0,25 0,25 1,50 0,00 3,29 5,71 4,63 4,50 4,38 2,40 2,45 70 0,00 1,75 0,25 1,40 3,00 4,43 6,00 2,93 10 0,40 8,86 5,50 0,67 60 10 0,00 3,25 0,80 1,00 0,33 2,00 5,00 7,00 6,25 8,75 0,57 3,18 0,75 2,20 0,40 1,75 9,40 11,14 7,00 10,00 12,20 10,14 50 10 1,67 6,06 40 0,00 0,40 0,80 0,60 4,83 3,33 10 7,67 4,60 3,13 6,14 0,00 2,86 1,00 2,25 0,75 1,00 0,40 3,00 2,14 3,83 30 10 9,29 1,33 4,67 2,70 20 0,33 1,60 2,25 10 2,17 2,00 2,60 6,67 6,00 10,29 6,33 6,86 4,28 10 10 0,00 2,80 0,33 3,17 0,50 0,60 1,00 3,75 10,14 6,29 0,50 2,64 0,67 2,75 2,80 2,20 5,17 3,00 4,25 0 10 2,40 7,17 7,71 9,17 4,30 0,50 0,33 0,67 1,40 9,38 5,88 8,14 20 1,40 6,83 5,40 1,29 3,75 10 20 1,00 0,00 0,00 1,67 1,60 5,00 5,17 5,71 7,40 2,17 2,81 1,20 0,00 1,00 0,40 20 20 0,75 0,80 1,80 1,83 6,29 8,33 6,14 0,75 2,55 30 20 0,00 1,00 3,20 3,00 0,14 1,83 3,00 9,29 6,00 9,00 1,67 3,47 40 20 0,00 2,33 2,71 0,80 3,67 2,50 0,00 9,83 9,17 3,25 1,25 3,23

Tabela 3: Número de tripes (ninfas+adultos) por folha no Sítio Rosário

(Conclusão) X1 X2 21/06 29/06 07/07 14/07 21/07 28/07 08/04 08/11 18/08 25/08 09/03 Media 0,00 0,75 3,00 0,00 5,14 8,60 50 20 1,00 1,17 7,00 7,00 0,83 3,14 60 20 0,50 0,25 0,50 5,00 4,86 10,50 11,29 3,57 4,17 4,14 4,33 4,46 70 20 0,00 1,75 0,60 1,33 3,00 3,80 3,50 9,00 10,00 4,00 0,40 3,40 80 20 0,25 3,20 1,40 1,00 1,20 1,17 1,71 3,57 6,00 8,83 0,57 2,63 90 20 0,33 1,20 0,00 2,40 2,83 3,57 2,29 12,80 4,17 10,80 5,17 4,14 0,00 100 20 2,00 1,20 0,33 8,00 1,57 2,43 8,33 10,33 4,40 1,29 3,63 110 20 0,33 4,50 0,50 0,83 0,50 0,80 6,43 10,67 13,50 1,67 9,00 4,43 120 20 0,33 1,25 0,50 1,40 5,00 4,67 4,33 7,75 13,17 9,86 8,71 5,18 130 20 0,25 1,75 0,80 0,50 3,80 1,40 1,75 11,75 3,60 6,75 1,80 3,10 150 30 0,00 0,00 0,00 0,50 6,33 11,00 12,88 11,57 1,00 2,60 2,14 4,37 140 30 0,00 1,50 1,50 1,00 1,00 3,71 0,33 3,14 4,83 2,88 6,71 2,42 130 30 0,00 2,00 0,50 0,60 4,67 5,57 5,50 5,78 2,55 1,60 1,63 0,17 0,00 0,25 2,80 1,40 120 30 1,00 1,20 6,14 2,86 0,14 3,71 0,171,79 110 30 0,00 0,00 1,00 1,40 2,60 11,83 6,80 4,63 3,86 4,75 0,14 3,36 100 0,33 0,25 0,25 6,50 11,17 1,57 8,71 9,43 13,29 30 1,40 1,00 4,90 0,00 0,00 1,80 6,43 17,20 5,33 11,57 10,71 90 30 2,20 4,17 11,60 6,46 80 30 1,00 1,00 5,50 9,83 1,33 1,67 1,25 0,40 2,80 7,83 1,33 3,09 70 0,25 0,25 1,00 0,00 30 0,25 3,00 3,83 5,67 6,25 6,83 2,17 2,68 60 30 0,67 3,20 3,00 3,40 0,67 6,33 2,29 6,50 11,67 1,25 1,67 3,69 50 30 0,50 0,33 0,67 2,60 4,20 3,33 11,17 2,80 9,80 9,60 0,86 4,17 1,50 0.00 0,00 5,20 12,67 8,60 40 30 0,50 1,75 2,20 8,29 4,00 4,06 30 30 1,00 2,00 0,25 1,25 1,75 5,80 6,86 11,00 6,88 0,86 3,53 1,17 0,67 20 30 2,40 2,00 1,00 3,17 5,67 8,17 12,43 14,33 7,00 2,83 5,42 10 30 3,00 2,50 NA 1,60 7,60 4,83 7,67 12,57 15,29 7,83 1,50 6,44 0 30 0,67 2,50 1,40 2,80 5,67 NA 6,29 6,20 8,86 7,17 6,00 4,75

Tabela 4: Número de tripes (ninfas+adultos) por folha no sítio Novo II

(Continua) X1 X2 04/06 19/06 27/06 28/06 04/07 11/07 24/07 31/07 07/08 Media 2,70 125 0 1,80 1,86 0,88 3,38 5,00 0,83 0,00 2,04 1,88 115 0 0,00 0,17 0,43 0,70 0,22 3,13 2,43 4,13 1,60 1,42 105 0 1,27 0,00 0,00 0,00 0,00 1,11 5,71 0,50 0,00 0,96 5,33 95 0 0,20 0,14 0,86 2,75 0,00 0,83 0,43 1,25 1,31 85 0 0,00 0,14 0,14 2,57 0,22 5,44 2,44 0,00 0,00 1,22 75 0 0,00 0,71 2,60 4,00 0,43 1,63 3,33 0,00 0,00 1,41 0,00 0,88 65 0 0,00 0,00 0,13 2,44 2,44 0,97 1,17 1,67 55 0 0,00 0,14 1,14 0,38 1,11 1,57 0,20 0,00 2,00 0,73 45 0 0,43 0,43 0,71 4,67 1,00 5,56 3,00 2,20 0,00 2,00 35 0,33 0,00 0,00 1,09 0,17 5,25 5,78 1,57 5,00 2,13 0 25 0 0,33 0,00 0,57 4,36 0,14 2,57 2,75 1,78 5,00 1,95 20 10 0,33 0,33 1,75 0,00 0,43 2,00 0,25 1,33 0,00 0,71 30 10 0,20 0,00 0,50 1,38 1,30 2,29 0,00 0,29 0,91 2,22 40 10 0,14 0,43 0,88 2,00 0,14 3,89 0,00 0,00 2,00 1,05 50 10 0,00 0,75 1,00 2,67 0,25 2,89 0,00 0,00 1,00 1,44 0,00 0,50 0,20 2,55 0,44 2,00 6,22 2,29 60 10 3,67 5,00 70 10 0,83 0,00 2,14 2,33 0,60 3,11 0,00 2,22 1,27 0,20 80 10 0,00 0,00 0,00 3,10 0,00 3,11 3,56 0,56 2,50 1,42 90 10 0,00 0,00 1,25 2,91 0,89 2,78 1,33 0,33 0,80 1,14 100 10 0,20 1,38 0,71 3,89 2,22 0,14 3,71 4,17 2,38 5,00 110 10 0,20 1,00 1,71 0,00 2,00 14,29 0,00 0,00 0,00 2,13 120 10 0,60 1,86 0,83 4,11 0,89 4,89 0,00 1,43 0,67 1,70 130 10 0,50 2,14 0,11 0,43 1,33 0,33 31,00 2,57 4,29 4,74 140 10 0,83 0,00 0,00 1,11 0,25 0,14 0,00 0,00 0,00 0,26 155 20 1,00 0,14 0,14 0,38 0,75 4,33 4,33 0,50 2,86 1,60

Tabela 4: Número de tripes (ninfas+adultos) por folha no sítio Novo II (Continuação)

X1 X2 04/06 19/06 27/06 28/06 04/07 11/07 24/07 31/07 07/08 Media 145 20 0,00 1,17 2,71 0,29 2,14 0,00 2,00 0,22 0,00 0,95 0,80 135 20 2,57 1,50 1,14 2,71 3,14 0,00 0,00 0,00 1,32 7,29 125 20 1,57 0,43 0,83 3,56 1,75 1,50 0,00 0,40 1,92 115 20 0,00 0,57 0,71 1,13 1,29 2,78 0,00 0,92 0,70 1,13 105 20 0,17 0,00 0,00 1,70 2,00 2,75 0,00 0,86 0,25 0,86 95 20 0,00 0,00 0,50 0,63 1,00 1,78 0,67 1,20 0,33 0,68 85 20 0,00 0,86 0,20 0,00 2,75 2,38 1,64 1,75 0,00 1,06 75 20 0,00 0,14 1,00 0,00 1,00 3,73 4,25 0,00 0,00 1,12 65 20 1,50 0,67 2,43 0,71 4,14 1,50 0,29 0,00 15,00 2,92 0,20 55 20 0,00 0,14 2,33 2,33 2,00 0,25 2,22 5,71 1,69 45 20 0,00 2,14 0,71 2,00 3,00 0,29 0,11 4,14 0,43 1,43 0,00 35 20 0,14 1,13 2,86 0,44 2,78 2,36 1,00 0,00 1,19 1,50 0,88 1,44 2,44 25 20 0,44 0,75 2,38 0,57 3,75 1,57 15 20 0,00 3,71 3,00 3,90 0,11 1,29 1,25 0,00 0,00 1,47 0,60 0,00 2,00 0,25 10 30 0,67 4,10 4,89 1,88 3,67 2,01 20 30 0,80 0,71 1,00 0,57 0,00 3,67 2,17 1,50 0,00 1,16 0,20 30 30 1,00 1,60 2,91 1,13 2,43 3,00 1,33 5,71 2,15 40 30 0,14 1,29 2,78 1,00 0,67 0,00 4,00 1,56 3,29 1,63 50 30 0,00 1,14 3,89 0,00 0,33 0,29 3,57 7,73 2,78 2,19 2,22 60 30 0,40 0,43 0,00 0,00 1,50 0,00 0,40 1,86 0,76 1,22 1,71 3,67 70 30 0,00 0,33 0,17 3,00 3,00 2,00 1,68 80 30 0,50 4,14 3,00 3,11 1,25 0,78 0,00 0,57 2,22 1,73 90 30 0,80 0,80 1,60 7,38 1,56 0,00 4,57 2,00 10,00 3,19 100 30 0,40 0,83 0,17 4,63 3,29 3,33 0,00 0,43 1,89 1,66 110 30 0,80 0,00 6,50 4,90 2,75 1,33 0,14 1,71 2,13 2,25

Tabela 4: Número de tripes (ninfas+adultos) por folha no sítio Novo II (Continuação)

										(Conti	muaçac
X1	X2	04/06	19/06	27/06	28/06	04/07	11/07	24/07	31/07	07/08	Media
120	30	0,50	0,00	1,11	1,56	0,00	2,00	0,56	0,00	0,00	0,64
130	30	0,67	0,40	0,00	4,44	0,33	0,78	2,22	0,22	2,00	1,23
140	30	0,50	0,17	0,00	0,58	0,29	0,86	3,00	5,00	0,00	1,15
150	30	0,17	1,17	1,00	0,88	1,63	1,14	3,89	1,25	3,14	1,58
160	30	0,00	0,13	0,33	0,00	1,80	4,11	0,00	1,71	0,00	0,90
170	30	0,50	0,29	1,89	0,00	5,25	2,75	2,33	0,00	1,88	1,65
185	40	0,50	0,20	2,78	2,14	4,40	4,00	1,25	1,67	0,00	1,88
175	40	0,80	0,43	3,43	0,78	5,80	2,33	0,88	5,00	1,00	2,27
165	40	0,40	0,83	1,11	2,56	4,00	5,25	2,08	5,71	3,13	2,79
155	40	0,17	0,86	2,56	2,55	3,00	2,14	2,89	0,00	1,88	1,78
145	40	3,33	2,29	2,11	2,78	2,71	1,86	0,56	0,22	0,86	1,86
135	40	0,50	2,83	0,86	2,00	1,33	3,56	3,88	2,14	0,00	1,90
125	40	0,17	0,29	0,00	2,33	3,29	4,00	1,57	0,00	0,13	1,31
115	40	0,60	2,00	3,00	3,44	8,43	2,88	1,57	0,88	3,00	2,87
105	40	0,60	0,67	0,86	5,71	1,20	6,38	7,20	0,60	2,22	2,83
95	40	0,00	1,00	1,14	3,44	4,00	2,11	2,00	1,29	0,71	1,74
85	40	1,50	1,00	1,88	1,22	1,33	3,67	2,00	0,57	2,86	1,78
75	40	0,83	1,29	3,25	3,00	1,56	1,00	2,00	0,33	0,00	1,47
65	40	0,33	1,00	0,00	9,13	3,14	3,27	1,86	0,75	7,50	3,00
55	40	1,17	0,83	1,20	3,11	0,33	1,88	4,20	1,00	0,00	1,52
45	40	0,33	0,50	3,29	4,75	2,13	3,71	4,10	0,75	0,71	2,25
35	40	0,50	0,71	3,33	3,30	2,50	9,71	4,36	1,00	0,63	2,89
25	40	1,17	0,13	0,88	3,36	2,22	0,00	4,80	1,25	1,71	1,72
15	40	0,00	0,00	4,71	0,57	3,18	4,38	14,50	0,00	2,14	3,28
5	40	0,00	0,00	3,29	2,78	5,25	1,13	9,00	4,67	3,89	3,33

Tabela 4: Número de tripes (ninfas+adultos) por folha no sítio Novo II

(Conclusão) X1 X2 04/06 19/06 27/06 28/06 04/07 11/07 24/07 31/07 07/08 Media 0 50 1,83 1,00 0,57 8,89 6,89 5,43 1,63 2,00 0,56 3,20 10 50 0,33 0,00 0,14 0,50 3,10 4,44 0,33 2,14 2,14 1,46 0,33 0,29 20 50 1,00 2,44 1,57 0,63 4,38 3,33 3,57 1,95 30 50 1,50 1,00 0,00 0,86 0,80 1,25 13,14 2,86 0,00 2,38 40 50 0,50 0,00 2,43 1,00 2,11 1,43 0,43 7,29 1,85 1,50 0,20 0,89 50 50 0,29 1,29 2,57 2,00 6,88 0,00 2,00 1,79 60 50 0,20 0,00 3,86 1,67 3,25 2,11 2,63 0,00 1,60 0,71 70 50 0,00 0,60 0,57 3,33 0,13 4,50 5,00 5,33 4,00 2,61 80 50 0,17 0,71 0,00 0,78 0,29 1,57 4,11 0,00 0,67 0,92 90 50 0,60 0,00 0,83 4,83 1,00 0,71 3,11 0,67 1,14 1,43 100 50 0,00 0,14 1,00 0,00 2,44 2,71 0,00 0,13 0,90 1,67 110 50 0,00 0,33 0,86 2,00 0,00 0,80 5,00 3,60 1,56 1,57 120 50 1,00 0,50 0,29 1,00 2,83 3,50 3,88 0,18 0,00 1,46 130 50 0,25 0,88 3,00 1,29 3,75 4,89 5,00 0,57 0,00 2,18 140 50 0,00 0,14 2,50 1,00 2,13 2,55 0,00 0,00 1,78 1,12 150 50 0,20 0,43 0,25 1,00 1,63 4,63 8,13 0,00 2,00 1,71 160 50 0,00 0,00 2,14 2,56 1,58 0,56 0,22 5,63 1,00 1,52 170 50 0,25 0,57 3,38 1,33 2,43 1,18 2,13 1,33 1,67 1,59 0,43 180 50 0,00 1,43 9,29 3,63 4,00 0,88 0,17 4,14 2,66 190 50 7,50 1,57 4,00 0,00 2,25 4,00 5,75 0,00 2,83 0,40 200 50 0,60 0,50 3,86 3,00 5,70 0,00 2,70 3,89 1,50 2,42 210 50 4,40 0,83 2,71 6,25 0,78 3,18 4,71 0,18 2,75 1,71 220 50 4,50 1,29 3,00 3,00 0,00 4,11 0,00 0,00 4,14 2,23 230 50 2,14 0,00 0,57 2,38 2,86 3,17 5,83 0,00 0,33 1,92 240 50 1,75 0,17 0,33 3,50 2,75 2,78 0,00 0,00 3,33 1,62

Programa para construir o gráfico de pontos

```
x11(2.5,2.5,6)
require(geoRglm)
SP1007<-read.table("SP1007.TXT", head=F)
SP1007Geo<-as.geodata(SP1007, head=F, coords=1:2, data.col=5)
plot(SP1007Geo)
```

Programa para ajustar o modelo

```
require(geoRglm)
SP1007<-read.table("SP1007.TXT", head=F)
SP1007Geo<-as.geodata(SP1007, head=F, coords=1:2,
data.col=4, units.m.col=3)
plot(SP1007Geo)
mcmc.5 <- mcmc.control(S.scale = 0.6, thin=20,n.iter=50000,
burn.in=1000, S.start="random")
model.5 < -list(cov.pars=c(0.6, 0.01), beta=1, family="poisson")
outmcmc.5 <- glsm.mcmc(SP1007Geo, model= model.5, mcmc.input=
mcmc.5)
mcmcobj.5 <- prepare.likfit.glsm(outmcmc.5)</pre>
lik.5 <- likfit.glsm(mcmcobj.5, ini.phi = 0.1, fix.nugget.rel =
FALSE)
print(lik.5)
summary(lik.5)
lik.5.mat.nugget <- likfit.glsm(mcmcobj.5, ini.phi =1,cov.model =
"matern", nugget.rel = 0.385, units.m.col=3)
print(lik.5.mat.nugget)
summary(lik.5.mat.nugget)
lik.5.mat.nugget
```

APÊNDICE B

Programa para gerar as covariáveis A e B com dependência espacial

```
require(geoR)
cov1<-grf(400, grid = "reg", nx=20, ny=20, xlims = c(1, 20),
ylims = c(1, 20),cov.pars=c(1, 5))
cov2<-grf(400, grid = "reg", nx=20, ny=20, xlims = c(1, 20),
ylims = c(1, 20),cov.pars=c(1, 7))
```

Programa para gerar as covariáveis A e B - Variáveis correlacionadas

```
require(geoR) g1<-grf(400, grid = "reg", nx=20, ny=20, xlims = c(1, 20), ylims = c(1, 20), cov.pars=c(1, 6)) covA<-read.table("gercov1.txt", head=F) nor<-rnorm(400, 0, 1) norm<-matrix(nor, 20, 20) covB<-0.9*cov1+0.3*norm
```

Programa utilizado para a simulação considerando 4 vizinhos

```
# Lendo os dados
const<-0
a1<-1
a2<-1
esp<-1.00 n=1000
# Definindo a função
proc <- function(...)
# Lendo a covariável 1
cov1<-read.table("gercov1.txt", head=F)
# Lendo a covariável 2
cov2<-read.table("gercov2.txt", head=F)
# Definindo os parametros do modelo ajustado
# Ajustando o modelo para o primeiro passo do ajuste
m1<-const+a1*cov1+a2*cov2
# Calculando as probabilidades
```

```
prob1 < -exp(m1)/(1 + exp(m1))
pc1<-prob1[,1]
pc2<-prob1[,2]
pc3<-prob1[,3]
pc4<-prob1[,4]
pc5<-prob1[,5]
pc6<-prob1[,6]
pc7<-prob1[,7]
pc8<-prob1[,8]
pc9<-prob1[,9]
pc10<-prob1[,10]
pc11<-prob1[,11]
pc12<-prob1[,12]
pc13<-prob1[,13]
pc14<-prob1[,14]
pc15<-prob1[,15]
pc16<-prob1[,16]
pc17<-prob1[,17]
pc18<-prob1[,18]
pc19<-prob1[,19]
pc20<-prob1[,20]
# Condicional dos vetores
pasc1<-rbinom(20, size=1, prob=pc1)
pasc2<-rbinom(20, size=1, prob=pc2)
pasc3<-rbinom(20, size=1, prob=pc3)
pasc4<-rbinom(20, size=1, prob=pc4)
pasc5<-rbinom(20, size=1, prob=pc5)
pasc6<-rbinom(20, size=1, prob=pc6)
pasc7<-rbinom(20, size=1, prob=pc7)
pasc8<-rbinom(20, size=1, prob=pc8)
pasc9<-rbinom(20, size=1, prob=pc9)
pasc10<-rbinom(20, size=1, prob=pc10)
pasc11<-rbinom(20, size=1, prob=pc11)
pasc12<-rbinom(20, size=1, prob=pc12)
pasc13<-rbinom(20, size=1, prob=pc13)
pasc14<-rbinom(20, size=1, prob=pc14)
```

```
pasc15<-rbinom(20, size=1, prob=pc15)
pasc16<-rbinom(20, size=1, prob=pc16)
pasc17<-rbinom(20, size=1, prob=pc17)
pasc18<-rbinom(20, size=1, prob=pc18)
pasc19<-rbinom(20, size=1, prob=pc19)
pasc20<-rbinom(20, size=1, prob=pc20)
binp1<-cbind(pasc1, pasc2, pasc3, pasc4, pasc5, pasc6, pasc7,
pasc8, pasc9, pasc10, pasc11, pasc12, pasc13, pasc14, pasc15,
pasc16, pasc17, pasc18, pasc19, pasc20)
# Segundo passo do ajuste
m2 < -m1 for (i in 2:19)
for (j in 2:19)
m2[i,j] < -m1[i,j] + esp*(prob1[i-1,j] + prob1[i+1,j] + prob1[i,j-1] +
prob1[i,j+1])/4
# Calculando as probabilidades
prob2 < -exp(m2)/(1+exp(m2))
pc1<-prob2[,1]
pc2<-prob2[,2]
pc3<-prob2[,3]
pc4<-prob2[,4]
pc5<-prob2[,5]
pc6<-prob2[,6]
pc7<-prob2[,7]
pc8<-prob2[,8]
pc9<-prob2[,9]
pc10<-prob2[,10]
pc11<-prob2[,11]
pc12<-prob2[,12]
pc13<-prob2[,13]
pc14<-prob2[,14]
pc15<-prob2[,15]
pc16<-prob2[,16]
pc17<-prob2[,17]
pc18<-prob2[,18]
pc19<-prob2[,19]
pc20<-prob2[,20]
```

```
# Condicional dos vetores
pasc1<-rbinom(20, size=1, prob=pc1)
pasc2<-rbinom(20, size=1, prob=pc2)
pasc3<-rbinom(20, size=1, prob=pc3)
pasc4<-rbinom(20, size=1, prob=pc4)
pasc5<-rbinom(20, size=1, prob=pc5)
pasc6<-rbinom(20, size=1, prob=pc6)
pasc7<-rbinom(20, size=1, prob=pc7)
pasc8<-rbinom(20, size=1, prob=pc8)
pasc9<-rbinom(20, size=1, prob=pc9)
pasc10<-rbinom(20, size=1, prob=pc10)
pasc11<-rbinom(20, size=1, prob=pc11)
pasc12<-rbinom(20, size=1, prob=pc12)
pasc13<-rbinom(20, size=1, prob=pc13)
pasc14<-rbinom(20, size=1, prob=pc14)
pasc15<-rbinom(20, size=1, prob=pc15)
pasc16<-rbinom(20, size=1, prob=pc16)
pasc17<-rbinom(20, size=1, prob=pc17)
pasc18<-rbinom(20, size=1, prob=pc18)
pasc19<-rbinom(20, size=1, prob=pc19)
pasc20<-rbinom(20, size=1, prob=pc20)
binp2<-cbind(pasc1, pasc2, pasc3, pasc4, pasc5, pasc6, pasc7,
pasc8, pasc9, pasc10, pasc11, pasc12, pasc13, pasc14, pasc15,
pasc16, pasc17, pasc18, pasc19, pasc20)
# Segundo passo do ajuste
m3 < -m2 for (i in 2:19)
for (j in 2:19)
m3[i,j] < -m1[i,j] + esp*(prob2[i-1,j] + prob2[i+1,j] + prob2[i,j-1] +
prob2[i,j+1])/4
# Calculando as probabilidades
prob3 < -exp(m3)/(1+exp(m3))
pc1<-prob3[,1]
pc2<-prob3[,2]
pc3<-prob3[,3]
pc4<-prob3[,4]
pc5<-prob3[,5]
```

```
pc6<-prob3[,6]
pc7<-prob3[,7]
pc8<-prob3[,8]
pc9<-prob3[,9]
pc10<-prob3[,10]
pc11<-prob3[,11]
pc12<-prob3[,12]
pc13<-prob3[,13]
pc14<-prob3[,14]
pc15<-prob3[,15]
pc16<-prob3[,16]
pc17<-prob3[,17]
pc18<-prob3[,18]
pc19<-prob3[,19]
pc20<-prob3[,20]
# Condicional dos vetores
pasc1<-rbinom(20, size=1, prob=pc1)
pasc2<-rbinom(20, size=1, prob=pc2)
pasc3<-rbinom(20, size=1, prob=pc3)
pasc4<-rbinom(20, size=1, prob=pc4)
pasc5<-rbinom(20, size=1, prob=pc5)
pasc6<-rbinom(20, size=1, prob=pc6)
pasc7<-rbinom(20, size=1, prob=pc7)
pasc8<-rbinom(20, size=1, prob=pc8)
pasc9<-rbinom(20, size=1, prob=pc9)
pasc10<-rbinom(20, size=1, prob=pc10)
pasc11<-rbinom(20, size=1, prob=pc11)
pasc12<-rbinom(20, size=1, prob=pc12)
pasc13<-rbinom(20, size=1, prob=pc13)
pasc14<-rbinom(20, size=1, prob=pc14)
pasc15<-rbinom(20, size=1, prob=pc15)
pasc16<-rbinom(20, size=1, prob=pc16)
pasc17<-rbinom(20, size=1, prob=pc17)
pasc18<-rbinom(20, size=1, prob=pc18)
pasc19<-rbinom(20, size=1, prob=pc19)
pasc20<-rbinom(20, size=1, prob=pc20)
```

```
binp3<-cbind(pasc1, pasc2, pasc3, pasc4, pasc5, pasc6, pasc7,
pasc8, pasc9, pasc10, pasc11, pasc12, pasc13, pasc14, pasc15,
pasc16, pasc17, pasc18, pasc19, pasc20)
autocov1<-m3 autocov2<-m3 r2<-sqrt(2)
for (i in 2:19)
for (j in 2:19)
autocov1[i,j] < -(binp3[i-1,j] + binp3[i+1,j] + binp3[i,j-1] +
binp3[i,j+1])/4
respb<-matrix(0, 18, 18)
respb<-binp3[2:19,2:19]
respb1 < -matrix(0, 324, 1)
respb2<-binp3[2:19, 2]
respb3<-binp3[2:19, 3]
respb4<-binp3[2:19, 4]
respb5<-binp3[2:19, 5]
respb6<-binp3[2:19, 6]
respb7<-binp3[2:19, 7]
respb8<-binp3[2:19, 8]
respb9<-binp3[2:19, 9]
respb10<-binp3[2:19, 10]
respb11<-binp3[2:19, 11]
respb12<-binp3[2:19, 12]
respb13<-binp3[2:19, 13]
respb14<-binp3[2:19, 14]
respb15<-binp3[2:19, 15]
respb16<-binp3[2:19, 16]
respb17<-binp3[2:19, 17]
respb18<-binp3[2:19, 18]
respb19<-binp3[2:19, 19]
respb1<-cbind(respb2, respb3, respb4, respb5, respb6, respb7,
respb8, respb9, respb10, respb11, respb12, respb13, respb14,
respb15, respb16, respb17, respb18, respb19)
respb1<-as.vector(respb1)
cov1b<-cbind(cov1[2:19, 2], cov1[2:19, 3], cov1[2:19, 4],
cov1[2:19, 5], cov1[2:19, 6], cov1[2:19, 7], cov1[2:19, 8],
cov1[2:19, 9], cov1[2:19, 10], cov1[2:19, 11], cov1[2:19, 12],
```

```
cov1[2:19, 13], cov1[2:19, 14], cov1[2:19, 15], cov1[2:19, 16],
cov1[2:19, 17], cov1[2:19, 18], cov1[2:19, 19])
cov1b<-as.vector(cov1b)
cov2b<-cbind(cov2[2:19, 2], cov2[2:19, 3], cov2[2:19, 4],
cov2[2:19, 5], cov2[2:19, 6], cov2[2:19, 7], cov2[2:19, 8],
cov2[2:19, 9], cov2[2:19, 10], cov2[2:19, 11], cov2[2:19, 12],
cov2[2:19, 13], cov2[2:19, 14], cov2[2:19, 15], cov2[2:19, 16],
cov2[2:19, 17], cov2[2:19, 18], cov2[2:19, 19])
cov2b<-as.vector(cov2b)
autocov12<-autocov1[2:19, 2]
autocov13<-autocov1[2:19, 3]
autocov14<-autocov1[2:19, 4]
autocov15<-autocov1[2:19, 5]
autocov16<-autocov1[2:19, 6]
autocov17<-autocov1[2:19, 7]
autocov18<-autocov1[2:19, 8]
autocov19<-autocov1[2:19, 9]
autocov110<-autocov1[2:19, 10]
autocov111<-autocov1[2:19, 11]
autocov112<-autocov1[2:19, 12]
autocov113<-autocov1[2:19, 13]
autocov114<-autocov1[2:19, 14]
autocov115<-autocov1[2:19, 15]
autocov116<-autocov1[2:19, 16]
autocov117<-autocov1[2:19, 17]
autocov118<-autocov1[2:19, 18]
autocov119<-autocov1[2:19, 19]
autocov1<-cbind(autocov12, autocov13, autocov14, autocov15,
autocov16, autocov17, autocov18, autocov19, autocov110,
autocov111, autocov112, autocov113, autocov114, autocov115,
autocov116, autocov117, autocov118, autocov119)
autocovb1<-as.vector(autocov1)
mod1<-glm(respb1 cov1b+cov2b+autocovb1, family=binomial)
s1<-summary(mod1)
mod2<-glm(respb1 autocovb1, family=binomial)
s2<-summary(mod2)
```

```
mod3<-glm(respb1 cov1b+cov2b, family=binomial)
s3<-summary(mod3)
require(Rcitrus)
coves<-read.table("coves.txt", head=F)
coves<-c(covesV1, covesV2)
covars <- array(coves, dim=c(dim(cov2),2), dimnames=list(NULL, NULL, c("m", "l")))
mod4 <- autologistic.citrus(Y m+l+R+C, obj=binp3, covariate=covars)
s4<-summary(mod4)
mod5 <- autologistic.citrus(Y R+C, obj=binp3, covariate=covars)
s5<-summary(mod5)
mod6 <- autologistic.citrus(Y m+l, obj=binp3, covariate=covars)
s6<-summary(mod6)
return(list(MBin=mean(binp3), M1p1=s1$coef[1,1],
M1p2=s1$coef[2,1], M1p3=s1$coef[3,1], M1p4=s1$coef[4,1],
M1ep1=s1$coef[1,2], M1ep2=s1$coef[2,2], M1ep3=s1$coef[3,2],
M1ep4=s1$coef[4,2], M2p1=s2$coef[1,1], M2p2=s2$coef[2,1],
M1ep1=s2$coef[1,2], M2ep2=s2$coef[2,2], M3p1=s3$coef[1,1],
M3p2=s3$coef[2,1], M3p3=s3$coef[3,1], M3ep1=s3$coef[1,2],
M3ep2=s3$coef[2,2], M3epe=s3$coef[3,2], M4p1=s4$coef[1,1],
M4p2=s4$coef[2,1], M4p3=s4$coef[3,1], M4p4=s4$coef[4,1],
M4p5=s4$coef[5,1], M4ep1=s4$coef[1,2], M4ep2=s4$coef[2,2],
M4ep3=s4$coef[3,2], M4ep4=s4$coef[4,2], M4ep5=s4$coef[5,2],
M5p1=s5$coef[1,1], M5p2=s5$coef[2,1], M5p3=s5$coef[3,1],
M5ep1=s5$coef[1,2], M5ep2=s5$coef[2,2], M5ep3=s5$coef[3,2],
M6p1=s6$coef[1,1], M6p2=s6$coef[2,1], M6p3=s6$coef[3,1],
M6ep1=s6$coef[1,2], M6ep2=s6$coef[2,2], M6ep3=s6$coef[3,2],
QM1p1=(s1\$coef[1,1])\hat{2}, QM1p2=(s1\$coef[2,1])\hat{2},
QM1p3 = (s1\$coef[3,1])\hat{2}, QM1p4 = (s1\$coef[4,1])\hat{2},
QM2p1=(s2\$coef[1,1])\hat{2}, QM2p2=(s2\$coef[2,1])\hat{2},
QM3p1=(s3$coef[1,1])2, QM3p2=(s3$coef[2,1])2,
QM3p3=(s3$coef[3,1])2, QM4p1=(s4$coef[1,1])2,
QM4p2=(s4$coef[2,1])2, QM4p3=(s4$coef[3,1])2,
QM4p4=(s4\$coef[4,1])\hat{2}, QM4p5=(s4\$coef[5,1])\hat{2},
QM5p1=(s5$coef[1,1])\hat{2}, QM5p2=(s5$coef[2,1])\hat{2},
QM5p3 = (s5\$coef[3,1])\hat{2}, QM6p1 = (s6\$coef[1,1])\hat{2},
QM6p2=(s6\$coef[2,1])\hat{2}, QM6p3=(s6\$coef[3,1])\hat{2}))
```

```
set.seed(0602)
res <- sapply(1:n, proc)
P1<-(as.vector((res[1,]), mode="numeric")) summary(P1)
M1Int<-(as.vector((res[2,]), mode="numeric")) summary(M1Int)
M1Cov1<-(as.vector((res[3,]), mode="numeric")) summary(M1Cov1)
M1Cov2<-(as.vector((res[4,]), mode="numeric")) summary(M1Cov2)
M1AutC<-(as.vector((res[5,]), mode="numeric")) summary(M1AutC)
M1Intep<-(as.vector((res[6,]), mode="numeric")) summary(M1Intep)
M1Cov1ep<-(as.vector((res[7,]), mode="numeric")) summary(M1Cov1ep)
M1Cov2ep<-(as.vector((res[8,]), mode="numeric")) summary(M1Cov2ep)
M1AutCep<-(as.vector((res[9,]), mode="numeric")) summary(M1AutCep)
M2Int<-(as.vector((res[10,]), mode="numeric")) summary(M2Int)
M2AutC<-(as.vector((res[11,]), mode="numeric")) summary(M2AutC)
M2Intep<-(as.vector((res[12,]), mode="numeric")) summary(M2Intep)
M2AutCep<-(as.vector((res[13,]), mode="numeric"))
summary(M2AutCep)
M3Int<-(as.vector((res[14,]), mode="numeric"))
summary(M3Int)
M3Cov1<-(as.vector((res[15,]), mode="numeric"))
summary(M3Cov1)
M3Cov2<-(as.vector((res[16,]), mode="numeric"))
summary(M3Cov2)
M3Intep<-(as.vector((res[17,]), mode="numeric"))
summary(M3Intep)
M3Cov1ep<-(as.vector((res[18,]), mode="numeric"))
summary(M3Cov1ep)
M3Cov2ep<-(as.vector((res[19,]), mode="numeric"))
summary(M3Cov2ep)
M4Int<-(as.vector((res[20,]), mode="numeric"))
summary(M4Int)
M4Cov1<-(as.vector((res[21,]), mode="numeric"))
summary(M4Cov1)
M4Cov2<-(as.vector((res[22,]), mode="numeric"))
summary(M4Cov2)
M4R<-(as.vector((res[23,]), mode="numeric"))
```

```
summary(M4R)
M4C<-(as.vector((res[24,]), mode="numeric"))
summary(M4C)
M4Intep<-(as.vector((res[25,]), mode="numeric"))
summary(M4Intep)
M4Cov1ep<-(as.vector((res[26,]), mode="numeric"))
summary(M4Cov1ep)
M4Cov2ep<-(as.vector((res[27,]), mode="numeric"))
summary(M4Cov2ep)
M4Rep<-(as.vector((res[28,]), mode="numeric"))
summary(M4Rep)
M4Cep<-(as.vector((res[29,]), mode="numeric"))
summary(M4Cep)
M5Int<-(as.vector((res[30,]), mode="numeric"))
summary(M5Int)
M5R<-(as.vector((res[31,]), mode="numeric"))
summary(M5R)
M5C<-(as.vector((res[32,]), mode="numeric"))
summary(M5C)
M5Intep<-(as.vector((res[33,]), mode="numeric"))
summary(M5Intep)
M5Rep<-(as.vector((res[34,]), mode="numeric"))
summary(M5Rep)
M5Cep<-(as.vector((res[35,]), mode="numeric"))
summary(M5Cep)
M6Int<-(as.vector((res[36,]), mode="numeric"))
summary(M6Int)
M6Cov1<-(as.vector((res[37,]), mode="numeric"))
summary(M6Cov1)
M6Cov2<-(as.vector((res[38,]), mode="numeric"))
summary(M6Cov2)
M6Intep<-(as.vector((res[39,]), mode="numeric"))
summary(M6Intep)
M6Cov1ep<-(as.vector((res[40,]), mode="numeric"))
summary(M6Cov1ep)
M6Cov2ep<-(as.vector((res[41,]), mode="numeric"))
```

```
summary(M6Cov2ep)
QM1Int<-(as.vector((res[42,]), mode="numeric"))
summary(QM1Int)
QM1Cov1<-(as.vector((res[43,]), mode="numeric"))
summary(QM1Cov1)
QM1Cov2<-(as.vector((res[44,]), mode="numeric"))
summary(QM1Cov2)
QM1AutC<-(as.vector((res[45,]), mode="numeric"))
summary(QM1AutC)
QM2Int<-(as.vector((res[46,]), mode="numeric"))
summary(QM2Int)
QM2AutC<-(as.vector((res[47,]), mode="numeric"))
summary(QM2AutC)
QM3Int<-(as.vector((res[48,]), mode="numeric"))
summary(QM3Int)
QM3Cov1<-(as.vector((res[49,]), mode="numeric"))
summary(QM3Cov1)
QM3Cov2<-(as.vector((res[50,]), mode="numeric"))
summary(QM3Cov2)
QM4Int<-(as.vector((res[51,]), mode="numeric"))
summary(QM4Int)
QM4Cov1<-(as.vector((res[52,]), mode="numeric"))
summary(QM4Cov1)
QM4Cov2<-(as.vector((res[53,]), mode="numeric"))
summary(QM4Cov2)
QM4R<-(as.vector((res[54,]), mode="numeric"))
summary(QM4R)
QM4C<-(as.vector((res[55,]), mode="numeric"))
summary(QM4C)
QM5Int<-(as.vector((res[56,]), mode="numeric"))
summary(QM5Int)
QM5R<-(as.vector((res[57,]), mode="numeric"))
summary(QM5R)
QM5C<-(as.vector((res[58,]), mode="numeric"))
summary(QM5C)
QM6Int<-(as.vector((res[59,]), mode="numeric"))
```

```
summary(QM6Int)
QM6Cov1<-(as.vector((res[60,]), mode="numeric"))
summary(QM6Cov1)
QM6Cov2<-(as.vector((res[61,]), mode="numeric"))
summary(QM6Cov2)</pre>
```

Programa utilizado para os dados originais considerando 4 vizinhos

```
# Lendo a variável resposta
resp<-read.table("dadoBP.txt", head=F)</pre>
# Lendo a covariável 1
cov1<-read.table("cov1.txt", head=F)
# Lendo a covariável 2
cov2<-read.table("cov2.txt", head=F)
autocov1<-matrix(0, 20, 20)
respb<-matrix(0, 18, 18)
for (i in 2:19)
for (j in 2:19)
autocov1[i,j] < -(resp[i-1,j] + resp[i+1,j] + resp[i,j-1] +
resp[i,j+1])/4
respb<-matrix(0, 18, 18)
respb<-resp[2:19,2:19]
respb1<-matrix(0, 324, 1)
respb2<-resp[2:19, 2]
respb3<-resp[2:19, 3]
respb4<-resp[2:19, 4]
respb5<-resp[2:19, 5]
respb6<-resp[2:19, 6]
respb7<-resp[2:19, 7]
respb8<-resp[2:19, 8]
respb9<-resp[2:19, 9]
respb10<-resp[2:19, 10]
respb11<-resp[2:19, 11]
respb12<-resp[2:19, 12]
respb13<-resp[2:19, 13]
```

```
respb14<-resp[2:19, 14]
respb15<-resp[2:19, 15]
respb16<-resp[2:19, 16]
respb17<-resp[2:19, 17]
respb18<-resp[2:19, 18]
respb19<-resp[2:19, 19]
respb1<-cbind(respb2, respb3, respb4, respb5, respb6, respb7,
respb8, respb9, respb10, respb11, respb12, respb13, respb14,
respb15, respb16, respb17, respb18, respb19)
respb1<-as.vector(respb1)
cov1b<-cbind(cov1[2:19, 2], cov1[2:19, 3], cov1[2:19, 4],
cov1[2:19, 5], cov1[2:19, 6], cov1[2:19, 7], cov1[2:19, 8],
cov1[2:19, 9], cov1[2:19, 10], cov1[2:19, 11], cov1[2:19, 12],
cov1[2:19, 13], cov1[2:19, 14], cov1[2:19, 15], cov1[2:19, 16],
cov1[2:19, 17], cov1[2:19, 18], cov1[2:19, 19])
cov1b<-as.vector(cov1b)
cov2b<-cbind(cov2[2:19, 2], cov2[2:19, 3], cov2[2:19, 4],
cov2[2:19, 5], cov2[2:19, 6], cov2[2:19, 7], cov2[2:19, 8],
cov2[2:19, 9], cov2[2:19, 10], cov2[2:19, 11], cov2[2:19, 12],
cov2[2:19, 13], cov2[2:19, 14], cov2[2:19, 15], cov2[2:19, 16],
cov2[2:19, 17], cov2[2:19, 18], cov2[2:19, 19])
cov2b<-as.vector(cov2b)
autocov12<-autocov1[2:19, 2]
autocov13<-autocov1[2:19, 3]
autocov14<-autocov1[2:19, 4]
autocov15<-autocov1[2:19, 5]
autocov16<-autocov1[2:19, 6]
autocov17<-autocov1[2:19, 7]
autocov18<-autocov1[2:19, 8]
autocov19<-autocov1[2:19, 9]
autocov110<-autocov1[2:19, 10]
autocov111<-autocov1[2:19, 11]
autocov112<-autocov1[2:19, 12]
autocov113<-autocov1[2:19, 13]
autocov114<-autocov1[2:19, 14]
autocov115<-autocov1[2:19, 15]
```

```
autocov116<-autocov1[2:19, 16]
autocov117<-autocov1[2:19, 17]
autocov118<-autocov1[2:19, 18]
autocov119<-autocov1[2:19, 19]
autocov1<-cbind(autocov12, autocov13, autocov14, autocov15,
autocov16, autocov17, autocov18, autocov19, autocov110,
autocov111, autocov112, autocov113, autocov114, autocov115,
autocov116, autocov117, autocov118, autocov119)
autocovb1<-as.vector(autocov1)</pre>
mod1<-glm(respb1 cov1b+cov2b+autocovb1, family=binomial)
s1<-summary(mod1)
mod2<-glm(respb1 autocovb1, family=binomial)
s2<-summary(mod2)
mod3<-glm(respb1 cov1b+cov2b, family=binomial)
s3<-summary(mod3)
require(Rcitrus)
coves<-read.table("coves.txt", head=F) coves<-c(covesV1, covesV2)
covars <- array(coves, dim=c(dim(cov2),2), dimnames=list(NULL,
NULL, c("m", "l"))) mod4 <- autologistic.citrus(Y m+l+R+C,
obj=resp, covariate=covars) s4<-summary(mod4)
mod5 <- autologistic.citrus(Y R+C, obj=resp, covariate=covars)
s5<-summary(mod5)
mod6 <- autologistic.citrus(Y m+l, obj=resp, covariate=covars)
s6<-summary(mod6)
s1
s2
s3
s4
s5
s6
```

Programa para estimar a covariável 2 considerando 4 vizinhos

```
# Lendo a variável resposta
resp<-read.table("dadoBP.txt", head=F)
```

```
# Lendo a covariável 1
cov1<-read.table("cov1.txt", head=F)
# Lendo a covariável 2
cov2<-read.table("cov28viz.txt", head=F)
autocov2<-matrix(0, 20, 20)
respb<-matrix(0, 18, 18)
r2 < -sqrt(2)
for (i in 2:19)
for (j in 2:19)
autocov2[i,j] < -(resp[i-1,j] + resp[i+1,j] + resp[i,j-1] +
resp[i,j+1] + resp[i-1,j-1]/r2 + resp[i+1,j-1]/r2 +
resp[i-1,j+1]/r2+resp[i+1,j+1]/r2)/(4+4/r2)
respb<-matrix(0, 18, 18)
respb<-resp[2:19,2:19]
respb1<-matrix(0, 324, 1)
respb2<-resp[2:19, 2]
respb3<-resp[2:19, 3]
respb4<-resp[2:19, 4]
respb5<-resp[2:19, 5]
respb6<-resp[2:19, 6]
respb7<-resp[2:19, 7]
respb8<-resp[2:19, 8]
respb9<-resp[2:19, 9]
respb10<-resp[2:19, 10]
respb11<-resp[2:19, 11]
respb12<-resp[2:19, 12]
respb13<-resp[2:19, 13]
respb14<-resp[2:19, 14]
respb15<-resp[2:19, 15]
respb16<-resp[2:19, 16]
respb17<-resp[2:19, 17]
respb18<-resp[2:19, 18]
respb19<-resp[2:19, 19]
respb1<-cbind(respb2, respb3, respb4, respb5, respb6, respb7,
respb8, respb9, respb10, respb11, respb12, respb13, respb14,
respb15, respb16, respb17, respb18, respb19)
```

```
respb1<-as.vector(respb1)
cov1b<-cbind(cov1[2:19, 2], cov1[2:19, 3], cov1[2:19, 4],
cov1[2:19, 5], cov1[2:19, 6], cov1[2:19, 7], cov1[2:19, 8],
cov1[2:19, 9], cov1[2:19, 10], cov1[2:19, 11], cov1[2:19, 12],
cov1[2:19, 13], cov1[2:19, 14], cov1[2:19, 15], cov1[2:19, 16],
cov1[2:19, 17], cov1[2:19, 18], cov1[2:19, 19])
cov1b<-as.vector(cov1b)
cov2b<-cbind(cov2[2:19, 2], cov2[2:19, 3], cov2[2:19, 4],
cov2[2:19, 5], cov2[2:19, 6], cov2[2:19, 7], cov2[2:19, 8],
cov2[2:19, 9], cov2[2:19, 10], cov2[2:19, 11], cov2[2:19, 12],
cov2[2:19, 13], cov2[2:19, 14], cov2[2:19, 15], cov2[2:19, 16],
cov2[2:19, 17], cov2[2:19, 18], cov2[2:19, 19])
cov2b<-as.vector(cov2b)
autocov22<-autocov2[2:19, 2]
autocov23<-autocov2[2:19, 3]
autocov24<-autocov2[2:19, 4]
autocov25<-autocov2[2:19, 5]
autocov26<-autocov2[2:19, 6]
autocov27<-autocov2[2:19, 7]
autocov28<-autocov2[2:19, 8]
autocov29<-autocov2[2:19, 9]
autocov210<-autocov2[2:19, 10]
autocov211<-autocov2[2:19, 11]
autocov212<-autocov2[2:19, 12]
autocov213<-autocov2[2:19, 13]
autocov214<-autocov2[2:19, 14]
autocov215<-autocov2[2:19, 15]
autocov216<-autocov2[2:19, 16]
autocov217<-autocov2[2:19, 17]
autocov218<-autocov2[2:19, 18]
autocov219<-autocov2[2:19, 19]
autocov2<-cbind(autocov22, autocov23, autocov24, autocov25,
autocov26, autocov27, autocov28, autocov29, autocov210,
autocov211, autocov212, autocov213, autocov214, autocov215,
autocov216, autocov217, autocov218, autocov219)
autocovb2<-as.vector(autocov2)</pre>
```

```
mod1<-glm(respb1 cov1b+cov2b+autocovb2, family=binomial)
s1<-summary(mod1)
mod2<-glm(respb1 autocovb2, family=binomial)
s2<-summary(mod2)
mod3<-glm(respb1 cov1b+cov2b, family=binomial)</pre>
s3<-summary(mod3)
require(Rcitrus)
coves<-read.table("coves8viz.txt", head=F) coves<-c(covesV1, covesV2)
covars <- array(coves, dim=c(dim(cov2),2), dimnames=list(NULL, NULL, c("m", "l")))
mod4 <- autologistic.citrus(Y m+l+dA+dB+R+C, obj=resp,
covariate=covars)
s4<-summary(mod4)
mod5 <- autologistic.citrus(Y dA+dB+R+C, obj=resp,
covariate=covars)
s5<-summary(mod5)
mod6 <- autologistic.citrus(Y m+l, obj=resp, covariate=covars)
s6<-summary(mod6)
s1
s2
s3
s4
s5
s6
```

Programa utilizado para análise dos dados considerando 1% de observações faltantes e 8 vizinhos

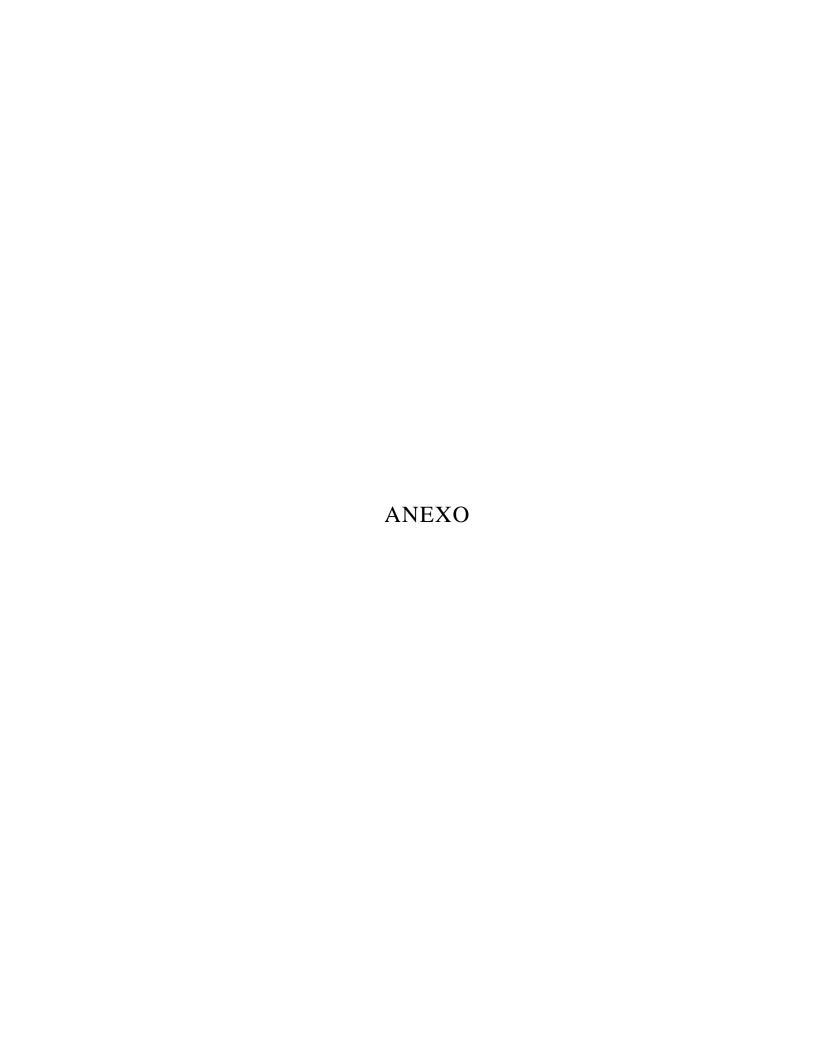
```
# Lendo a variável resposta
resp<-read.table("M1.txt", head=F)
# Lendo a covariável 1
cov1<-read.table("cov1.txt", head=F)
# Lendo a covariável 2
cov2<-read.table("cov28viz.txt", head=F)
m1<-resp
m1[7,14]<-0.133838384
```

```
m1[11,5]<-0.133838384
m1[13,11]<-0.133838384
m1[16,16]<-0.133838384
resp<-m1
autocov2<-matrix(0, 20, 20) respb<-matrix(0, 18, 18)
r2 < -sqrt(2)
for (i in 2:19)
for (j in 2:19)
autocov2[i,j] < -(resp[i-1,j] + resp[i+1,j] + resp[i,j-1] +
resp[i,j+1] + resp[i-1,j-1]/r2 + resp[i+1,j-1]/r2 +
resp[i-1,j+1]/r2+resp[i+1,j+1]/r2)/(4+4/r2)
respb<-matrix(0, 18, 18)
respb<-resp[2:19,2:19]
respb1<-matrix(0, 324, 1)
respb2<-resp[2:19, 2]
respb3<-resp[2:19, 3]
respb4<-resp[2:19, 4]
respb5<-resp[2:19, 5]
respb6<-resp[2:19, 6]
respb7<-resp[2:19, 7]
respb8<-resp[2:19, 8]
respb9<-resp[2:19, 9]
respb10<-resp[2:19, 10]
respb11<-resp[2:19, 11]
respb12<-resp[2:19, 12]
respb13<-resp[2:19, 13]
respb14<-resp[2:19, 14]
respb15<-resp[2:19, 15]
respb16<-resp[2:19, 16]
respb17<-resp[2:19, 17]
respb18<-resp[2:19, 18]
respb19<-resp[2:19, 19]
respb1<-cbind(respb2, respb3, respb4, respb5, respb6, respb7,
respb8, respb9, respb10, respb11, respb12, respb13, respb14,
respb15, respb16, respb17, respb18, respb19)
respb1<-as.vector(respb1)
```

```
cov1b<-cbind(cov1[2:19, 2], cov1[2:19, 3], cov1[2:19, 4],
cov1[2:19, 5], cov1[2:19, 6], cov1[2:19, 7], cov1[2:19, 8],
cov1[2:19, 9], cov1[2:19, 10], cov1[2:19, 11], cov1[2:19, 12],
cov1[2:19, 13], cov1[2:19, 14], cov1[2:19, 15], cov1[2:19, 16],
cov1[2:19, 17], cov1[2:19, 18], cov1[2:19, 19])
cov1b<-as.vector(cov1b)
cov2b<-cbind(cov2[2:19, 2], cov2[2:19, 3], cov2[2:19, 4],
cov2[2:19, 5], cov2[2:19, 6], cov2[2:19, 7], cov2[2:19, 8],
cov2[2:19, 9], cov2[2:19, 10], cov2[2:19, 11], cov2[2:19, 12],
cov2[2:19, 13], cov2[2:19, 14], cov2[2:19, 15], cov2[2:19, 16],
cov2[2:19, 17], cov2[2:19, 18], cov2[2:19, 19])
cov2b<-as.vector(cov2b)
autocov22<-autocov2[2:19, 2]
autocov23<-autocov2[2:19, 3]
autocov24<-autocov2[2:19, 4]
autocov25<-autocov2[2:19, 5]
autocov26<-autocov2[2:19, 6]
autocov27<-autocov2[2:19, 7]
autocov28<-autocov2[2:19, 8]
autocov29<-autocov2[2:19, 9]
autocov210<-autocov2[2:19, 10]
autocov211<-autocov2[2:19, 11]
autocov212<-autocov2[2:19, 12]
autocov213<-autocov2[2:19, 13]
autocov214<-autocov2[2:19, 14]
autocov215<-autocov2[2:19, 15]
autocov216<-autocov2[2:19, 16]
autocov217<-autocov2[2:19, 17]
autocov218<-autocov2[2:19, 18]
autocov219<-autocov2[2:19, 19]
autocov2<-cbind(autocov22, autocov23, autocov24, autocov25,
autocov26, autocov27, autocov28, autocov29, autocov210,
autocov211, autocov212, autocov213, autocov214, autocov215,
autocov216, autocov217, autocov218, autocov219)
autocovb2<-as.vector(autocov2)</pre>
autocov2
```

```
mod1<-glm(respb1 cov1b+cov2b+autocovb2, family=binomial)
s1<-summary(mod1)
mod2<-glm(respb1 autocovb2, family=binomial)
s2<-summary(mod2)
mod3<-glm(respb1 cov1b+cov2b, family=binomial)
s3<-summary(mod3)
require(Rcitrus)
coves<-read.table("coves8viz.txt", head=F)
coves<-c(covesV1, covesV2)
covars <- array(coves, dim=c(dim(cov2),2),
dimnames=list(NULL, NULL, c("m", "l")))
mod4 <- autologistic.citrus(Y m+l+dA+dB+R+C, obj=resp,
covariate=covars)
s4<-summary(mod4)
mod5 <- autologistic.citrus(Y dA+dB+R+C, obj=resp,
covariate=covars)
s5<-summary(mod5)
mod6 <- autologistic.citrus(Y m+l, obj=resp, covariate=covars)
s6<-summary(mod6) s1
s2
s3
s4
s5
s6
coef1 < -s1$coef[1,1]
coef2 < -s1$coef[2,1]
coef3<-s1$coef[3,1]
coef4 < -s1$coef[4,1]
s1
coef1
coef2
coef3
coef4
p1<-matrix(0, 20, 20)
p1<-coef1+coef2*cov1+coef3*cov2+coef4*autocov2
eat<-matrix(0, 20, 20)
```

```
 \begin{tabular}{ll} \# \ Calculando \ as \ probabilidades \ eat <-exp(p1)/(1+exp(p1)) \\ m1[7,14] <-eat[7,14] \\ m1[11,5] <-eat[7,14] \\ m1[13,11] <-eat[7,14] \\ m1[16,16] <-eat[7,14] \\ resp <-m1 \\ \end{tabular}
```



ANEXO A

Tabela 3.5 – Estatísticas Descritivas - Fazenda São Paulo

Datas	Média	Var.	Mín.	Máx.	N	p
10/07	0,25	0,43	0,00	6,20	100	0,56
24/07	0,56	1,08	0,00	5,17	100	0,51
21/07	0,08	0,02	0,00	1,00	100	0,35
07/08	1,18	2,56	0,00	10,00	98	0,69
14/08	1,87	3,49	0,00	9,00	100	0,84
21/08	2,09	2,94	0,00	7,78	100	0,89
28/08	2,32	4,50	0,00	10,50	100	0,83
04/09	6,94	15,61	1,11	30,00	100	1,00

Tabela 3.6 – Eatísticas Descritivas - Estância Bela Vista

Datas	Média	Var.	Mín.	Máx.	N	p
11/07	6,03	11,25	1,25	22,50	100	0,89
01/08	11,00	25,76	1,33	21,00	100	1,00
08/08	12,14	34,89	1,17	25,83	84	1,00
14/08	6,03	20,53	0,00	26,00	99	1,00
09/09	7,15	34,12	0,00	30,00	99	0,98

Tabela 3.7 – Eatísticas Descritivas - Sítio Rosário

Datas	Média	Var.	Mín.	Máx.	N	p
21/06	0,52	1,20	0,00	7,00	50	0,56
29/06	1,67	1,73	0,00	5,40	50	0,90
07/07	0,98	0,70	0,00	3,20	48	0,90
14/07	1,44	0,80	0,00	3,40	50	0,98
21/07	2,30	4,14	0,00	8,00	50	0,94
28/07	4,42	10,68	0,33	12,67	50	1,00
04/08	4,72	6,24	0,00	12,67	50	0,98
11/08	7,63	8,81	2,86	17,20	50	1,00
18/08	8,61	16,25	0,14	20,00	50	1,00
25/08	5,80	11,13	0,20	13,29	50	1,00
03/09	2,95	10,21	0,00	10,83	50	0,98

Tabela 3.8 – Eatísticas Descritivas - Sítio Novo II

Datas	Média	Var.	Mín.	Máx.	N	p
04/06	0,60	1,11	0,00	7,50	100	0,69
19/06	0,67	0,60	0,00	4,14	100	0,78
27/06	1,53	2,00	0,00	9,29	100	0,88
28/06	2,22	3,33	0,00	9,13	100	0,90
04/07	1,76	2,79	0,00	8,43	100	0,93
11/07	3,15	12,32	0,00	31,00	100	0,96
24/07	2,80	6,89	0,00	14,50	100	0,84
31/07	1,25	2,77	0,00	7,73	100	0,71
07/08	1,85	5,17	0,00	15,00	100	0,74

Tabela 3.9 – Resumo estatístico para β

Prorpiedade	Data	Mín.	Q1	Md	\overline{X}	Q3	Máx.	Var.
Fazenda São Paulo	10/07	-0,60	-0,55	-0,53	-0,53	-0,52	-0,34	0,001
	24/07	-0,86	-0,76	-0,73	-0,73	-0,70	-0,52	0,002
	31/07	-1,00	-0,94	-0,92	-0,92	-0,91	-0,84	0,001
Estância Bela Vista	08/08	2,33	2,35	2,36	2,36	2,36	2,39	0,0001
Sítio Novo II	04/06	-0,48	-0,41	-0,30	-0,31	-0,23	-0,05	0,009
	27/06	0,11	0,19	0,21	0,21	0,23	0,30	0,001
	04/07	0,18	0,25	0,26	0,26	0,28	0,37	0,001

Tabela 3.10 – Resumo estatístico para σ^2

Prorpiedade	Data	Mín.	Q1	Md	\overline{X}	Q3	Máx.	Var.
Fazenda São Paulo	10/07	0,01	0,12	0,25	0,22	0,29	0,42	0,01
	24/07	0,09	0,26	0,33	0,39	0,44	1,20	0,04
	31/07	0,01	0,19	0,22	0,21	0,24	0,39	0,004
Estância Bela Vista	08/08	0,15	0,20	0,21	0,21	0,22	0,41	0,001
Sítio Novo II	04/06	0,05	0,14	0,19	0,29	0,49	0,68	0,03
	27/06	0,08	0,18	0,20	0,23	0,23	0,87	0,01
	04/07	0,15	0,27	0,30	0,31	0,33	0,98	0,01

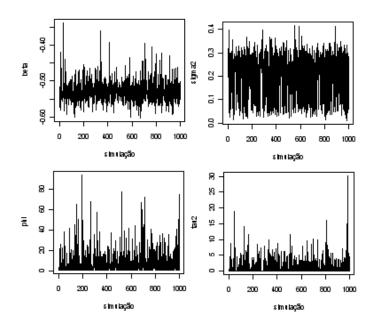


Figura 3.2 – Gráficos da convergência dos parâmetros - Fazenda São Paulo - 10/07.

Tabela 3.11 – Resumo estatístico para ϕ

Prorpiedade	Data	Mín.	Q1	Md	\overline{X}	Q3	Máx.	Var.
Fazenda São Paulo	10/07	0,54	1,00	3,84	7,30	8,24	93,86	110,22
	24/07	0,57	15,18	27,83	32,65	46,34	111,20	470,72
	31/07	0,54	0,60	1,00	2,87	3,37	67,15	27,93
Estância Bela Vista	08/08	1,03	14,38	15,72	15,79	17,12	28,54	6,51
Sítio Novo II	04/06	0,54	2,48	44,70	41,22	67,61	201,30	1283,98
	27/06	3,89	23,06	26,88	26,23	30,44	56,54	55,17
	04/07	4,85	21,61	24,51	24,86	27,88	49,41	33,48

Tabela 3.12 – Resumo estatístico para τ^2

Prorpiedade	Data	Mín.	Q1	Md	\overline{X}	Q3	Máx.	Var.
Fazenda São Paulo	10/07	0,00	0,00	0,01	1,07	1,30	30,23	5,33
	24/07	0,00	1,25	2,01	2,10	2,78	10,030	1,87
	31/07	0,00	0,00	0,01	0,47	0,01	25,57	3,19
Estância Bela Vista	08/08	0,00	0,83	0,95	0,93	1,05	1,60	0,047
Sítio Novo II	04/06	0,00	0,01	1,99	1,90	3,01	10,75	3,23
	27/06	0,00	2,12	2,54	2,51	2,95	10,09	0,85
	04/07	0,00	1,68	1,97	1,97	2.25	5,00	0,30

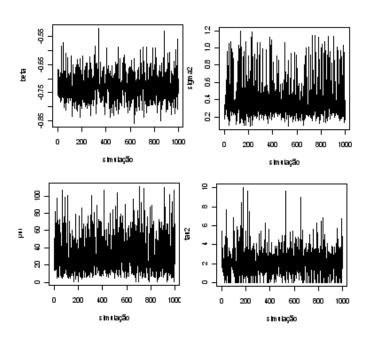


Figura 3.3 – Gráficos da convergência dos parâmetros - Fazenda São Paulo - 24/07.

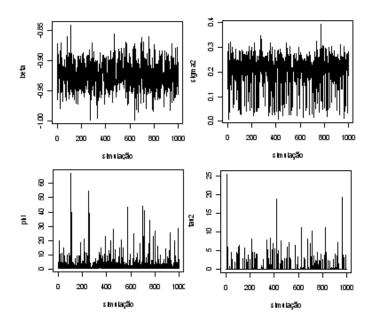


Figura 3.4 – Gráficos da convergência dos parâmetros - Fazenda São Paulo - 31/07.

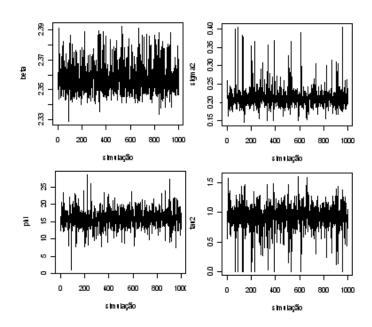


Figura 3.5 – Gráficos da convergência dos parâmetros - Estância Bela Vista - 08/08.

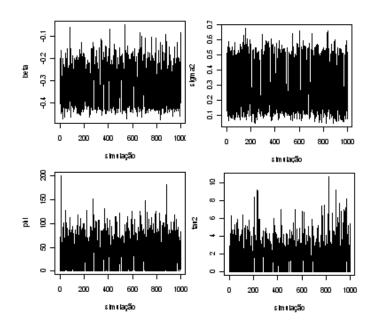


Figura 3.6 – Gráficos da convergência dos parâmetros - Sítio Novo II - 04/06.

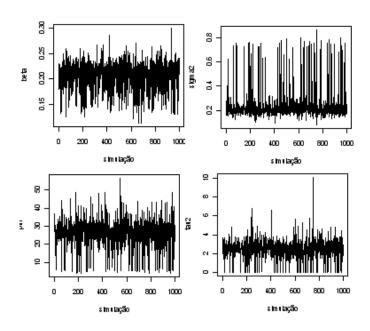


Figura 3.7 – Gráficos da convergência dos parâmetros - Sítio Novo II - 27/06.

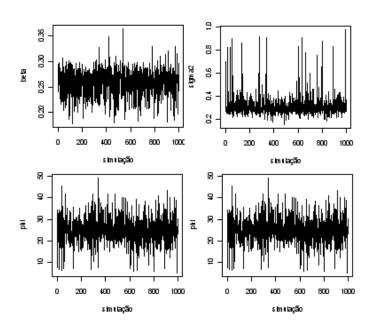


Figura 3.8 – Gráficos da convergência dos parâmetros - Sítio Novo II - 04/07.

ANEXO B

Tabela 3.13 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0=-3,00,\ \beta_1=-1,00,\ \beta_2=-1,00$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando baixa infestação e quatro vizinhos

			0,00	- Curra		0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-3,10	0,41	0,36	-3,08	0,41	0,35	-3,05	0,41	0,35	-3,03	0,40	0,35	-3,01	0,39	0,34
	β_1	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,02	0,24	0,22
	β_2	-1,05	0,25	0,24	-1,05	0,25	0,24	-1,05	0,24	0,24	-1,05	0,24	0,24	-1,04	0,24	0,24
	γ	-0,87	6,34	47,45	-0,62	4,90	25,83	-0,69	5,84	36,28	-0,50	4,89	25,06	-0,41	4,96	27,34
M2	β_0	-2,23	0,24	0,23	-2,22	0,24	0,22	-2,20	0,24	0,22	-2,19	0,24	0,22	-2,17	0,24	0,22
	γ	-1,14	5,93	32,36	-0,88	4,65	19,51	-0,91	5,51	26,95	-0,70	4,63	19,07	-0,59	4,64	18,84
M3	β_0	-3,10	0,36	0,32	-3,07	0,35	0,32	-3,04	0,35	0,31	-3,01	0,34	0,31	-2,98	0,33	0,31
	β_1	-1,03	0,24	0,23	-1,02	0,24	0,23	-1,02	0,24	0,23	-1,02	0,23	0,22	-1,01	0,23	0,22
	β_2	-1,04	0,25	0,24	-1,04	0,24	0,24	-1,04	0,24	0,24	-1,04	0,24	0,23	-1,04	0,24	0,23
M4	β_0	-3,12	0,41	0,36	-3,09	0,41	0,36	-3,07	0,41	0,35	-3,04	0,40	0,35	-3,02	0,40	0,35
	β_1	-1,04	0,24	0,23	-1,04	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23
	β_2	-1,06	0,25	0,24	-1,06	0,25	0,24	-1,06	0,25	0,24	-1,05	0,24	0,24	-1,05	0,24	0,24
	γ_1	-1,39	4,57	110,00	-1,24	4,32	93,10	-1,08	4,04	80,59	-0,88	3,68	64,49	-0,78	3,52	58,44
	γ_2	-0,67	3,26	52,28	-0,54	2,93	39,36	-0,40	2,47	20,95	-0,31	2,14	21,15	-0,30	2,16	21,73
M6	β_0	-2,23	0,24	0,23	-2,22	0,24	0,23	-2,20	0,24	0,22	-2,19	0,24	0,22	-2,18	0,24	0,22
	γ_1	-1,57	4,43	86,90	-1,42	4,19	76,53	-1,25	3,92	65,59	-1,05	3,58	53,63	-0,93	3,42	48,05
	γ_2	-0,60	3,12	40,58	-0,47	2,81	31,62	-0,33	2,39	24,52	-0,24	2,09	19,25	-0,22	2,10	19,59

Tabela 3.14 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0=-3,00,\ \beta_1=-1,00,\ \beta_2=-1,00$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando baixa infestação e oito vizinhos

		Side	0,00	Daixa	meste	0,25	e oito v	1211110	$\frac{0.50}{0.50}$			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC		Est	EPC		Est	EPC	EP
M1	β_0	-3,07	0,44	0,38	-3,04		0,38	-3,02	0,44	0,37	-2,99	0,44	0,37	-2,97	0,64	0,37
	β_1	-1,04	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,03	0,24	0,23	-1,03	1,06	0,22
	β_2	-1,05	0,25	0,24	-1,05	0,25	0,24	-1,05	0,25	0,24	-1,05	0,25	0,24	-1,05	0,60	0,24
	γ	-0,82	3,29	2,26	-0,74	3,12	2,21	-0,73	3,12	2,17	-0,67	2,95	2,13	-0,59	1,38	2,08
M2	β_0	-2,21	0,29	0,26	-2,20	0,29	0,26	-2,18	0,29	0,26	-2,17	0,29	0,25	-2,16	1,64	0,25
	γ	-0,83	2,84	1,95	-0,72	2,69	1,91	-0,68	2,66	1,88	-0,59	2,52	1,83	-0,49	4,81	1,79
M3	β_0	-3,10	0,36	0,32	-3,07	0,35	0,32	-3,04	0,35	0,31	-3,02	0,34	0,31	-2,98	0,48	0,31
	β_1	-1,03	0,24	0,23	-1,02	0,24	0,23	-1,02	0,24	0,23	-1,02	0,23	0,22	-1,02	0,99	0,22
	β_2	-1,04	0,25	0,24	-1,04	0,24	0,24	-1,04	0,24	0,24	-1,04	0,24	0,23	-1,04	0,60	0,23
M4	β_0	-3,12	0,47	0,39	-3,10	0,46	0,39	-3,07	0,47	0,39	-3,05	0,46	0,39	-3,03	0,46	0,38
	β_1	-1,06	0,25	0,24	-1,06	0,25	0,24	-1,05	0,25	0,24	-1,06	0,25	0,24	-1,05	0,25	0,23
	β_2	-1,07		•	-1,07		,	-1,08	,	•	•		0,25	•		•
	γ_1			-	•		101,70									
	γ_2	-0,68			-0,54		-						25,45			
	γ_3	-0,78		-	-0,70		-						41,74			
	γ_4	-0,77			-0,62		-						20,83			
M5	β_0	-2,25			-2,24		-									0,26
	γ_1	-1,59		-	-1,43		-						63,78			
	γ_2	-0,61		•	-0,47		-	•		•	•			•		23,30
	γ_3	-0,68		-	-0,60		-						35,91			
	γ_4	-0,65	3,26	50,05	-0,51	2,88	37,93	-0,46	2,77	33,38	-0,29	2,18	18,89	-0,32	2,35	22,07

Tabela 3.15 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;$ 0.25; 0.50; 0.75 e 1.00 considerando média infestação e quatro vizinhos

		1	0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP												
M1	β_0	-1,02	0,26	0,20	-0,94	0,26	0,21	-0,87	0,26	0,21	-0,78	0,26	0,21	-0,69	0,26	0,21
	β_1	0,26	0,12	0,12	0,25	0,12	0,12	0,25	0,11	0,12	0,25	0,11	0,12	0,25	0,11	0,11
	β_2	0,26	0,14	0,14	0,25	0,14	0,13	0,25	0,14	0,13	0,25	0,13	0,13	0,25	0,13	0,13
	γ	-0,04	0,83	0,59	-0,05	0,78	0,57	-0,03	0,75	0,55	-0,02	0,71	0,53	-0,02	0,70	0,52
M2	β_0	-0,98	0,26	0,20	-0,91	0,25	0,20	-0,84	0,25	0,20	-0,76	0,25	0,20	-0,67	0,26	0,21
	γ	-0,06	0,82	0,57	-0,06	0,77	0,56	-0,03	0,74	0,54	-0,01	0,71	0,52	0,00	0,70	0,51
M3	β_0	-1,02	0,13	0,13	-0,95	0,13	0,13	-0,87	0,13	0,12	-0,78	0,13	0,12	-0,69	0,12	0,12
	β_1	0,26	0,12	0,12	0,25	0,12	0,12	0,25	0,11	0,12	0,25	0,11	0,11	0,25	0,11	0,11
	β_2	0,26	0,14	0,14	0,25	0,14	0,13	0,25	0,14	0,13	0,25	0,13	0,13	0,25	0,13	0,13
M4	β_0	-1,02	0,27	0,21	-0,95	0,26	0,21	-0,87	0,26	0,21	-0,78	0,26	0,21	-0,69	0,26	0,21
	β_1	0,26	0,12	0,12	0,26	0,12	0,12	0,25	0,11	0,12	0,25	0,11	0,12	0,25	0,11	0,11
	β_2	0,26	0,14	0,14	0,25	0,14	0,13	0,25	0,14	0,13	0,25	0,13	0,13	0,25	0,13	0,13
	γ_1	-0,01	0,30	0,21	-0,02	0,29	0,20	-0,01	0,28	0,19	0,00	0,26	0,19	0,00	0,26	0,18
	γ_2	-0,02	0,29	0,21	-0,01	0,27	0,20	-0,01	0,26	0,20	-0,01	0,25	0,19	-0,01	0,25	0,18
M5	β_0	-0,98	0,26	0,20	-0,91	0,25	0,20	-0,84	0,25	0,20	-0,76	0,25	0,20	-0,67	0,26	0,21
	γ_1	-0,01	0,30	0,20	-0,02	0,28	0,20	-0,01	0,27	0,19	0,00	0,26	0,18	0,01	0,25	0,18
	γ_2	-0,03	0,28	0,20	-0,02	0,27	0,20	-0,02	0,26	0,19	-0,01	0,25	0,19	-0,01	0,25	0,18

Tabela 3.16 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;\,0.25;\,0.50;\,0.75$ e 1.00 considerando média infestação e oito vizinhos

		OITO	v1z1n	nos												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-0,97	0,34	0,26	-0,90	0,34	0,26	-0,82	0,34	0,26	-0,74	0,34	0,27	-0,65	0,35	0,27
	β_1	0,26	0,12	0,12	0,25	0,12	0,12	0,25	0,11	0,12	0,25	0,11	0,12	0,25	0,11	0,11
	β_2	0,26	0,14	0,14	0,25	0,14	0,13	0,25	0,14	0,13	0,25	0,13	0,13	0,25	0,13	0,13
	γ	-0,21	1,18	0,82	-0,22	1,13	0,80	-0,20	1,09	0,77	-0,17	1,03	0,75	-0,14	1,01	0,72
M2	β_0	-0,94	0,33	0,25	-0,87	0,34	0,25	-0,79	0,34	0,26	-0,72	0,34	0,26	-0,64	0,35	0,26
	γ	-0,21	1,17	0,81	-0,21	1,12	0,78	-0,19	1,08	0,76	-0,14	1,02	0,73	-0,11	1,00	0,71
M3	β_0	-1,02	0,13	0,13	-0,95	0,13	0,13	-0,87	0,13	0,12	-0,78	0,13	0,12	-0,69	0,12	0,12
	β_1	0,26	0,12	0,12	0,25	0,12	0,12	0,25	0,11	0,12	0,25	0,11	0,11	0,25	0,11	0,11
	β_2	0,26	0,14	0,14	0,25	0,14	0,13	0,25	0,14	0,13	0,25	0,13	0,13	0,25	0,13	0,13
M4	β_0	-1,01	0,35	0,26	-0,93	0,35	0,27	-0,85	0,35	0,27	-0,77	0,35	0,27	-0,68	0,36	0,28
	β_1	0,26	0,12	0,12	0,26	0,12	0,12	0,26	0,12	0,12	0,25	0,12	0,12	0,26	0,11	0,12
	β_2	0,26	0,14	0,14	0,25	0,14	0,14	0,26	0,14	0,13	0,26	0,13	0,13	0,26	0,13	0,13
	γ_1	-0,01	0,31	0,21	-0,02	0,30	0,20	-0,01	0,29	0,20	-0,01	0,27	0,19	0,00	0,26	0,19
	γ_2	-0,02	0,30	0,21	-0,02	0,28	0,20	-0,02	0,27	0,20	-0,01	0,26	0,19	-0,02	0,26	0,19
	γ_3	-0,04	0,30	0,21	-0,04	0,29	0,20	-0,04	0,27	0,20	-0,03	0,26	0,19	-0,02	0,25	0,19
	γ_4	-0,02	0,30	0,21	-0,02	0,29	0,20	-0,02	0,28	0,20	-0,01	0,26	0,19	0,00	0,25	0,19
M5	β_0	-0,97	0,34	0,26	-0,90	0,34	0,26	-0,83	0,35	0,26	-0,75	0,35	0,27	-0,67	0,35	0,27
	γ_1	-0,01	0,30	0,21	0,00	0,29	0,20	-0,01	0,28	0,19	-0,01	0,26	0,19	0,00	0,26	0,18
	γ_2	-0,03	0,29	0,21	-0,02	0,28	0,20	-0,02	0,27	0,19	-0,01	0,26	0,19	-0,01	0,25	0,18
	γ_3	-0,03	0,29	0,21	-0,03	0,28	0,20	-0,03	0,27	0,19	-0,02	0,26	0,19	-0,01	0,25	0,18
	γ_4	-0,01	0,30	0,21	-0,01	0,29	0,20	-0,01	0,28	0,19	0,00	0,26	0,19	0,01	0,25	0,18

Tabela 3.17 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando alta infestação e quatro vizinhos

		quai	10 11	LIIIIO	3											
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	0,05	0,36	0,30	0,13	0,37	0,31	0,22	0,39	0,32	0,33	0,43	0,34	0,45	0,47	0,36
	β_1	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,04	0,16	0,16
	β_2	1,03	0,17	0,17	1,03	0,17	0,17	1,02	0,17	0,17	1,02	0,17	0,17	1,02	0,18	0,17
	γ	-0,09	0,67	0,54	0,00	0,67	0,54	0,10	0,68	0,54	0,18	0,71	0,54	0,24	0,75	0,55
M2	β_0	0,08	0,31	0,25	0,12	0,33	0,26	0,15	0,34	0,27	0,21	0,37	0,29	0,27	0,41	0,30
	γ	-0,17	0,59	0,45	-0,06	0,59	0,45	0,07	0,60	0,45	0,17	0,62	0,46	0,25	0,66	0,47
M3	β_0	0,00	0,13	0,13	0,13	0,13	0,13	0,27	0,13	0,13	0,43	0,14	0,14	0,59	0,14	0,14
	β_1	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,15	0,15	1,03	0,16	0,15	1,04	0,16	0,16
	β_2	1,02	0,17	0,16	1,02	0,17	0,16	1,02	0,17	0,17	1,02	0,17	0,17	1,02	0,18	0,17
M4	β_0	0,05	0,36	0,30	0,13	0,37	0,31	0,22	0,39	0,32	0,33	0,43	0,34	0,45	0,47	0,36
	β_1	1,03	0,16	0,15	1,04	0,16	0,15	1,04	0,16	0,15	1,04	0,16	0,16	1,04	0,16	0,16
	β_2	1,03	0,17	0,17	1,03	0,17	0,17	1,03	0,17	0,17	1,03	0,17	0,17	1,03	0,18	0,17
	γ_1	-0,02	0,24	0,19	0,00	0,24	0,19	0,02	0,25	0,19	0,05	0,25	0,19	0,06	0,26	0,20
	γ_2	0,00	0,25	0,19	0,00	0,25	0,19	0,03	0,25	0,19	0,04	0,25	0,20	0,07	0,26	0,20
M5	β_0	0,08	0,31	0,25	0,12	0,33	0,16	0,15	0,34	0,27	0,21	0,37	0,29	0,27	0,41	0,30
	γ_1	-0,04	0,20	0,16	-0,02	0,20	0,16	0,01	0,21	0,16	0,04	0,22	0,16	0,05	0,23	0,17
	γ_2	-0,05	0,22	0,16	-0,02	0,21	0,13	0,02	0,21	0,16	0,05	0,22	0,16	0,08	0,23	0,17

Tabela 3.18 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e sem dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando alta infestação e oito vizinhos

		<u>oito</u>	<u>vizin</u>	hos												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	0,13	0,51	0,40	0,21	0,53	0,42	0,29	0,55	0,43	0,40	0,57	0,45	0,50	0,62	0,48
	β_1	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,04	0,16	0,16
	β_2	1,03	0,17	0,17	1,02	0,17	0,17	1,03	0,17	0,17	1,02	0,17	0,17	1,02	0,17	0,17
	γ	-0,26	0,98	0,76	-0,15	0,98	0,76	-0,02	0,99	0,76	0,07	0,96	0,76	0,16	1,01	0,77
M2	β_0	0,12	0,45	0,34	0,15	0,47	0,35	0,18	0,48	0,36	0,23	0,49	0,38	0,27	0,53	0,40
	γ	-0,25	0,87	0,64	-0,12	0,87	0,64	0,02	0,86	0,64	0,13	0,83	0,64	0,25	0,87	0,65
M3	β_0	0,00	0,13	0,13	0,13	0,13	0,13	0,27	0,13	0,13	0,43	0,14	0,14	0,59	0,14	0,14
	β_1	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,16	0,15	1,03	0,15	0,16
	β_2	1,02	0,17	0,16	1,02	0,17	0,16	1,02	0,17	0,17	1,02	0,17	0,17	1,02	0,17	0,17
M4	β_0	0,10	0,52	0,41	0,17	0,54	0,43	0,25	0,57	0,44	0,36	0,58	0,47	0,46	0,64	0,49
	β_1	1,04	0,16	0,15	1,04	0,16	0,15	1,04	0,16	0,16	1,04	0,16	0,16	1,05	0,16	0,16
	β_2	1,04	0,17	0,17	1,04	0,17	0,17	1,04	0,17	0,17	1,03	0,17	0,17	1,03	0,18	0,17
	γ_1	-0,03	0,25	0,19	-0,01	0,25	0,19	0,00	0,25	0,19	0,02	0,26	0,20	0,04	0,27	0,20
	γ_2	-0,02	0,26	0,19	-0,01	0,26	0,19	0,02	0,26	0,20	0,02	0,26	0,20	0,04	0,27	0,20
	γ_3	-0,02	0,25	0,19	-0,01	0,25	0,19	0,01	0,26	0,19	0,02	0,25	0,19	0,02	0,26	0,20
	γ_4	-0,03	0,24	0,19	-0,01	0,25	0,19	0,00	0,25	0,19	0,01	0,25	0,19	0,02	0,25	0,20
M5	β_0	0,07	0,46	0,35	0,10	0,48	0,36	0,13	0,49	0,37	0,17	0,50	0,39	0,22	0,54	0,41
	γ_1	-0,04	0,21	0,16	-0,02	0,21	0,16	-0,01	0,22	0,16	0,00	0,22	0,17	0,02	0,23	0,17
	γ_2	-0,05	0,22	0,16	-0,03	0,22	0,16	0,01	0,22	0,16	0,02	0,22	0,17	0,04	0,24	0,17
	γ_3	0,01	0,21	0,16	0,02	0,22	0,16	0,03	0,22	0,16	0,05	0,22	0,16	0,05	0,22	0,17
	γ_4	0,00	0,21	0,16	0,02	0,22	0,16	0,03	0,22	0,16	0,05	0,22	0,16	0,07	0,22	0,17

Tabela 3.19 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00; 0.25; 0.50; 0.75 e 1.00 considerando baixa infestação e quatro vizinhos$

		quai	10 11	21111108												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-3,09	0,38	0,35	-3,07	0,39	0,35	-3,05	0,39	3,45	-3,03	0,38	0,34	-3,02	0,39	0,34
	β_1	-1,08	0,33	0,29	-1,09	0,33	0,29	-1,11	0,33	0,29	-1,12	0,32	0,29	-1,14	0,32	0,29
	β_2	-1,08	0,31	0,29	-1,10	0,31	0,29	-1,12	0,31	0,29	-1,15	0,32	0,29	-1,17	0,32	0,29
	γ	-0,66	2,85	6,10	-0,53	1,78	1,22	-0,53	2,91	8,29	-0,38	1,56	1,14	-0,29	1,54	1,10
M2	β_0	-2,61	0,27	0,25	-2,60	0,27	0,25	-2,58	0,26	0,25	-2,57	0,26	0,24	-2,56	0,26	0,24
	γ	2,33	2,70	6,13	2,50	1,53	1,03	2,53	2,62	5,58	2,71	1,32	0,94	2,83	1,29	0,90
M3	β_0	-3,10	0,36	0,34	-3,08	0,36	0,34	-3,06	0,36	0,33	-3,04	0,37	0,33	-3,02	0,36	0,33
	β_1	-1,04	0,30	0,28	-1,06	0,30	0,27	-1,08	0,29	0,27	-1,10	0,29	0,27	-1,12	0,28	0,27
	β_2	-1,04	0,27	0,27	-1,07	0,27	0,27	-1,09	0,27	0,27	-1,12	0,27	0,27	-1,14	0,27	0,27
M4	β_0	-3,10	0,40	0,35	-3,09	0,39	0,35	-3,07	0,39	0,35	-3,05	0,39	0,35	-3,03	0,38	0,34
	β_1	-1,08	0,33	0,29	-1,10	0,33	0,29	-1,12	0,33	0,29	-1,13	0,33	0,29	-1,15	0,32	0,29
	β_2	-1,09	0,32	0,30	-1,11	0,32	0,30	-1,13	0,32	0,30	-1,16	0,32	0,30	-1,18	0,32	0,30
	γ_1	-0,29	1,69	12,27	-0,20	1,28	6,05	-0,18	1,16	5,83	-0,14	0,81	1,89	-0,10	0,98	3,09
	γ_2	-0,49	2,39	26,93	-0,38	1,99	17,73	-0,27	1,59	10,92	-0,19	1,25	6,17	-0,12	0,57	0,40
M5	β_0	-2,32	1,25	0,25	-2,61	0,27	0,25	-2,59	0,26	0,25	-2,58	0,26	0,25	-2,57	0,27	0,25
	γ_1	0,46	1,61	9,18	0,55	1,23	5,02	0,58	1,08	3,84	0,63	0,74	1,29	0,67	0,93	2,56
	γ_2	0,29	2,31	21,35	0,40	1,93	14,61	0,51	1,53	9,24	0,60	1,19	4,60	0,67	0,51	0,36

Tabela 3.20 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando baixa infestação e

oito vizinhos 0,00 0,25 0,50 0.75 1,00 Est EPC Est EPC Est EPC Est EPC EP Est EPC EP Mod Par EP EP EP β_0 -3,05 0,41 0,36 -3,03 0,41 0,36 -3,01 0,40 0,35 -3,00 0,41 0,35 -2,98 0,40 0,35 M1 β_1 -1,11 0,36 0,30 -1,13 0,36 0.30 -1.14 0.35 0,30 -1,12 0,45 0,30 -1,16 0,34 0,30 0,31 -1,18 0,35 0,31 -1,20 0,36 0,31 -1,120,350,31 -1,14 0,35 0,31 -1,16 0,35 1,63 -0,85 2,32 1,57 -0,72 2,29 1,52 -1,20 2,69 1,74 -1,10 2,55 1,69 -0,99 2,50 γ M2-2,76 0,26 0,28 -2,75 0,27 0,27 -2,74 0,25 0,27 -2,74 0,26 0,27 -2,73 0,26 0,27 β_0 3,70 1,66 1,36 3,80 1,56 1,31 3,90 1,49 1,26 4,02 1,38 1,20 4,13 1,35 1,16 γ M3 -3,10 0,36 0,34 -3,08 0,36 0,34 -3,06 0,36 0,33 -3,04 0,36 0,33 -3,02 0,36 0,33 β_1 0,28 -1,06 0,30 0,27 -1,07 0,29 0,27 -1,09 0,29 0,27 -1,12 0,28 0,27 -1,04 0,30 -1,04 0,27 0,27 -1,06 0,27 0,27 -1,08 0,27 0,27 -1,11 0,27 0,27 -1,13 0,27 0,27 0,37 -3,08 0,43 M4 -3,11 0,43 0,37 -3,10 0,43 0,36 -3,06 0,42 0,36 -3,05 0,42 0,36 0,31 -1,15 0,35 0,30 -1,17 0,35 0,30 -1,12 0,37 0,31 -1,13 0,36 0,31 -1,14 0,36 β_1 β_2 -1,13 0,36 0,32 -1,15 0,36 0,32 -1,17 0,36 0,32 -1,19 0,36 0,32 -1,21 0,36 0,32 -0,29 1,70 12,09 -0,22 1,40 7,39 -0,18 1,20 6,67 -0,16 1,01 3,39 -0,12 1,16 4,57 γ_1 -0,49 2,41 27,32 -0,38 2,01 18,10 -0,28 1,61 11,41 -0,19 1,26 6,11 -0,15 0,81 1,85 γ_2 -0,32 1,80 13,37 -0,24 1,40 8,05 -0,18 1,16 5,36 -0,14 1,03 2,94 -0,12 0,84 1,61 γ_3 9,30 -0,16 0,99 3,32 -0,13 0,81 1,84 -0,13 0,82 1,67 -0,26 1,51 9,34 -0,24 1,49 γ_4 -2,84 0,29 0,29 -2,83 0,29 0,29 -2,82 0,29 0,29 -2,82 0,28 0,28 -2,81 0,28 0,28 M5 β_0 0,37 1,65 10,89 0,43 1,38 7,08 0,47 1,13 4,37 0,48 0,95 2,31 0,53 1,10 3,57 γ_1 0,19 2,35 23,34 0,30 1,95 14,93 0,40 1,56 9,68 0,48 1,27 6,18 0,52 0,81 1,81 γ_2 0,29 1,77 13,45 0,38 1,36 7,84 0,43 1,11 4,18 0,47 1,00 3,11 0,49 0,82 1,59 γ_3 0,33 1,49 9,00 0,35 1,47 8,93 0,43 0,98 3,39 0,45 0,80 1,84 0,46 0,80 1,72 γ_4

Tabela 3.21 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando média infestação e quatro vizinhos

		quui	10 112	ZIIIIIO												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-0,98	0,25	0,20	-0,91	0,25	0,21	-0,83	0,25	0,21	-0,74	0,26	0,21	-0,65	0,28	0,21
	β_1	0,26	0,14	0,14	0,27	0,14	0,13	0,28	0,14	0,13	0,30	0,14	0,13	0,31	0,14	0,13
	β_2	0,26	0,14	0,13	0,27	0,14	0,13	0,29	0,14	0,13	0,30	0,14	0,13	0,31	0,14	0,13
	γ	-0,18	0,84	0,59	-0,17	0,80	0,58	-0,15	0,77	0,56	-0,14	0,75	0,54	-0,12	0,73	0,53
M2	β_0	-1,09	0,25	0,20	-1,04	0,24	0,20	-0,97	0,24	0,20	-0,91	0,25	0,20	-0,84	0,26	0,20
	γ	0,27	0,82	0,57	0,30	0,77	0,55	0,35	0,74	0,53	0,41	0,71	0,51	0,45	0,70	0,49
M3	β_0	-1,02	0,13	0,13	-0,95	0,13	0,13	-0,87	0,13	0,12	-0,78	0,12	0,12	-0,69	0,12	0,12
	β_1	0,25	0,14	0,13	0,26	0,13	0,13	0,27	0,13	0,13	0,29	0,13	0,13	0,30	0,13	0,13
	β_2	0,25	0,13	0,13	0,26	0,13	0,13	0,28	0,13	0,13	0,30	0,13	0,13	0,31	0,13	0,13
M4	β_0	-0,98	0,25	0,20	-0,91	0,25	0,21	-0,83	0,25	0,21	-0,74	0,26	0,21	-0,65	0,28	0,21
	β_1	0,26	0,15	0,14	0,27	0,14	0,13	0,28	0,14	0,13	0,30	0,14	0,13	0,31	0,14	0,13
	β_2	0,26	0,14	0,14	0,27	0,14	0,13	0,29	0,14	0,13	0,31	0,14	0,13	0,32	0,14	0,13
	γ_1	-0,04	0,30	0,21	-0,03	0,29	0,20	-0,03	0,28	0,20	-0,03	0,27	0,19	-0,02	0,26	0,19
	γ_2	-0,06	0,30	0,21	-0,06	0,29	0,20	-0,05	0,27	0,20	-0,05	0,26	0,19	-0,04	0,26	0,19
M5	β_0	-1,10	0,24	0,20	-1,04	0,24	0,20	-0,98	0,24	0,20	-0,91	0,25	0,20	-0,85	0,26	0,20
	γ_1	0,07	0,29	0,20	0,08	0,28	0,20	0,09	0,27	0,19	0,11	0,26	0,18	0,12	0,25	0,18
	γ_2	0,06	0,29	0,20	0,06	0,28	0,20	0,76	0,27	0,19	0,09	0,25	0,18	0,11	0,25	0,18

Tabela 3.22 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;\,0.25;\,0.50;\,0.75$ e 1.00 considerando média infestação e oito vizinhos

		01to	V1Z1n	<u>hos</u>												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-0,91	0,34	0,26	-0,84	0,34	0,26	-0,76	0,35	0,26	-0,67	0,36	0,27	-0,58	0,37	0,27
	β_1	0,27	0,15	0,14	0,28	0,15	0,14	0,29	0,15	0,13	0,30	0,15	0,13	0,31	0,14	0,13
	β_2	0,27	0,15	0,14	0,28	0,15	0,14	0,30	0,15	0,13	0,31	0,15	0,13	0,32	0,15	0,13
	γ	-0,44	1,21	0,84	-0,41	1,17	0,81	-0,39	1,14	0,79	-0,36	1,11	0,76	-0,33	1,06	0,74
M2	β_0	-1,12	0,31	0,24	-1,08	0,31	0,25	-1,03	0,31	0,25	-0,98	0,32	0,25	-0,92	0,33	0,25
	γ	0,38	1,08	0,77	0,45	1,03	0,75	0,52	1,00	0,72	0,61	0,95	0,69	0,68	0,93	0,66
M3	β_0	-1,02	0,13	0,13	-0,95	0,13	0,13	-0,87	0,13	0,12	-0,78	0,12	0,12	-0,61	0,34	0,12
	β_1	0,25	0,14	0,13	0,26	0,13	0,13	0,27	0,13	0,13	0,29	0,13	0,13	0,30	0,13	0,13
	β_2	0,25	0,13	0,13	0,26	0,13	0,13	0,28	0,13	0,13	0,29	0,13	0,13	0,31	0,13	0,13
M4	β_0	-0,94	0,35	0,26	-0,87	0,35	0,27	-0,79	0,35	0,27	-0,70	0,37	0,28	-0,61	0,38	0,28
	β_1	0,27	0,16	0,14	0,28	0,15	0,14	0,29	0,15	0,14	0,31	0,15	0,14	0,31	0,14	0,13
	β_2	0,27	0,15	0,14	0,28	0,15	0,14	0,30	0,15	0,14	0,31	0,15	0,14	0,32	0,15	0,13
	γ_1	-0,04	0,31	0,21	-0,04	0,29	0,21	-0,03	0,28	0,20	-0,03	0,27	0,19	-0,03	0,26	0,19
	γ_2	-0,06	0,31	0,21	-0,06	0,29	0,21	-0,05	0,28	0,20	-0,05	0,27	0,19	-0,04	0,27	0,19
	γ_3	-0,05	0,29	0,21	-0,05	0,28	0,21	-0,05	0,28	0,20	-0,04	0,28	0,19	-0,03	0,26	0,19
	γ_4	-0,05	0,30	0,21	-0,04	0,29	0,21	-0,04	0,27	0,20	-0,04	0,27	0,19	-0,04	0,27	0,19
M5	β_0	-1,16	0,31	0,25	-1,12	0,32	0,25	-1,06	0,32	0,25	-1,01	0,33	0,26	-0,96	0,34	0,26
	γ_1	0,07	0,30	0,21	0,08	0,28	0,20	0,09	0,27	0,19	0,10	0,26	0,19	0,11	0,25	0,18
	γ_2	0,05	0,30	0,21	0,06	0,29	0,20	0,07	0,27	0,19	0,09	0,26	0,19	0,10	0,26	0,18
	γ_3	0,05	0,28	0,21	0,06	0,27	0,20	0,06	0,27	0,19	0,08	0,27	0,19	0,09	0,25	0,18
	γ_4	0,05	0,29	0,21	0,06	0,28	0,20	0,07	0,26	0,19	0,08	0,26	0,19	0,08	0,26	0,18

Tabela 3.23 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;~0.25;~0.50;~0.75$ e 1.00 considerando alta infestação e quatro vizinhos

		1	0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP												
M1	β_0	0,08	0,40	0,31	0,18	0,42	0,32	0,29	0,43	0,34	0,40	0,45	0,36	0,53	0,47	0,38
	β_1	1,04	0,21	0,18	1,08	0,21	0,18	1,12	0,22	0,19	1,15	0,22	0,19	1,19	0,23	0,20
	β_2	1,06	0,23	0,19	1,09	0,23	0,19	1,12	0,23	0,20	1,16	0,23	0,21	1,20	0,24	0,21
	γ	-0,15	0,74	0,56	-0,08	0,76	0,57	-0,02	0,75	0,57	0,05	0,76	0,58	0,10	0,75	0,59
M2	β_0	-1,30	0,26	0,23	-1,32	0,26	0,24	-1,34	0,26	0,24	-1,36	0,27	0,25	-1,36	0,27	0,26
	γ	2,51	0,52	0,41	2,64	0,51	0,41	2,77	0,51	0,41	2,90	0,51	0,42	3,01	0,51	0,42
M3	β_0	0,00	0,13	0,13	0,13	0,13	0,13	0,28	0,14	0,14	0,42	0,14	0,14	0,59	0,15	0,15
	β_1	1,01	0,15	0,15	1,06	0,15	0,15	1,11	0,16	0,16	1,16	0,16	0,16	1,21	0,18	0,17
	β_2	1,03	0,17	0,16	1,07	0,17	0,16	1,12	0,17	0,17	1,17	0,18	0,17	1,21	0,19	0,18
M4	β_0	0,08	0,40	0,31	0,18	0,42	0,33	0,29	0,43	0,34	0,40	0,45	0,36	0,54	0,48	0,38
	β_1	1,05	0,21	0,18	1,09	0,22	0,18	1,13	0,22	0,19	1,16	0,21	0,20	1,20	0,23	0,20
	β_2	1,07	0,23	0,19	1,10	0,23	0,20	1,13	0,23	0,20	1,17	0,23	0,21	1,21	0,24	0,21
	γ_1	-0,03	0,28	0,21	-0,02	0,28	0,21	-0,01	0,28	0,21	0,01	0,28	0,21	0,03	0,29	0,22
	γ_2	-0,05	0,28	0,21	-0,03	0,29	0,21	-0,01	0,30	0,21	0,01	0,29	0,21	0,02	0,29	0,22
M5	β_0	-1,30	0,26	0,23	-1,32	0,26	0,24	-1,34	0,26	0,24	-1,36	0,27	0,25	-1,37	0,28	0,26
	γ_1	0,61	0,22	0,17	0,64	0,22	0,17	0,67	0,22	0,17	0,71	0,22	0,17	0,74	0,23	0,18
	γ_2	0,64	0,21	0,17	0,68	0,21	0,17	0,72	0,22	0,17	0,74	0,22	0,17	0,77	0,22	0,18

Tabela 3.24 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis independentes e com dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando alta infestação e oito vizinhos

		OHO	V1Z1n	nos												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	0,16	0,51	0,39	0,24	0,53	0,41	0,33	0,54	0,42	0,42	0,56	0,44	0,53	0,56	0,47
	β_1	1,07	0,23	0,19	1,09	0,23	0,20	1,13	0,24	0,20	1,15	0,24	0,21	1,19	0,24	0,22
	β_2	1,09	0,25	0,21	1,11	0,26	0,21	1,14	0,25	0,22	1,17	0,26	0,22	1,20	0,25	0,23
	γ	-0,31	0,98	0,74	-0,20	0,99	0,74	-0,10	0,97	0,74	0,00	0,97	0,75	0,09	0,93	0,75
M2	β_0	-1,68	0,23	0,27	-1,71	0,23	0,27	-1,74	0,23	0,28	-1,77	0,23	0,29	-1,80	0,24	0,29
	γ	3,31	0,47	0,49	3,44	0,45	0,49	3,57	0,45	0,49	3,70	0,45	0,50	3,81	0,45	0,50
M3	β_0	0,00	0,13	0,13	0,13	0,13	0,13	0,27	0,14	0,14	0,42	0,14	0,14	0,58	0,15	0,15
	β_1	1,01	0,15	0,15	1,06	0,15	0,15	1,11	0,16	0,16	1,15	0,17	0,16	1,20	0,17	0,16
	β_2	1,03	0,17	0,16	1,07	0,17	0,16	1,11	0,17	0,17	1,16	0,18	0,14	1,21	0,18	0,18
M4	β_0	0,13	0,53	0,40	0,20	0,55	0,41	0,30	0,55	0,45	0,39	0,57	0,45	0,50	0,58	0,48
	β_1	1,08	0,23	0,20	1,10	0,24	0,21	1,14	0,24	0,21	1,16	0,24	0,21	1,19	0,25	0,22
	β_2	1,09	0,25	0,21	1,12	0,26	0,21	1,14	0,25	0,22	1,17	0,26	0,23	1,20	0,26	0,23
	γ_1	-0,03	0,29	0,21	-0,02	0,29	0,21	-0,01	0,29	0,21	0,02	0,29	0,22	0,03	0,31	0,22
	γ_2	-0,04	0,29	0,21	-0,02	0,30	0,21	0,00	0,31	0,21	0,01	0,31	0,22	0,01	0,30	0,22
	γ_3	-0,03	0,28	0,21	-0,02	0,28	0,21	-0,01	0,28	0,21	0,00	0,28	0,22	0,02	0,29	0,22
	γ_4	-0,03	0,29	0,21	-0,01	0,28	0,21	-0,01	0,29	0,21	0,00	0,29	0,21	0,03	0,30	0,22
M5	β_0	-1,74	0,25	0,27	-1,77	0,23	0,28	-1,80	0,24	0,29	-1,83	0,24	0,29	-1,86	0,25	0,30
	γ_1	0,44	0,27	0,18	0,46	0,27	0,18	0,48	0,28	0,19	0,50	0,27	0,19	0,52	0,29	0,19
	γ_2	0,47	0,26	0,18	0,50	0,27	0,18	0,52	0,28	0,18	0,54	0,28	0,19	0,54	0,28	0,19
	γ_3	0,41	0,25	0,18	0,42	0,25	0,18	0,43	0,25	0,19	0,44	0,25	0,19	0,46	0,26	0,19
	γ_4	0,39	0,25	0,18	0,41	0,25	0,18	0,41	0,25	0,19	0,43	0,25	0,19	0,45	0,26	0,19

Tabela 3.25 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00; 0.25; 0.50; 0.75 e 1.00 considerando baixa infestação e quatro vizinhos$

		4000	0,00			0,25			0,50			0,75			1,00	
									,							
Mod	Par	Est	EPC	EP												
M1	β_0	-3,09	0,38	0,35	-3,07	0,37	0,35	-3,06	0,37	0,34	-3,05	0,38	0,34	-3,03	0,37	0,34
	β_1	-1,12	0,75	0,70	-1,16	0,72	0,69	-1,19	0,73	0,69	-1,22	0,74	0,68	-1,25	0,73	0,68
	β_2	-0,99	0,71	0,69	-0,99	0,69	0,68	-1,00	0,69	0,68	-1,00	0,69	0,67	-1,01	0,68	0,67
	γ	-0,24	1,35	1,00	-0,20	1,33	0,97	-0,09	1,31	0,95	0,03	1,25	0,92	0,11	1,22	0,90
M2	β_0	-2,52	0,24	0,24	-2,51	0,24	0,24	-2,51	0,24	0,24	-2,51	0,23	0,24	-2,51	0,24	0,24
	γ	3,24	1,00	0,76	3,31	0,98	0,74	3,43	0,95	0,72	3,54	0,90	0,70	3,62	0,86	0,68
M3	β_0	-3,08	0,36	0,34	-3,06	0,36	0,34	-3,04	0,36	0,33	-3,03	0,36	0,33	-3,01	0,36	0,33
	β_1	-1,08	0,68	0,66	-1,12	0,66	0,65	-1,17	0,66	0,65	-1,23	0,67	0,65	-1,28	0,65	0,64
	β_2	-0,99	0,70	0,68	-0,99	0,68	0,68	-0,99	0,68	0,67	-0,99	0,68	0,66	-1,00	0,67	0,66
M4	β_0	-3,11	0,39	0,35	-3,09	0,38	0,35	-3,08	0,38	0,35	-3,07	0,38	0,35	-3,05	0,37	0,35
	β_1	-1,13	0,76	0,70	-1,17	0,73	0,70	-1,21	0,74	0,69	-1,23	0,75	0,69	-1,27	0,73	0,69
	β_2	-1,00	0,71	0,70	-1,00	0,70	0,69	-1,00	0,70	0,68	-1,01	0,70	0,68	-1,01	0,69	0,67
	γ_1	-0,08	0,50	0,37	-0,08	0,49	0,36	-0,04	0,49	0,35	0,00	0,47	0,34	0,01	0,46	0,33
	γ_2	-0,07	0,51	0,37	-0,05	0,50	0,36	-0,03	0,49	0,35	0,00	0,47	0,35	0,03	0,45	0,34
M5	β_0	-2,53	0,24	0,24	-2,52	0,24	0,24	-2,52	0,24	0,24	-2,52	0,24	0,24	-2,52	0,24	0,24
	γ_1	0,80	0,42	0,31	0,82	0,40	0,30	0,90	0,31	0,29	0,89	0,39	0,29	0,90	0,38	0,28
	γ_2	0,80	0,43	0,31	0,82	0,41	0,30	0,84	0,40	0,30	0,87	0,38	0,29	0,90	0,37	0,28

Tabela 3.26 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00; 0.25; 0.50; 0.75 e 1.00 considerando baixa infestação e oito vizinhos$

		oito	V1Z1n	hos												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-3,06	0,39	0,35	-3,04	0,39	0,35	-3,03	0,38	0,35	-3,02	0,38	0,35	-3,01	0,37	0,35
	β_1	-1,18	0,77	0,71	-1,21	0,75	0,71	-1,24	0,75	0,70	-1,25	0,77	0,70	-1,27	0,74	0,69
	β_2	-0,98	0,70	0,69	-0,99	0,69	0,68	-0,99	0,68	0,68	-1,00	0,69	0,67	-1,00	0,68	0,66
	γ	-0,58	1,83	1,33	-0,52	1,79	1,29	-0,37	1,73	1,25	-0,18	1,62	1,21	-0,03	1,50	1,17
M2	β_0	-2,71	0,22	0,26	-2,70	0,22	0,26	-2,70	0,22	0,26	-2,71	0,20	0,26	-2,70	0,21	0,26
	γ	4,49	0,92	0,95	4,53	0,87	0,92	4,62	0,85	0,89	4,71	0,79	0,86	4,77	0,75	0,83
M3	β_0	-3,08	0,36	0,34	-3,06	0,35	0,34	-3,04	0,35	0,33	-3,02	0,36	0,33	-3,00	0,36	0,33
	β_1	-1,08	0,68	0,66	-1,11	0,66	0,65	-1,17	0,66	0,65	-1,22	0,67	0,65	-1,27	0,65	0,64
	β_2	-0,99	0,70	0,68	-0,99	0,68	0,68	-0,99	0,67	0,67	-0,99	0,68	0,66	-1,00	0,67	0,66
M4	β_0	-3,14	0,41	0,37	-3,12	0,41	0,36	-3,11	0,41	0,36	-3,10	0,40	0,36	-3,08	0,40	0,36
	β_1	-1,19	0,80	0,74	-1,22	0,79	0,73	-1,25	0,78	0,73	-1,26	0,79	0,72	-1,28	0,76	0,72
	β_2	-1,00	0,73	0,71	-1,01	0,72	0,70	-1,01	0,71	0,70	-1,02	0,71	0,69	-1,02	0,70	0,68
	γ_1	-0,07	0,54	0,38	-0,06	0,53	0,37	-0,03	0,51	0,36	0,00	0,50	0,35	0,03	0,48	0,34
	γ_2	-0,06	0,54	0,38	-0,04	0,53	0,37	-0,02	0,52	0,37	0,00	0,50	0,36	0,23	0,41	0,35
	γ_3	-0,10	0,56	0,39	-0,09	0,55	0,38	-0,08	0,53	0,37	-0,06	0,49	0,36	-0,03	0,48	0,35
	γ_4	-0,08	0,55	0,39	-0,06	0,54	0,38	-0,04	0,51	0,37	-0,02	0,49	0,36	0,00	0,49	0,36
M5	β_0	-2,79	0,25	0,27	-2,78	0,24	0,27	-2,78	0,24	0,27	-2,78	0,23	0,27	-2,78	0,22	0,27
	γ_1	0,63	0,52	0,33	0,63	0,50	0,33	0,66	0,50	0,32	0,67	0,49	0,31	0,69	0,47	0,31
	γ_2	0,63	0,53	0,33	0,64	0,51	0,33	0,65	0,50	0,32	0,66	0,49	0,31	0,67	0,47	0,31
	γ_3	0,56	0,51	0,35	0,56	0,50	0,34	0,56	0,48	0,33	0,57	0,45	0,32	0,58	0,45	0,32
	γ_4	0,50	0,51	0,35	0,51	0,50	0,34	0,51	0,47	0,33	0,53	0,46	0,33	0,53	0,45	0,32

Tabela 3.27 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando média infestação e quatro vizinhos

		quat	10 112	ZIIIIIO	, D											
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-0,99	0,27	0,21	-0,92	0,26	0,21	-0,84	0,27	0,21	-0,75	0,27	0,21	-0,65	0,28	0,22
	β_1	0,24	0,45	0,43	0,26	0,44	0,43	0,29	0,43	0,42	0,33	0,41	0,42	0,36	0,41	0,41
	β_2	0,27	0,46	0,44	0,28	0,46	0,44	0,27	0,44	0,43	0,27	0,43	0,43	0,27	0,42	0,42
	γ	-0,12	0,84	0,59	-0,10	0,78	0,57	-0,09	0,78	0,56	-0,09	0,75	0,55	-0,09	0,72	0,53
M2	β_0	-1,15	0,25	0,20	-1,11	0,25	0,20	-1,06	0,26	0,20	-1,01	0,26	0,20	-0,96	0,26	0,20
	γ	0,57	0,78	0,54	0,64	0,72	0,52	0,71	0,72	0,50	0,77	0,69	0,49	0,84	0,66	0,47
M3	β_0	-1,02	0,13	0,13	-0,94	0,13	0,13	-0,86	0,13	0,13	-0,77	0,13	0,12	-0,68	0,12	0,12
	β_1	0,23	0,44	0,43	0,25	0,43	0,42	0,29	0,42	0,42	0,32	0,40	0,41	0,35	0,40	0,41
	β_2	0,27	0,45	0,44	0,28	0,45	0,43	0,27	0,44	0,43	0,27	0,43	0,42	0,27	0,42	0,42
M4	β_0	-0,99	0,26	0,21	-0,92	0,26	0,21	-0,84	0,27	0,21	-0,75	0,27	0,22	-0,65	0,28	0,22
	β_1	0,24	0,45	0,44	0,26	0,44	0,43	0,30	0,43	0,42	0,33	0,42	0,42	0,36	0,41	0,41
	β_2	0,28	0,46	0,45	0,28	0,46	0,44	0,28	0,44	0,43	0,27	0,43	0,43	0,27	0,42	0,42
	γ_1	-0,02	0,30	0,21	-0,02	0,28	0,20	-0,02	0,27	0,20	-0,02	0,26	0,19	-0,02	0,26	0,19
	γ_2	-0,05	0,30	0,21	-0,05	0,28	0,20	-0,03	0,28	0,20	-0,03	0,26	0,19	-0,02	0,26	0,19
M5	β_0	-1,16	0,25	0,20	-1,11	0,25	0,20	-1,06	0,26	0,20	-1,01	0,26	0,20	-0,96	0,26	0,20
	γ_1	0,15	0,28	0,20	0,17	0,26	0,19	0,18	0,25	0,19	0,19	0,25	0,18	0,21	0,24	0,18
	γ_2	0,13	0,28	0,20	0,15	0,27	0,19	0,17	0,26	0,19	0,19	0,25	0,18	0,22	0,24	0,17

Tabela 3.28 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0 =$, $\beta_1 =$, $\beta_2 =$ e γ =0,00; 0,25; 0,50; 0,75 e 1,00 considerando média infestação e oito vizinhos

		oito	<u>vizin</u>	hos												
			0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	-0,93	0,34	0,26	-0,87	0,34	0,26	-0,79	0,36	0,27	-0,70	0,35	0,27	-0,61	0,37	0,28
	β_1	0,26	0,45	0,44	0,27	0,44	0,43	0,31	0,43	0,43	0,34	0,42	0,42	0,37	0,41	0,42
	β_2	0,28	0,46	0,44	0,28	0,45	0,44	0,27	0,44	0,43	0,27	0,43	0,43	0,27	0,42	0,42
	γ	-0,35	1,18	0,83	-0,28	1,13	0,80	-0,26	1,11	0,78	-0,26	1,04	0,76	-0,23	1,02	0,74
M2	β_0	-1,24	0,30	0,24	-1,22	0,29	0,24	-1,18	0,30	0,24	-1,15	0,29	0,24	-1,12	0,30	0,25
	γ	0,87	0,99	0,73	1,01	0,93	0,70	1,11	0,89	0,67	1,21	0,82	0,64	1,31	0,80	0,62
M3	β_0	-1,02	0,13	0,13	-0,94	0,13	0,13	-0,86	0,13	0,13	-0,77	0,13	0,12	-0,68	0,12	0,12
	β_1	0,23	0,44	0,43	0,25	0,43	0,42	0,29	0,42	0,42	0,32	0,40	0,41	0,35	0,40	0,41
	β_2	0,27	0,45	0,44	0,28	0,45	0,43	0,27	0,44	0,43	0,27	0,43	0,42	0,27	0,42	0,42
M4	β_0	-0,96	0,35	0,27	-0,90	0,35	0,27	-0,82	0,36	0,27	-0,73	0,36	0,28	-0,64	0,37	0,29
	β_1	0,25	0,46	0,44	0,27	0,45	0,44	0,31	0,44	0,43	0,34	0,43	0,43	0,37	0,42	0,42
	β_2	0,28	0,47	0,45	0,29	0,47	0,44	0,27	0,45	0,44	0,27	0,44	0,43	0,27	0,43	0,43
	γ_1	-0,02	0,31	0,21	-0,02	0,29	0,21	-0,02	0,28	0,20	-0,02	0,27	0,20	-0,02	0,26	0,19
	γ_2	-0,05	0,30	0,21	-0,05	0,29	0,21	-0,04	0,28	0,20	-0,03	0,27	0,20	-0,02	0,27	0,19
	γ_3	-0,05	0,29	0,21	-0,04	0,29	0,21	-0,03	0,28	0,20	-0,02	0,26	0,20	-0,03	0,26	0,19
	γ_4	-0,03	0,29	0,21	-0,02	0,28	0,21	-0,03	0,27	0,20	-0,02	0,27	0,20	-0,01	0,26	0,19
M5	β_0	-1,28	0,30	0,25	-1,26	0,30	0,25	-1,23	0,30	0,25	-1,19	0,30	0,25	-1,16	0,31	0,2
5	γ_1	0,14	0,29	0,20	0,15	0,27	0,20	0,16	0,26	0,19	0,17	0,25	0,18	0,18	0,25	0,18
	γ_2	0,11	0,29	0,20	0,13	0,28	0,20	0,15	0,27	0,19	0,17	0,25	0,18	0,19	0,25	0,18
	γ_3	0,10	0,28	0,20	0,12	0,27	0,20	0,14	0,26	0,19	0,16	0,24	0,18	0,16	0,24	0,18
	γ_4	0,12	0,27	0,20	0,14	0,27	0,20	0,14	0,26	0,19	0,16	0,25	0,18	0,18	0,25	0,18

Tabela 3.29 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;~0.25;~0.50;~0.75$ e 1.00 considerando alta infestação e quatro vizinhos

		1	0,00			0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP												
M1	β_0	0,04	0,42	0,33	0,15	0,43	0,34	0,26	0,45	0,35	0,36	0,46	0,37	0,48	0,48	0,38
	β_1	1,02	0,51	0,51	1,07	0,52	0,51	1,13	0,54	0,52	1,19	0,54	0,52	1,27	0,54	0,53
	β_2	1,06	0,50	0,50	1,07	0,49	0,50	1,09	0,50	0,51	1,08	0,50	0,51	1,08	0,52	0,52
	γ	-0,08	0,81	0,61	-0,04	0,81	0,61	0,02	0,81	0,61	0,11	0,80	0,61	0,17	0,80	0,61
M2	β_0	-1,63	0,26	0,23	-1,64	0,25	0,24	-1,64	0,25	0,24	-1,66	0,26	0,25	-1,67	0,26	0,25
	γ	3,17	0,51	0,41	3,25	0,50	0,41	3,33	0,50	0,42	3,43	0,49	0,42	3,52	0,50	0,42
M3	β_0	0,00	0,14	0,14	0,02	0,20	0,15	0,27	0,15	0,15	0,41	0,16	0,16	0,57	0,16	0,16
	β_1	0,99	0,46	0,46	1,06	0,46	0,47	1,13	0,47	0,48	1,22	0,48	0,48	1,32	0,49	0,49
	β_2	1,06	0,49	0,50	1,07	0,49	0,50	1,08	0,50	0,51	1,08	0,50	0,51	1,07	0,51	0,52
M4	β_0	0,05	0,43	0,33	0,15	0,43	0,34	0,26	0,45	0,35	0,36	0,47	0,37	0,48	0,48	0,39
	β_1	1,02	0,51	0,51	1,08	0,52	0,51	1,14	0,54	0,52	1,20	0,54	0,53	1,28	0,55	0,54
	β_2	1,07	0,50	0,50	1,08	0,50	0,51	1,09	0,51	0,51	1,09	0,50	0,52	1,08	0,52	0,52
	γ_1	-0,02	0,31	0,23	-0,01	0,31	0,23	0,01	0,31	0,23	0,03	0,32	0,23	0,05	0,31	0,23
	γ_2	-0,03	0,30	0,22	-0,01	0,30	0,23	-0,01	0,30	0,23	0,02	0,31	0,23	0,03	0,30	0,23
M5	β_0	-1,63	0,26	0,24	-1,64	0,25	0,24	-1,65	0,26	0,24	-1,66	0,26	0,25	-1,68	0,26	0,26
	γ_1	0,80	0,23	0,18	0,82	0,23	0,18	0,85	0,23	0,18	0,87	0,24	0,18	0,89	0,24	0,19
	γ_2	0,79	0,22	0,18	0,81	0,22	0,18	0,82	0,23	0,18	0,85	0,23	0,18	0,87	0,23	0,18

Tabela 3.30 – Valores obtidos para a média das estimativas dos parametros a partir de 1000 simulações, supondo duas covariáveis dependentes e com dependência espacial, para $\beta_0=$, $\beta_1=$, $\beta_2=$ e $\gamma=0.00;~0.25;~0.50;~0.75$ e 1.00 considerando alta infestação e

oito vizinhos

		Ono	<u>vizin</u> 0,00	1108		0,25			0,50			0,75			1,00	
Mod	Par	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP	Est	EPC	EP
M1	β_0	0,10	0,51	0,40	0,18	0,53	0,42	0,27	0,54	0,43	0,35	0,53	0,45	0,46	0,55	0,46
	β_1	1,05	0,54	0,52	1,10	0,55	0,53	1,13	0,56	0,54	1,18	0,56	0,52	1,25	0,56	0,55
	β_2	1,06	0,50	0,50	1,07	0,50	0,50	1,08	0,51	0,51	1,08	0,50	0,51	1,07	0,51	0,52
	γ	-0,20	1,01	0,78	-0,11	1,01	0,78	-0,01	0,98	0,77	0,11	0,94	0,77	0,19	0,94	0,77
M2	β_0	-2,00	0,20	0,26	-2,01	0,19	0,27	-2,03	0,19	0,27	-2,05	0,19	0,28	-2,06	0,19	0,28
	γ	3,96	0,40	0,48	4,05	0,38	0,48	4,13	0,39	0,49	4,22	0,38	0,49	4,29	0,38	0,49
M3	β_0	0,00	0,14	0,14	0,13	0,15	0,15	0,27	0,15	0,15	0,41	0,16	0,16	0,56	0,16	0,16
	β_1	0,99	0,46	0,47	1,06	0,46	0,47	1,13	0,48	0,48	1,21	0,48	0,48	1,31	0,49	0,49
	β_2	1,06	0,49	0,50			•			-	1,08				•	ŕ
M4	β_0	0,07	0,52	0,41			•			-				0,42		-
	β_1	,	0,55	,	,						1,18		,	,	,	,
	β_2		0,51	,	,	•	,		,		1,10	,	,	,	,	,
	γ_1													0,05		
	γ_2	•		•			•			-				0,03	•	-
	γ_3	•		•			•			-				0,02	•	-
	γ_4	•		•			•			-				0,03	•	-
M5	β_0	-		-			•			-				-2,13		-
	γ_1	, , , , , , , , , , , , , , , , , , ,		ŕ	,						,		,	0,62	,	,
	γ_2	•		•			•			-				0,57	•	-
	γ_3	•		•			•			-				0,55	•	-
	γ_4	0,44	0,25	0,20	0,46	0,27	0,20	0,47	0,27	0,20	0,48	0,27	0,20	0,47	0,29	0,20